

2 相关工作

与本文相关的研究可归纳为以下四类：

金融问答 (Financial QA)

金融问答聚焦于财报、公告、研报等长文档中的事实性与数值型问题。该领域强调证据定位与实体对齐，且普遍存在缩写、口径不一致等问题。

检索增强生成 (RAG) 评测

RAG 将检索与生成结合，近年来的评测工作关注检索器类型（稀疏/稠密/混合）、检索器微调对下游任务的传导，以及复杂问题上的检索覆盖能力。

多跳/多步检索

多跳检索通过多轮检索逐步补全证据链，常用于跨段或跨文档推理。其核心挑战是如何设计有效的“继续检索”判断与证据合并策略。

智能化 RAG (Agentic RAG)

Agentic RAG 通过规划与工具调用扩展检索能力，但在成本、可控性与可复现性方面仍有挑战。本文选择规则化的多步检索与显式计算，以强调稳定性与可解释性。

3 方法

本文系统由四个核心模块构成：**查询理解**、**多步检索推理**、**证据整合与计算**、**答案生成**。系统采用流水线式数据流，模块间接口明确，便于复现与扩展。

图 1 多步检索循环流程 (示意)

Query → Query Understanding → Step-1 Retrieval → Gap Detector
→ (gap & gate) Refined Query Retrieval → Merge & Rank
→ Calculator (optional) → Template Answer

3.1 查询理解

目标是将原始金融查询规范化，解决缩写、实体歧义与任务类型识别问题。可采用：

规则与词典扩展（如将“YOY”扩展为“同比”）；

金融领域 NER 与实体链接；

轻量语义解析（不开启外部 API）。

输出为规范化查询 q_t 与结构化槽位（实体、指标、年份、计算类型），作为多步检索的输入。

3.2 多步检索推理

多步检索在第 t 轮使用当前查询 q_t 检索 $top-k$ 证据，基于 gap 检测决定是否继续：

****Gap Detector****: 判断是否缺失关键年份或比较对象;

- ****Gate****: 若 $\text{gap_conf} < \tau$, 终止后续检索;

****Merge Strategy****: 跨步候选去重并按 maxscore 或 step1 extunderscore first 排序;

- ****Stop Criteria****: 达到 T 或连续无新增证据时停止。

关键超参数定义:

检索轮数 T (max_steps)

- 每轮检索 top- k (top_k_each_step)

最终截断 top- k_f (top_k_final)

- 门控阈值 τ (min_gap_conf)

****Step6 最优配置****: $T=2$, $\text{top_k_each_step}=10$, $\text{merge}=\text{maxscore}$, $\text{novelty_threshold}=0.0$, $\text{stop_no_new_steps}=1$, $\tau=0.3$ 。

3.3 证据整合与计算

该模块从证据中抽取数值、年份、单位与实体, 并执行显式计算 (YoY/差值/占比/倍数)。核心约束:

单位一致性校验;

- 年份对齐要求;

候选冲突时拒算并回退。

-
- ****Step6 最优门控****: $\text{min_conf}=0.2$, $\text{allow_task_types}=[]$ (当前版本以稳定性为先)。
-

3.4 答案生成

- 采用模板化生成: 若计算器返回 $\text{status}=\text{ok}$ 且通过门控, 则输出结构化结果与解释; 否则回退基线答案, 并记录 fallback 原因以支持审计。

●

● ---

●

4 实验设置

●

数据集与划分

- 使用 FinDER 数据集, 包含 5,703 个查询—证据—答案三元组。数据按 train/dev/test 划分, 所有样本统一格式:

●

- $\{ \text{"qid": "...", "query": "...", "answer": "...", "evidences": [{"text": "..."}], "meta": {} \}$

●

子集定义

- ****complex_dev****: 满足任一条件即进入子集: 多证据、查询含 ≥ 2 年份、含比较/变化关键词、或含数值+年份组合。

****numeric_dev****: 查询或答案含数字/百分号/同比/差值/倍数关键词。

●

评价指标与口径

- 检索指标: $\text{Recall}@k$ 、 $\text{MRR}@k$ 、 $\text{evidence_hit}@k$

QA 指标: EM/F1 (用于对照)

- 数值指标: Numeric-EM、RelErr、Coverage

不确定匹配比例: 当证据缺少 `doc_id/evidence_id` 时使用文本匹配, 并记录比例。

-

- 关键参数

- 检索器: BM25 + Dense + Hybrid ($\alpha=0.5$)

多步检索 (best): `max_steps=2`, `top_k_each_step=10`, `merge=maxscore`

- 计算器门控 (best): `min_conf=0.2`, `allow_task_types=[]`

所有实验配置与结果均保存在 `outputs/<run_id>/`, 可复现。

5 实验结果与分析

本节直接引用 Step6 输出的表格与指标 (见 ``docs/TABLE_MAIN.md``、``docs/TABLE_NUMERIC.md``), 并对主要对照结果进行分析。

1) 检索效果 (full dev / complex dev)

****主结果表见**:** ``docs/TABLE_MAIN.md``

关键对照 (complex dev):

baseline(post-ft) vs best multistep:

- - Recall@10: 0.3909465 \rightarrow 0.3909465 (持平)
- - MRR@10: 0.2960138 \rightarrow 0.2960873 (+0.00007)
-
- 检索器微调带来的整体提升 (full dev):
- pre-ft baseline \rightarrow post-ft baseline: Recall@10 0.3246 \rightarrow 0.3772 (+0.0526)

2) 数值题表现 (numeric dev)

****数值表见**:** ``docs/TABLE_NUMERIC.md``

关键对照 (numeric dev):

baseline(post-ft) vs best calc gate:

- - Numeric-EM: 0.3838 \rightarrow 0.3838 (持平)
- - RelErr(mean): 683.3536 \rightarrow 683.3536 (持平)
- - Coverage: 0.6266 \rightarrow 0.6266 (持平)
-
- 说明: 当前版本计算器门控在 dev 上选择 `allow_task_types=[]`, 以避免数值误差回退。因此 numeric 指标未下降, 但尚未体现提升。该结果为“安全启用”基线, 可在后续提升抽取/计算置信度后再重新开启任务类型。

-

- 3) 消融与案例

-

- 消融结果见 `docs/TABLE_ABLATION.md`

典型复杂查询案例见附录 B (3 个案例, 包含多步检索每步 top-3 证据与 stop 原因)

●

● ---

●

● 6 错误分析与案例

●

● 1. 失败类型概览 (Step6)

- ****complex dev****: 主要集中在 `no_gap` 与 `max_steps`, 说明部分查询在第一步已覆盖核心证据, 但 refine 能力仍有限;

****numeric dev****: 由于计算器门控关闭 (allow_task_types=[]), 多数样本回退到 baseline, 表现为 fallback 占比高。

●

● 2. 失败原因分析

- 1) ****简称歧义与实体对齐不足****: 金融缩写可能指向多家公司, 导致检索命中无关证据。
- 2) ****检索漂移****: refined query 若过于相似或偏离目标, 会重复检索或引入噪声。
- 3) ****证据冲突与口径不一****: 不同段落可能存在统计口径差异 (如合并口径与单体口径), 需要更强的单位/实体对齐策略。
- 4) ****计算器保守门控****: 为避免算错, 门控阈值偏保守, 导致覆盖率受限。

●

● 3. 典型案例

- 典型复杂查询案例已整理在附录 B (`docs/CASE_STUDIES.md`), 包含 3 个查询的多步检索轨迹与证据对比。

●

● ---

●

● 7 讨论

●

● 1) 多步检索的收益与限制

- 多步检索在 complex dev 上避免了退化, 但整体提升有限, 主要原因在于 gap 识别与 query 重写仍偏规则化, 无法充分挖掘隐式实体关系与跨段落依赖。

●

● 2) 计算器的可控性与覆盖率

- 显式计算显著降低了算术错误的风险, 但门控策略为了安全性关闭了多数计算任务, 导致数值指标未提升。后续需通过更强的单位对齐与置信度校准逐步放宽门控。

●

● 3) 未来工作

- 引入更强的检索器与领域适配预训练; 提升实体消歧与 query rewriting 的准确性;
- 扩展计算器任务类型与多尺度单位转换; 结合轻量 agent 机制增强多步检索的决策质量。

●

● ---

●

● 8 结论

-
- 本文面向 FinDER 金融问答任务构建了可复现的金融 RAG 系统，在无外部 LLM API 的约束下引入多步检索与显式计算模块。实验表明：
-
- 检索器微调显著提升整体检索表现（full dev Recall@10: 0.3246 → 0.3772）；多步检索在复杂子集上保持不退化，MRR 略有提升；
- 计算器门控避免数值指标回退，为后续优化奠定稳定基线。

未来工作将集中在提升 gap 识别与 query 重写能力、增强数值抽取与单位对齐鲁棒性，并探索更强的检索与推理模型。

附录 A 结果表格

表 A1 主结果（full dev 与 complex dev）

label	run_id	full_r10	full_mrr10	complex_r10	complex_mrr10
pre_ft_baseline	20260130_234540_ae7cdf_m01	0.3246	0.2030	0.3457	0.2330
post_ft_baseline	20260130_234540_ae7cdf_m02	0.3772	0.2601	0.3909	0.2960
post_ft_multistep_best	20260130_234540_ae7cdf_m03	0.3772	0.2601	0.3909	0.2961
post_ft_baseline_calc_best	20260130_234540_ae7cdf_m04	0.3772	0.2601	0.3909	0.2960
post_ft_multistep_calc_best	20260130_234540_ae7cdf_m05	0.3772	0.2601	0.3909	0.2961
post_ft_multistep_T1_calc_best	20260130_234540_ae7cdf_m06	0.3772	0.2601	0.3909	0.2960

表 A2 数值题结果（numeric dev）

label	run_id	num_em	num_rel	num_cov
pre_ft_baseline	20260130_234540_ae7cdf_m01	0.3791	2874.5248	0.6202
post_ft_baseline	20260130_234540_ae7cdf_m01	0.3838	683.3536	0.6266

	0_ae7cdf_m02			
post_ft_multistep	20260130_23454	-	-	-
_best	0_ae7cdf_m03			
post_ft_baseline	20260130_23454	0.3838	683.3536	0.6266
calc_best	0_ae7cdf_m04			
post_ft_multistep	20260130_23454	0.3838	683.3536	0.6266
_calc_best	0_ae7cdf_m05			
post_ft_multistep	20260130_23454	0.3838	683.3536	0.6266
_T1_calc_best	0_ae7cdf_m06			

表 A3 消融结果

label	run_id	full_r10	full_mrr10	complex_r10	complex_mrr10
post_ft_multis	20260130_23	0.3772	0.2601	0.3909	0.2960
tep_T1_calc	4540_ae7cdf				
best	m06				

附录 B 典型复杂查询案例

5.4 典型复杂查询案例（3 个）

案例 1（qid=8c8c8c34）

Query: Hasbro (HAS) 2023 one-time charges impact on operating profitability vs historical trends and cap allocation implications.

- Gold Answer（摘要）: In 2023, Hasbro’s operating result turned from a profit in prior years (407.7 million in 2022 and 763.3 million in 2021) to an operating loss of 1,538.8 million...

Step0 Top3: 008beea7_e0_c0, 8c8c8c34_e0_c2, f8aec91a_e0_c1

- Step1 Top3: 008beea7_e0_c0, f8aec91a_e0_c1, 8c8c8c34_e0_c2

gap/stop: MISSING_ENTITY / MAX_STEPS, final_topk_size=10

- 分析: 该问题包含对比关系与年份信息，多步检索识别到 gap，但 refined query 与原查询高度相似，导致新增证据有限。

案例 2（qid=52e25ec7）

Query: Impact on net investing cash flows from EUC sale cash inflow offsets vs acquisition outflows, AVGO.

- Gold Answer（摘要）: The \$3,485 million inflow from the sale of the EUC business helped to partially offset the significantly higher cash expenditures related to acquisitions...

Step0 Top3: 506e7d1e_e0_c0, 52e25ec7_e0_c0, e4661352_e0_c3

- Step1 Top3: 506e7d1e_e0_c0, 52e25ec7_e0_c0, 1c47856d_e0_c1

gap/stop: MISSING_ENTITY / MAX_STEPS, final_topk_size=10

- 分析: 问题涉及“出售现金流入 vs 并购现金流出”的对比，多步检索能够维持证据覆盖但未显著扩展证据范围。

****案例 3 (qid=ed746c33) ****

Query: Cash flow & cap alloc implications of IRM's ASC 842 storage rev rec vs other lines.

- Gold Answer (摘要): For its Global Data Center Business, Iron Mountain recognizes storage revenues under ASC 842...

Step0 Top3: ed746c33_e0_c0, 2a8785e8_e0_c15, a68b8600_e0_c5

- gap/stop: NO_GAP/NO_GAP, final_topk_size=10

分析: 该类问题实体明确、语义集中, 单步检索即可覆盖核心证据, 多步检索不引入额外噪声。

-

- 参考文献

- [1] 参考文献占位。

-