

引用格式: 李子骏, 肖辉, 李雪峰. 面向知识密集型任务的检索增强生成技术综述[J]. 微电子学与计算机, 2025, 42(10): 48-65.
LI Z J, XIAO H, LI X F. Survey on retrieval-augmented generation techniques for knowledge-intensive tasks[J]. Microelectronics & Computer, 2025, 42(10): 48-65.

DOI: 10.19304/J.ISSN1000-7180.2025.0652

面向知识密集型任务的检索增强生成技术综述

李子骏, 肖辉, 李雪峰

(同济大学 电子与信息工程学院, 上海 201804)

摘要: 检索增强生成(Retrieval-Augmented Generation, RAG)作为一种融合信息检索与文本生成的范式, 通过引入外部知识源, 显著提升了模型的知识覆盖率、事实准确性与时效性。系统梳理了 RAG 技术的演进与研究现状, 从基本原理、系统架构出发, 深入分析检索器与生成器的协同建模机制及典型变体, 包括 FiD、REALM、REPLUG、GraphRAG 等。总结了 RAG 在开放域问答、领域知识问答、智能客服、企业知识管理等应用场景的实践效果, 并分析了多模态融合、外部工具调用和小样本学习等前沿方向。在此基础上, 指出了当前 RAG 研究所面临的评估体系不统一、训练开销高、可控性不足等挑战, 并对未来发展趋势进行了展望。

关键词: 检索增强生成; 预训练语言模型; 信息检索; 文本生成; 知识密集型任务

中图分类号: T18

文献标识码: A

文章编号: 1000-7180(2025)10-0048-18

Survey on retrieval-augmented generation techniques for knowledge-intensive tasks

LI Zijun, XIAO Hui, LI Xuefeng

(College of Electronic and Information Engineering, Tongji University, Shanghai 201804, China)

Abstract: Retrieval-Augmented Generation (RAG), as a paradigm that integrates information retrieval and text generation, significantly enhances the knowledge coverage, factual accuracy, and timeliness of models by incorporating external knowledge sources. This paper systematically reviews the technical evolution and research status of RAG, starting from its basic principles and system architecture. It delves into the co-modeling mechanisms of the retriever and generator and their typical variants, including FiD, REALM, REPLUG, and GraphRAG. Furthermore, it summarizes the practical effects of RAG in application scenarios such as open-domain question answering, domain knowledge question answering, intelligent customer service, and enterprise knowledge management, and explores cutting-edge directions such as multimodal fusion, external tool invocation, and few-shot learning. Based on this, the paper points out the challenges currently faced by RAG research, such as the lack of a unified evaluation system, high training costs, and insufficient controllability, and looks forward to future development trends. This paper aims to provide a systematic theoretical framework and practical reference for subsequent research.

Key words: retrieval-augmented generation; pre-trained language models; information retrieval; text generation; knowledge-intensive tasks

1 引言

近年来, 预训练语言模型(Pretrained Language

Models, PLMs)已成为自然语言处理(Natural Language Processing, NLP)研究的基础范式。自 BERT 模型提出以来, PLMs 在命名实体识别、问答系统和

收稿日期: 2025-08-26; 修回日期: 2025-09-05

基金项目: 国家自然科学基金(62175187)

<https://mc.spacejournal.cn>

文本分类等多个任务中取得了显著进展^[1]。以 GPT 系列、PaLM、ChatGLM、通义千问和 DeepSeek 为代表的生成式模型, 进一步推动了自然语言生成、对话建模等方向的发展, 标志着通用语言建模能力的跃升^[2-7]。

尽管大规模语言模型具备较强的泛化能力, 但知识获取依赖于预训练阶段所学习的静态语料, 在处理需要事实核查、时效性强或领域特定的任务时, 易出现知识缺失、信息幻觉等问题^[8]。该类问题在开放领域问答(Open-domain Question Answering, ODQA)、多文档推理和事实生成等任务中的短板尤为突出, 限制了模型在真实应用场景中的可信度与可控性。为提升生成模型对外部知识的调用能力, Lewis 等^[9]提出了 RAG(Retrieval-Augmented Generation)框架。通过在生成前引入信息检索机制, 使模型能够从外部文档库中动态获取与输入相关的文本, 作为辅助条件进而驱动模型生成更加准确和可验证的自然语言输出。与封闭式语言模型相比, RAG 具备更强的知识覆盖范围与时效适应性, 在多个知识密集型任务中表现出较强优势^[10-11]。近几年, RAG 研究方向持续拓展, 其技术体系覆盖了检索器与生成器的协同建模、结构优化、融合策略和多轮交互机制等多个维度。同时, 结合图结构建模、工具调用与多模态输入的研究工作也日益增多, 推动了 RAG 系统从单一文档增强向知识融合与智能推理方向发展。目前, RAG 已被广泛应用于开放问答、领域检索、智能客服和企业知识管理等场景, 展现出重要的市场价值。尽管 RAG 方法在特定任务中的应用取得了实效性进展, 目前尚缺乏系统性综述以梳理其理论基础、模型演化路径与研究趋势, 难以后续研究提供清晰框架与统一视角。

因此, 本文通过系统回顾 RAG 的技术演进、关键组成与代表性拓展, 从结构机制、应用场景与挑战展望等方面展开分析, 主要内容包括以下六点。

(1) 概述 RAG 的提出背景与方法范式, 明确其与传统问答模型的区别。

(2) 系统阐述 RAG 核心组成, 包括检索器、生成器及其协同机制。

(3) 归纳近年来提出的典型架构变体与优化策略, 如 FiD、REALM、REPLUG、GraphRAG 等。

(4) 总结 RAG 在多领域的实际应用, 包括问答系统、知识问答、企业助手等。

(5) 分析当前 RAG 系统在性能评估、训练代价

与可控性方面的关键挑战。

(6) 展望未来 RAG 研究在多模态融合、小样本学习与外部工具交互方面的发展方向。

本文旨在为相关研究提供统一视角与方法脉络, 进而推动 RAG 在理论探索与工程实践中的深入发展。

2 基本原理与系统架构

在 NLP 领域, 近年来大语言模型取得了显著进展, 尤其在文本生成、问答系统与语言理解等任务中展现出强大的泛化能力。然而, 现有模型面临“知识封闭性”(Knowledge Closedness)、“事实幻觉”(Hallucination)以及“可解释性不足”等核心挑战, 亟需一种机制以弥合语言模型参数内建知识与外部动态知识之间的鸿沟。RAG 范式正是在此背景下产生, 通过将神经语言模型与语义检索模块结合, 实现了“检索-生成”联动建模, 为构建具备知识调用能力的生成系统提供了新的思路。

RAG 架构在设计上秉持“外部知识调用 + 条件生成”策略, 使模型在生成答案前能够显式地从外部文档库中检索语义相关内容, 并以此作为生成条件进行语言建构, 从而有效提升生成结果的事实一致性、语义相关性与可溯源性。相比于传统闭卷模型(Closed-book Models)和检索式问答系统(Retrieval-based QA Systems), RAG 在保持语言自然度的同时实现了知识利用的动态性与模块化, 成为近年来知识密集型 NLP 研究的主流架构之一。本文将围绕 RAG 的核心建模理念、系统流程与关键组成模块展开, 进一步对其与其他问答范式之间的关系进行系统比较, 为后续基于 RAG 的模型改进与路径优化提供理论基础与架构认知。

为清晰地呈现 RAG 技术的发展脉络, 首先给出自 2020 年以来的关键进展时间轴, 如图 1 所示。

2.1 RAG 范式

RAG 是一种融合信息检索(Information Retrieval, IR)与文本生成(Text Generation)机制的神经语言建模框架, 其核心目标是赋予预训练语言模型以动态调用外部知识的能力。该方法在 2020 年被提出, 旨在解决传统语言模型对事实性、时效性知识建模能力不足的问题^[9]。与封闭式生成模型不同, RAG 系统采用“开放式”(Open-book)的生成范式。在该框架中, 模型在生成响应之前, 首先从一个外部知识源(通常为向量化语料库)中检索与输入查询语义相关的文档段落, 再将这些文档与原始查询联




图1 RAG 技术的关键进展时间轴

Fig. 1 Timeline of key advances in RAG technology

合编码，作为上下文条件馈入生成器，进而完成输出生成。这一过程使得模型可以在响应生成时访问与任务相关的即时信息，而不依赖模型参数中静态存储的知识。该范式具有显著优势，具体如下。

(1) RAG 框架通过显式调用文档，显著增强了生成结果的知识依据性与事实一致性，缓解了大语言模型中常见的幻觉问题^[8]。

(2) 系统的输出可追溯至原始文档，提高了可解释性，为用户提供了答案背后的来源支持。

(3) 模型对知识的存储与调用解耦，提高了整体系统的可扩展性与可更新性，支持快速集成不同领域知识库或增量更新文档集合。

上述特性使 RAG 在开放领域问答、知识注入对话、事实验证、文档搜索生成等任务中表现出良好的适用性^[11-12]。

从建模角度，RAG 并非将信息检索作为独立前处理步骤，而是将其作为可训练的子模块与生成器共同建模，形成一个联合概率优化目标。其训练与推理过程支持两种主流模式：一种是管线式结构，先训练检索器再调用生成器；另一种为端到端联合优化，将检索与生成解耦建模转化为可微优化过程，使得检索器可在生成器的损失引导下迭代更新^[9-10]。随着大语言模型能力的增强，RAG 也支持将生成器替换为黑盒模型（如 GPT-4），进一步形成“可训练检索器+不可训练生成器”的解耦范式，如 REPLUG 所提出的方式^[13]。目前，RAG 已发展为知识增强语言建模（Knowledge-intensive NLP）的主流

<https://mc.spacejournal.cn>

技术之一，并成为多模态问答、智能体系统（Agent）、领域对话系统等多类任务的基础框架之一。它不仅为解决知识“封闭性”提供了系统路径，也推动了生成模型向高可信、可验证、低幻觉方向演化。

2.2 系统流程

RAG 系统通常由两个核心模块组成：文档检索器（Retriever）与文本生成器（Generator），两者协同运行构成完整的检索增强生成流程。前者负责从大规模语料库中筛选与输入查询最相关的文档段落，后者则基于原始查询与所检索内容生成自然语言输出。这种结构明确分工的架构设计，兼顾信息覆盖性与语言生成能力，为解决大语言模型的知识时效性与幻觉问题提供了可行路径^[9]。RAG 的基本流程可划分为 4 个阶段，分别为编码、检索、融合与生成，系统处理过程主要流程包括以下 4 个阶段^[9, 11]。

(1) 编码阶段（Query Encoding）：用户输入的自然语言查询 x 首先通过预训练语言模型（如 BERT、RoBERTa）编码为低维稠密向量表示，作为语义检索的查询项输入。该编码阶段的关键在于捕捉查询的语义特征，以便在后续检索中实现高质量匹配。

(2) 检索阶段（Retrieval）：基于编码后的查询向量，系统在预构建的向量化文档索引中执行近似最近邻（Approximate Nearest Neighbor, ANN）搜索，返回 top- k 个与查询语义最相近的段落或片段。该检索过程可基于向量点积、余弦相似度等指标进行匹配，具体实现通常采用 FAISS、ScaNN 等高效索引

机制, 以确保在大规模语料库下的低延迟响应^[14]。

(3)融合阶段(Context Fusion): 将检索得到的文档内容与原始查询进行融合编码, 形成上下文条件输入供生成器使用。常见策略包括: 早期拼接、独立编码后融合、以及基于注意力机制的权重聚合。如 Fusion-in-Decoder(FiD)采用了对每个文档独立编码, 仅在 Decoder 阶段聚合的设计, 证明在多文档融合场景下能显著提升生成质量^[11]。

(4)生成阶段(Conditional Generation): 基于融合后的上下文表示, 文本生成器输出最终的自然语言回答 y 。生成模块通常采用 Encoder-Decoder 架构(如 BART、T5)或 Decoder-only 结构(如 GPT)实现, 具体选择取决于系统对可训练性、结构透明性和上下文长度的需求。

此流程体现了 RAG “文档增强” 建模范式的核心思想: 通过将语义检索纳入生成决策路径, 使语言模型具备了动态访问外部知识的能力, 进而提升了生成内容的事实一致性与知识可靠性^[10]。与传统封闭式生成模型相比, RAG 在处理需要事实支撑或领域知识支撑的任务时, 具备更强的适应能力与可解释性。此外, 该流程天然支持文档库的扩展与更新, 适用于快速变化的知识环境(如新闻、金融、法律等场景), 在系统部署层面具有良好的工程可扩展性。值得注意的是, 随着 RAG 在工业与研究中的广泛应用, 不同系统在具体流程实现上有所差异。例如, WebGPT 在检索阶段加入了 BM25 作为初筛机制以提高召回效率, REPLUG 则在生成器不可训练的场景下进一步优化检索器, 以更好适配输出语言模型的响应偏好^[13, 15]。这些演化体现了 RAG 范式在不同场景下的可定制性与灵活性。

2.3 问答系统

在自然语言处理的问答系统研究中, RAG 被广泛认为是连接闭卷问答(Closed-book QA)与检索式问答(Retrieval-based QA)两种范式的桥梁型架构。

其基本理念是在回答生成前主动从外部文档库中检索相关信息, 以此补充语言模型本身的知识表示能力, 从而生成更为准确且语义连贯的自然语言答案^[9, 13]。该范式通过融合外部知识调用能力与上下文感知语言建模能力, 试图克服传统问答模型在事实性、生成性与可扩展性方面的固有限制。

闭卷问答系统依赖于大规模语言模型(如 GPT-3、T5), 其全部知识均内嵌于参数之中, 回答生成过程完全不依赖外部资源^[16-17]。尽管此类模型在少样本泛化与语言生成方面展现出较强能力, 但由于其知识是静态冻结的, 难以适应知识快速演化的应用场景, 且在事实密集型任务中易出现“幻觉”(Hallucination)现象, 即输出与现实事实相悖的信息^[8, 18]。检索式问答系统则主要借助传统信息检索技术, 如 BM25、DPR 等, 基于关键词或向量匹配机制在文档库中检索相关片段, 并直接返回文本作为答案^[12, 19]。该方法因其高度可解释性与事实准确性在工业系统中长期占据主导地位。然而, 其回答往往为原文摘录, 缺乏语言生成的灵活性与上下文整合能力, 尤其在多文档融合、跨句推理等任务中表现受限^[12, 20]。

RAG 架构在上述两种极端之间建立起融合机制: 在保持事实性与可解释性的同时, 引入生成能力提升语言自然度。其生成器以检索结果为条件输入, 从多个候选段落中整合信息并生成语义合理、语言自然的回答^[11, 21]。该机制不仅提升了模型的回答质量, 也显著增强了系统对外部知识库的依赖能力, 使模型具备了“按需访知”的动态推理能力^[22]。在多项开放领域问答任务(如 Natural Questions、TriviaQA)中, RAG 模型在准确率、BLEU 等指标上显著优于封闭式模型和纯检索系统, 验证了其在事实一致性与生成质量之间的优越平衡能力^[9, 23]。表 1 对 3 种问答范式的核心特性进行了系统对比。

表 1 闭卷、检索式和 RAG 问答范式的对比

Tab. 1 Comparison of closed-book, retrieval-based and RAG question-answering paradigms

模型类型	是否调用外部知识	回答方式	优势	局限性
闭卷问答	否	直接从参数生成	生成自然、部署简便	幻觉率高、知识不可更新
检索式问答	是	文本片段直接返回	高可解释性、事实准确性强	回答缺乏语言柔性、难以跨句整合信息
RAG	是	基于检索内容进行生成	兼顾语言自然性与事实一致性	系统复杂性增加, 性能依赖检索质量

在实际应用层面, RAG 架构亦逐渐成为各类高

可靠性语言生成系统的核心基础模块, 广泛应用于

企业问答系统(金融、法律、医疗领等)、人机对话系统、复杂推理型任务中^[13,24]。随着检索模块与生成模块逐步解耦并优化, RAG 范式展现出良好的工程可扩展性, 适应了多源异构知识调用、知识图谱整合、多轮交互等复杂场景的需求, 成为知识增强型自然语言处理的重要方向。

3 RAG 关键组件与技术

RAG 系统通常由两个核心模块构成: 文档检索器与文本生成器。两者协同工作, 以实现从大规模知识库中动态调用信息并生成自然语言回答的目标^[9,11]。其基本处理流程包括以下步骤。

步骤 1 输入查询 x 首先经过编码器映射为稠密向量表示, 如式(1)所示。

$$\mathbf{q} = \text{Encoder}(x) \quad (1)$$

步骤 2 检索器基于该向量 $\mathbf{q}$ 在预构建的文档索引中选出 $\text{top-}k$ 个语义相关的文档, 如式(2)所示。

$$\{d_1, d_2, \dots, d_k\} = \text{top-}k(\text{Sim}(\mathbf{q}, d_i)) \quad (2)$$

步骤 3 检索到的文档与原始查询联合构成条件输入, 输入至文本生成器。

步骤 4 生成器通常采用序列到序列架构(如 BART、T5)进行条件生成, 输出最终回答文本 y 。

因此, 该机制可形式化地表示为一个条件概率建模问题, 如式(3)所示。

$$P(y|x) = \sum_{d \in D} P(y|x, d) \cdot P(d|x) \quad (3)$$

式中: $P(y|x)$ 表示在给定查询 x 的条件下, 生成输出 y 的总体概率; $P(d|x)$ 表示查询 x 检索到文档 d 的概率分布, 通常由向量检索模型估计; $P(y|x, d)$ 表示在查询与特定文档 d 的条件下生成回答的概率, 依赖于解码器建模能力。

由于对整个文档集合 D 求和在计算上不可行, 实际训练与推理中一般采用 $\text{top-}k$ 截断近似, 即

$$P(y|x) \approx \sum_{i=1}^k P(y|x, d_i) \cdot P(d_i|x) \quad (4)$$

该联合建模方式体现了 RAG 在知识选择与语言生成之间建立的概率耦合机制, 显著区别于传统封闭语言模型在生成时的“参数记忆”范式, 也区别于检索式系统的“文档摘录”逻辑^[10,13]。

3.1 检索器

在 RAG 架构中, 文档检索器的核心任务是建模条件概率分布 $P(d|x)$, 即在给定用户查询 x 的条件下, 选出最相关的文档 d 。该模块通过在大规模知识库中筛选出语义相关的段落, 为后续生成器提供

事实依据, 是整个 RAG 流程的关键入口。目前主流的检索方法可划分为稠密检索、稀疏检索和混合检索。

稠密检索(Dense Retrieval, DR)采用神经网络将查询与文档编码为低维稠密向量, 并通过向量间相似度(如内积或余弦)进行匹配。代表性方法如 DPR(Dense Passage Retriever, DPR)使用两个 BERT 编码器分别处理查询与文档, 通过对比学习优化匹配效果^[12]。该方法在多个开放领域问答任务(如 Natural Questions、TriviaQA)中显著优于传统方法, 成为 RAG 框架中广泛采用的检索器。后续如 ColBERT 提出 token 级交互的 late interaction 机制, 在保留语义信息的同时提高了检索粒度; ANCE 则通过异步更新负样本缓解了训练过程中的不稳定性^[22,25]。稀疏检索(Sparse Retrieval)则基于词项频率构建倒排索引, 例如 TF-IDF 与 BM25。其通过对词语出现频率与文档长度进行加权打分, 匹配时高度依赖关键词重合, 虽然不具备深层语义理解能力, 但实现简单、可解释性强, 适用于大规模快速检索或资源受限场景。在实际应用中, 如 WebGLM 就采用此方法进行候选段落初筛, 从而降低生成器处理负担^[26]。混合检索(Hybrid Retrieval)尝试结合稠密与稀疏方法的优势, 通常采用线性加权或级联的方式对两个检索结果进行融合。例如 ColBERTv2 引入 BM25 筛选 top 文档, 再用稠密模型进行精 rerank, 有效提高了召回质量与系统效率的平衡^[27]。该策略在工业部署中极具实用价值, 特别适用于长尾查询或召回瓶颈场景。

在检索器设计之外, 文档库的构建与维护策略同样关键。文档通常以段落级或句子级粒度进行切分, 以控制生成模块的输入长度与上下文承载能力^[9]。检索向量可由 BERT、RoBERTa、E5 等预训练模型生成, 并通过近似最近邻(Approximate Nearest Neighbors, ANN)算法(如 FAISS, ScaNN)建立高效索引结构^[14]。对于新闻、法律问答等知识快速更新的领域, KILT toolkit 可提供统一的任务接口与评测数据支持, 可与具备增量索引功能的检索框架结合使用^[23]。综上, 检索器在 RAG 中承担了“知识选择器”的角色, 其设计直接影响到生成器的响应质量与事实一致性, 是当前 RAG 研究中持续优化的重点方向。

3.2 生成器

在 RAG 系统中, 生成模块承担最终文本输出的任务, 其质量直接决定了系统的实用性与鲁棒性。

近年来, 生成器的选择经历了从中等规模、结构明确、可调优的开源模型(如 Flan-T5、UL2)向大型闭源语言模型(如 GPT-4、Claude、Gemini)的快速演进。

(1) 模型架构演进

在 RAG 系统的发展初期, 生成器主要依赖于可训练的 Encoder-Decoder 结构模型, 典型代表如 T5 及其强化版本 Flan-T5^[28]。Flan-T5 通过大规模多语言、多任务指令微调(Instruction Tuning), 在保持 T5 架构通用性的同时, 显著提升了模型在零样本与少样本任务中的泛化性能^[29]。与此同时, UL2 则以统一语言学习(Unifying Language Learning)为目标, 将 causal LM、masked LM 与 span corruption 等训练目标融合为“Mixture-of-Denoisers”训练范式, 从而兼具生成、填空与问答能力^[30]。由于这类模型开源、结构透明且易于微调, 它们在学术界被广泛采用, 成为 RAG 任务中可控性强、解释性良好的生成器选项。

然而, 随着大语言模型推理能力的迅猛发展, 实际应用系统逐步转向使用大型闭源 Decoder-only 模型作为生成组件, 例如 GPT-4^[31]、Claude-3^[32]、Gemini 1.5 Pro^[33] 等。这类模型不仅具备强大的语言理解与推理能力, 还能处理极长的上下文输入(支持数十万至百万 tokens), 为 RAG 系统在多文档融合、长链推理、复杂决策生成等任务中提供了前所未有的技术支撑。尽管这些闭源模型通常不可训练、参数不可微调, 但其性能优势推动了“Retriever + Promptable LLM”范式的兴起, 即通过灵活构造 prompt 接口调用 LLM 输出答案, 从而解耦生成器的训练与使用过程。

在此背景下, REPLUG 框架提出冻结大模型参数, 仅对 retriever 进行训练以适配任意黑盒 LLM 的策略, 显著降低了系统调优成本与部署复杂度^[13]。该框架现已集成至 LangChain、LlamaIndex 等 RAG 开发生态中, 成为工业级检索增强生成系统的常见范式。同时, 一些最新研究进一步探索如何通过检索控制生成行为, 例如, Li 等^[34] 的 Refiner 模块提出在检索后将返回内容重新结构化, 将与查询相关的信息按段落连接并提取, 以高效支持下游生成器推理, 实验证明可提升多跳 QA 的准确性和生成一致性。此外, Chan 等^[35] 提出的 RQ-RAG 模型通过明确 query 重写、拆解与澄清步骤, 实现对查询的多阶段 refinement, 进而改善复杂查询的检索准确度与答题质量。

综上所述, 当前 RAG 生成器的演化趋势呈现出明确的双轨格局: 学术研究更偏好使用开源、可控的 Encoder-Decoder 模型以支持微调与分析; 工业界则倾向采用高性能、零微调的闭源大模型 API 以满足部署效率和推理质量的要求。二者在架构、控制机制与使用策略上的分化也推动了 RAG 在多个领域的多样化发展。

(2) 解码与生成控制策略

尽管生成式语言模型的能力进展显著, 但在 RAG 系统中, 生成模块的输出质量仍高度依赖于解码策略与生成控制机制的有效性。当前主流的解码方法包括贪婪解码(Greedy Decoding)、束搜索(Beam Search)以及基于概率采样的策略, 如 Top-k 和 Top-p 采样(Nucleus Sampling)。在具体应用中, 贪婪解码与束搜索虽然计算效率较高且输出稳定, 但容易导致输出冗余和缺乏多样性; 相比之下, Top-p 采样方法通过限制候选词汇的累积概率范围, 能够有效减少幻觉(Hallucination)与词语退化(Degeneration)现象, 提升生成的自然度与创造性, 尤其在多轮对话与复杂语言生成任务中效果显著^[36]。

与此同时, RAG 系统的生成输出越来越依赖于对模型行为的外部控制。Prompt Engineering 作为一种轻量但强大的控制策略, 通过精心设计输入提示, 能够显著增强语言模型的结构遵循能力与任务适应性。当前已有大量系统化研究探索如何通过自动化模板构建、任务提示归纳(Prompt Induction)和软提示调优(Soft Prompt Tuning)来优化 prompt 的表达能力^[26]。此外, 随着生成器参数规模的指数级增长, 直接对大模型进行全参数微调在计算和数据上成本极高, 这促使研究者转向参数高效微调(Parameter-Efficient Fine-Tuning, PEFT)策略。代表方法如 Prefix Tuning 和 LoRA 通过引入少量可调参数模块, 在冻结预训练模型参数的前提下实现高效迁移学习, 广泛应用于 Flan-T5、LLaMA、Qwen 等开源语言模型中^[37-38]。

控制输出内容的结构与语义以外, 近年也出现了对生成质量进行后验校验与纠错的机制, 如自我校验(Self-consistency Decoding)、对比式引导(Contrastive Generation), 以及通过引入辅助判别器的方式过滤幻觉输出^[39]。例如, RRHF(Rank Responses to Align LMs with Human Feedback)等方法在场景中用于通过多候选答案排序选择最可靠输出, 有效提升了事实一致性^[40]。这些生成后处理机制在医疗问答、法律推理等对可信度要求极高的场景中展现出

潜力。

目前生成控制技术正朝着多目标约束与强化学习优化方向演进。例如, RAG-Reward 首次将细粒度 reward-model 与 RLHF 应用于 RAG 流程, 有效提升生成质量与可靠性^[41]。Plan*RAG 则提出在检索生成过程中引入结构化推理计划, 通过有向无环图规划多跳推理路径, 使生成行为更具透明度与可控性^[42]。综合来看, 未来 RAG 生成模块研究不仅聚焦生成质量, 也将同步增强可控性、可解释性和可信度, 对构建高稳定性、高可验证性的检索增强系统具有重要意义^[43]。

3.3 检索与生成的协同机制

在 RAG 系统中, 文档检索模块与文本生成模块之间的协同效率, 直接决定了模型在准确性、语义一致性、可训练性以及多跳推理能力等方面的综合表现。由于 RAG 架构将外部知识与神经生成有机融合, 其性能不仅取决于各模块的独立表现, 更依赖于两者在训练与推理阶段的信息流动方式与优化策略的合理设计。近年来, 伴随大规模预训练模型与高性能索引系统的快速发展, 研究者针对检索器和生成器之间的交互提出了多种协同范式与优化机制, 主要可归纳为 3 大类: 管线式(Pipeline-based)协同、端到端联合训练(End-to-End Joint Training)、以及多轮交互式推理机制(Iterative Retrieval-Generation)。此外, 一系列结构优化与微调方法也被广泛引入, 以进一步缓解模块间语义错配、误差传递(Error Propagation)与训练成本过高等问题。

RAG 系统的演进正逐渐从早期的“模块级串联”向“信息级联动”转变, 即不仅在结构上将检索与生成拼接使用, 更在训练目标、语义表示与推理路径上实现深度融合。这一转变促使研究者从优化独立模块性能, 转向关注两个模块之间的信息对齐与行为耦合, 从而推动 RAG 技术朝着更高的鲁棒性、更强的推理能力以及更好的可控性方向发展。

(1) 协同训练方式

在 RAG 系统的构建过程中, 检索器与生成器的协同训练方式是影响模型最终性能与部署可行性的关键因素。早期多数方法采用管线式训练策略, 即将检索器与生成器作为两个相对独立的模块进行分阶段优化: 首先利用标准检索任务(如对比学习、近邻预测)对检索器进行训练, 随后将其所返回的 top- k 文档作为生成器的固定输入进行文本生成训练。这种做法的优势在于实现简单、可调试性强, 且便于使用已有的高效检索模型(如 DPR、ColBERT)进

<https://mc.spacejournal.cn>

行模块复用。然而, 其缺乏全局目标的一致性, 即两模块的优化方向并未对齐, 导致所谓的检索误差传播问题: 当检索器检索结果质量较低或与生成目标语义偏离时, 生成器往往无法纠正信息缺失, 从而造成输出准确性下降。

为缓解上述问题, 研究者提出了端到端联合训练(End-to-end Joint Training)策略, 将检索器与生成器纳入统一的可微分计算图中, 并通过生成损失对检索器反向传播梯度, 从而实现两模块在目标函数上的一致优化。原始 RAG 框架中引入了 Soft attention 机制, 使得检索的多个文档段落以加权方式参与生成过程, 从而允许对检索器参数进行联合优化^[9]。然而, 受限于文档检索的离散性特征, 该过程需借助近似推断(如负采样)来构造伪标签, 使训练稳定性和效率受到挑战。此外, 该方法在大规模语料场景下对计算资源和显存的要求极高, 难以直接迁移至工业级部署中。

为此, 后续研究进一步提出了多种改进机制以提升联合训练的稳定性与可扩展性。例如, REALM 在预训练阶段即引入可学习检索器, 并通过 BERT 语言建模目标引导其学习有助于预测遮蔽词的文档段落, 从而将检索器训练任务内嵌于语言建模过程, 显著增强了检索器对语言分布的适应性^[10]。FiD 则通过将文档编码与生成解码过程解耦, 实现了高效的多文档信息融合, 同时避免了生成器对低质量文档的干扰, 从架构层面上缓解了检索误差传播问题^[11]。此外, 为进一步提升检索器与生成器的协同效果, 研究者探索了强化学习在 RAG 协同训练中的应用。例如, Chen 等^[44]提出的 MMOA-RAG 框架将 RAG 的多个模块视为强化学习智能体, 通过多智能体联合优化流程, 使各组件的目标一致并提高最终问答质量。另一项工作 RAG-RL 则采用课程强化学习优化生成行为, 展示了在复杂推理任务中提升生成准确性与鲁棒性的潜力^[45]。

综上, 尽管端到端联合训练在理论上具备更优的信息流一致性与性能上限, 但其在训练稳定性与计算资源方面的代价仍是制约其大规模应用的瓶颈。因此, 在实际应用中, 研究者往往在 Pipeline 与 End-to-End 之间进行折中, 或采用如 REPLUG 等轻量级调优机制, 在不修改生成器参数的前提下对检索器进行针对性适配, 代表了 RAG 系统向“低耦合、高适应性”协同范式演进的重要方向。

(2) 多轮交互式检索生成

尽管经典 RAG 框架通过单轮检索生成已在开

放领域问答等任务中取得显著性能, 但其在处理复杂查询、多跳推理与长链因果关系建模等任务中仍存在局限。主要原因在于, 传统 RAG 系统将所有必要信息集中于一次性检索的 top- k 文档中, 忽视了人类在面对复杂问题时常采用的逐步推理与迭代查找(Iterative Reasoning and Retrieval)策略。

为弥补这一缺陷, 近期研究提出了多轮交互式 RAG(Iterative RAG)架构, 试图模拟人类“查-思-查”的认知过程。在这一范式中, 系统并不依赖单轮查询获取全部信息, 而是通过在每轮生成中引入中间推理结果、问题拆解或假设链条, 构造更具上下文感知能力的后续检索查询, 从而逐步引导检索器补全信息链条, 实现更深层次的多跳推理与语义聚合。代表性方法如 IRCOT(Iterative Retrieval with Chain-of-Thought)将自然语言推理链(Chain-of-Thought, CoT)显式引入生成器输出, 每一轮中间推理结果作为下一轮检索器的输入构造, 鼓励系统沿着逻辑推理路径递进构建答案^[46]。这种方法实质上引入了一个“生成-推理-再检索”的循环过程, 能够有效处理包含多个实体、事件和时间关系的复杂问答问题。

在实验层面, IRCOT 在多跳问答数据集(如 HotpotQA、MuSiQue-Full)上显著优于单轮 RAG 系统, 特别是在需要聚合分布在多个文档中的零散证据(Evidence Aggregation)时表现更优。与之相似的还有 MultiHop-RAG 模型, 专门评估多跳问答场景下的检索生成效果, 采用查询细化和中间状态缓存机制提升密度检索效率^[47]。同时, Zhuang 等^[48]提出 EfficientRAG, 重点在检索器效率与内容聚合改进, 两者均为多轮交互式检索生成方式提供真实案例引用。

值得注意的是, 多轮交互式 RAG 虽然提升了推理能力与答案质量, 但也产生了新的挑战, 包括推理路径控制、错误积累传播(Error Cascade)、以及计算成本上升等问题。因此, 近期研究也正在探索使用强化学习(Reinforcement Learning, RL)、查询过滤机制、生成校验网络等手段进行鲁棒性增强与路径优化, 推动 RAG 系统在复杂认知任务中的稳定部署与大规模应用。

(3) 优化与微调方法

在标准 RAG 架构中, 检索器与生成器之间虽然通过中间文档作为接口实现协同, 但仍面临多种性能瓶颈: 例如检索质量对生成输出的脆弱依赖、跨文档信息融合不足、以及生成器参数更新受限等

问题。为进一步提升两个模块之间的信息交互效率与系统整体的鲁棒性, 研究者提出了结构优化与训练机制, 代表性方法包括 Fusion-in-Decoder (FiD)、REALM(Retrieval-Augmented Language Model)与 REPLUG, 它们分别从不同维度增强 RAG 架构的生成质量与可适配性。

FiD 旨在解决早期 RAG 系统中由于将多个检索文档统一拼接后输入编码器所导致的信息干扰与冗余问题^[11]。FiD 采用独立编码、解码器融合(Late Fusion)的策略: 即将每个检索文档单独通过共享参数的编码器进行编码, 并在解码阶段引入交叉注意力机制进行融合。这种设计显著减少了跨文档干扰、提升了文档粒度的表达能力, 尤其适用于处理多个来源证据的问答任务。FiD 在 NQ、TriviaQA 等数据集上均优于原始 RAG 系统, 现已成为多文档生成模型的重要基础结构之一。

REALM 则从训练阶段引入检索器优化, 提出在预训练层面联动检索器与语言模型的思路^[10]。其通过在语言建模任务中动态检索与当前上下文语义相关的文档, 并将其作为输入的一部分, 联合优化语言建模损失与检索目标, 从而使检索器能够学习到符合语言分布的检索行为。REALM 将知识检索机制嵌入语言模型预训练流程, 首次实现了检索器与 PLM 的深度耦合, 是后续预训练型 RAG 结构(如 KILT、KAT)设计的重要参考。

在生成器为闭源语言模型(如 GPT-3.5/4、Claude)等不可调参数的场景下, REPLUG 提出了一种轻量化适配机制, 通过“冻结生成器、训练检索器”的策略, 允许用户无需访问生成器权重, 只通过优化检索器以生成更契合生成器偏好的上下文, 从而提升 RAG 整体性能。REPLUG 还引入了一种响应反馈回路机制, 评估生成器对检索结果的“有用性”, 以构建迭代式的强化检索器训练流程。此方法代表了“低耦合、高兼容”方向的典型范式, 已被广泛集成至 LangChain、LlamaIndex 等主流 RAG 开发平台^[13]。

综上所述, 优化机制不仅显著提升了 RAG 系统在复杂任务中的表现, 还推动了 RAG 从单纯的检索-生成拼接结构向更深度融合、语义一致性更强、训练友好的方向发展。尤其是在多文档 QA、事实验证(Fact Verification)、多跳推理等知识密集型场景中, 这些改进方法提供了更加鲁棒与高效的基础架构。

4 RAG 的变体

随着大语言模型的语义理解与生成能力不断增强, RAG 逐渐成为提升语言模型事实一致性与知识覆盖能力的重要技术路径。尤其在开放域问答、事实验证、多轮对话生成等知识密集型任务中, RAG 显示出显著优势^[9-10]。

然而, 原始 RAG 架构中的“单轮检索 + 拼接生成”范式在应对复杂问题推理、多模态融合、结构化信息注入等方面仍存在诸多局限。为进一步增强系统鲁棒性与性能扩展能力, 近年来研究者围绕 RAG 的核心组件和训练策略进行了多样化的演进探索。典型改进方向包括: ①生成融合策略优化, 如 FiD 结构; ②检索器与生成器分离训练机制, 如 REALM、REPLUG 等系统; ③与外部工具集成的 Tool-Augmented LLMs, 赋予模型执行与调用能力; ④跨模态数据处理能力扩展, 使 RAG 可用于图文问答(Visual Question Answering, VQA)等任务; ⑤指令调优(Instruction Tuning)与 RAG 结合, 推动指令跟随能力向知识增强迁移。本节将重点梳理近年来具有代表性的架构创新, 包括生成融合策略优化、分离训练、工具集成、多模态扩展与指令调优等方向。

4.1 Fusion-in-Decoder

Fusion-in-Decoder(FiD)框架是对经典 RAG 架构中检索结果融合方式的一种重要结构性改进。传统 RAG 方法多采用“早期融合”(Early Fusion)策略, 即将检索到的多个文档与查询拼接后统一送入生成器编码阶段。然而在处理多文档输入时, 该策略往往面临信息稀释(Information Dilution)、上下文干扰(Context Interference)及长文本截断等问题, 严重影响生成质量^[11]。

FiD 通过引入“延迟融合”机制, 提出在编码阶段对每个检索文档独立编码, 仅在解码阶段融合所有文档表示。这一设计使得模型能够充分地利用每篇文档的语义信息, 避免文档间相互干扰, 从而增强了生成阶段的对齐性与上下文鲁棒性。具体而言, FiD 对输入文本 $\{d_1, d_2, \dots, d_k\}$ 与查询 q 分别进行独立编码, 获得一组上下文向量 $\{h_1, h_2, \dots, h_k\}$, 最终由解码器以注意力机制对这些向量进行加权聚合并生成回答。这种结构设计可视为对 Seq2Seq 架构在 RAG 框架下的一种有效泛化。

研究表明, FiD 在多个开放域问答数据集上均实现了优于传统早期融合方法的性能表现, 特别是 <https://mc.spacejournal.cn>

在 Natural Questions 与 TriviaQA 等复杂问答任务中, 其 Top- k 检索文档的综合利用能力显著增强^[49-50]。此外, FiD 也成为后续多文档 QA 系统(如 FiD-KD、FiD-Reranker)及长文摘要任务中融合策略优化的关键基础, 广泛应用于基准系统的构建与评估。

4.2 REALM、REPLUG、GTR 等

随着 RAG 系统在复杂任务中的广泛应用, 其基础架构也经历了从静态管线式到动态可适配框架的演进。一系列新兴架构通过重构检索器与生成器的训练方式, 提升了 RAG 系统在多语言、多任务与黑盒环境下的适应性及扩展性, 代表性方案包括 Retrieval-Augmented Language Model(REALM)、REPLUG 与 Generalist Transformer Retriever(GTR)。

REALM 首次在语言模型预训练阶段引入检索机制, 是最早实现“可检索语言建模”的代表方法^[10]。REALM 在 BERT 的基础上引入了文档索引库与可微检索模块, 训练过程包含两部分损失: 一方面优化语言建模目标, 另一方面优化查询与文档的对比学习目标。检索器的训练受到语言建模任务反向传播的指导, 从而实现语言建模与检索能力的深度融合。这种方法打破了封闭式语言模型在知识表示上的限制, 使得模型能够在推理阶段“按需访问”外部知识资源, 缓解了知识遗忘与幻觉问题, 尤其在自然问答与事实验证任务中表现出色。

相比之下, REPLUG 则专为闭源大语言模型(如 GPT-3/4)设计, 其关键思想在于“保持生成器冻结, 仅训练检索器”以适配其输出^[13]。在该框架中, 检索器被训练为提升黑盒大语言模型输出中正确答案的概率, 形成了轻量、灵活的适配机制。REPLUG 以强化检索质量为优化目标, 完全避免了对生成器参数的访问和修改限制, 显著降低了工业场景中接入 RAG 组件的复杂度。实验表明, 在不进行任何 LLM 微调的前提下, 仅通过 REPLUG 训练检索器即可显著提升 RAG 系统在问答、摘要等任务中的响应一致性与事实性。

GTR 系列强调在多任务、多语言、多检索模式下实现统一建模^[51]。GTR 采用大规模指令微调与任务标签引导的架构设计, 使其具备稀疏检索、稠密检索与联合检索这 3 类检索方式的适配能力。在预训练阶段, GTR 使用 T5 架构对数十个检索任务进行联合训练, 包括问答、检索排序、句子对相似度等, 通过共享模型参数实现迁移泛化能力。该方法在 BEIR、MS MARCO、TREC-COVID 等数据集上取得了优异性能, 已被 Google 部署于真实产品环境

中, 如多语言搜索与信息检索服务。此外, GTR 还结合多任务联合训练框架通过将多个任务合并训练, 使检索模型在多个知识密集应用(如问答与事实验证)中均展现稳健性能, 该思路与 GTR 同源, 为多任务检索能力的提升提供了初步实验依据^[52]。

综上所述, REALM、REPLUG 与 GTR 分别从训练粒度、模型耦合与任务广度这 3 个维度对 RAG 系统的架构进行了重塑, 反映出 RAG 研究正朝着低成本适配、高效泛化与跨语言迁移方向不断拓展。这些方法不仅增强了系统对知识动态变化的适应能力, 也拓展了其在医疗、金融、搜索引擎等高精度场景中的实际可用性。

4.3 工具增强型语言模型

随着 LLM 在通用语言生成任务中的表现日益优异, 研究者逐步认识到其在封闭生成范式下仍面临知识静态性、计算能力有限和操作不可执行等核心瓶颈。为突破上述限制, 近年来兴起的工具增强型语言模型(Tool-Augmented LLMs)将 RAG 机制拓展至外部工具调用与动态交互执行领域, 通过结合检索、推理与执行动作, 实现了更强的问题求解与上下文适应能力。这一方向也被广泛归入“LLM Agents”或“Reasoning + Acting”研究范式中, 成为继传统 RAG 之后的重要发展趋势。

典型实现架构包括 LangChain、LlamaIndex 等通用框架, 它们通常将 LLM 与外部 API 工具(如 Web Search、SQL、Python REPL、文件系统、向量数据库等)进行集成, 并通过多轮 Prompt 交互引导模型完成“工具调用-结果感知-决策修正”的复杂任务流程。例如 LangChain 框架支持定义“Tool”、“Agent”、“Memory”、“Chain”等模块, 实现复杂任务分解与多轮执行控制, 在法律问答、企业搜索、编程代理等场景中获得广泛应用^[53]。在该范式中, Prompt 结构设计成为连接 LLM 推理与工具执行的核心机制。ReAct(Reason + Act)框架开创性地将思维链(CoT)与 Action 指令融合进统一的 Prompt 模板, 明确区分“思维链条”与“工具操作”两个逻辑阶段, 使模型能够边推理边调用外部函数。在 ReAct 中, 语言模型在每轮生成中首先给出自然语言的推理线索(Thought), 再输出一个动作调用(Action), 并根据返回观测信息(Observation)继续迭代, 从而构成一个完整的代理执行回路^[54]。

该类方法本质上将 RAG 从“纯检索增强”扩展为“行为增强与信息流增强”双结合系统, 具备更高的通用性与部署灵活性。已有研究指出, 工具

增强型语言模型在法律判例分析、金融报表问答、科研文献推理、数学题解等高复杂度任务中显著优于传统静态 RAG 方法, 尤其在需要与动态数据库、代码执行器等系统交互的环境中更具实用性^[55-56]。值得注意的是, 该类系统目前仍面临几个关键问题, 包括工具调用的稳定性、输出对齐一致性、安全边界控制等, 是后续“Agent-RAG”类系统持续演进的重要研究方向。

4.4 检索增强指令微调

在 LLM 不断朝通用性与任务泛化能力演进的背景下, 传统的指令微调方法虽能显著提升指令遵循性, 但其训练语料通常来自静态数据集, 难以覆盖长尾知识、实时信息或多样任务。为解决此类问题, 检索增强指令微调(Retrieval-Augmented Fine-Tuning, RA-FT)提出将检索机制嵌入至指令微调过程中, 使模型在参数优化阶段即能访问丰富的外部知识, 兼具可训练性与知识动态性, 成为指令微调的一种结构增强路径。

RA-FT 的基本范式是在微调阶段引入检索器, 为每条指令自动检索 Top- k 外部文档, 并将其与原始指令联合输入模型进行训练。相较于在推理阶段才进行知识注入的经典 RAG 结构, RA-FT 通过显式建模“指令+检索知识→响应”三元关系, 使得模型内化知识的能力显著增强, 特别适用于少样本或任务迁移场景。RAFT 系统构建了跨领域文档检索管道与多阶段训练框架, 并在金融、医疗、法律等垂直领域构建专属的 RAG 数据管线, 对大模型进行领域适配微调, 有效弥合了通用 LLM 与行业任务之间的知识鸿沟^[57]。另外, Self-RAG 提出了一种“自监督式增强”机制, 这是另外一种代表性工作。该方法首先由 LLM 自主生成检索查询与候选文档, 再对其回答进行自动评估, 最终构建出高质量的训练三元组。这一“生成-检索-审视”循环被视为一种模型自我反思机制, 极大提升了训练数据的质量与覆盖面, 增强了模型在开放领域问答和跨任务泛化场景下的鲁棒性与可解释性^[22]。

当前, RA-FT 已被广泛融合进各类开源指令微调框架(如 Alpaca, Open-Instruction-Tuning, Unsloth 等)中, 并被视为应对大模型“知识过时”问题、快速适配专业领域的一条有效路径。其核心价值在于实现结构化数据增强(Retrieval-based Augmentation)与指令任务对齐(Instruction Alignment)的统一, 同时也为训练效率、知识选择机制等带来新的挑战。

4.5 GraphRAG

随着 RAG 系统在问答、对话与文档生成等任务中的持续拓展,研究者逐渐意识到传统基于无结构文档拼接的 RAG 架构在处理信息冗余、逻辑一致性以及多实体对齐等问题时存在显著局限。为此,GraphRAG 架构应运而生,旨在通过引入结构化知识建模机制,加强检索内容的语义组织性与推理连贯性,推动 RAG 从“文本融合”走向“知识融合”。

GraphRAG 的核心思想是将检索器返回的文档集合进行实体与关系抽取,构建轻量级知识图谱,再通过图神经网络(Graph Neural Networks, GNN)或路径注意力机制实现结构感知的信息汇聚与推理。在生成阶段,图结构可用于增强生成器的语境感知能力、约束事实生成路径,或通过节点级条件控制引导特定内容输出。该机制不仅提升了信息表达的紧凑性与一致性,也为长链推理、多跳问答等复杂任务提供了更具显式语义结构的支撑。Hu 等^[58]提出的 GRAG(Graph Retrieval-Augmented Generation)是这一方向的重要实例之一,其方法包括:基于实体链接和关系抽取构建文档间融合图;基于图路径进行重排序与选择;利用图感知解码器融合图结构与文本上下文。该方法在多文档问答与领域总结任务上显著优于传统 Dense RAG 与 FiD 方法,特别在应对冗余冲突文段、推理链条歧义等问题时展现出较强鲁棒性。

目前,GraphRAG 可分为 4 种典型方式:实体图构建式(Entity-centric)、路径引导式(Path-based)、关系模板填充式(Relational prompting)、图结构对齐式生成(Graph-grounded Decoding)。在 HotpotQA、Doc2Dial 等数据集上集成结构感知的 RAG 模型整体提升了生成质量 5~10 BLEU points,且幻觉减少率达 20% 以上,凸显了结构增强对语义准确性的重要促进作用^[59]。进一步,GraphRAG 还展现出与图数据库(如 Neo4j)和知识存储系统(如 Wikidata、PubMedKG)自然集成的潜力,为面向医疗、金融、法律等高知识密度领域构建高可信度检索生成系统提供了新思路。未来研究可探索在图构建效率、图结构压缩、路径选择启发式(如语义多样性或信息增益)等方向的进一步优化,以提升系统在大规模开放场景下的可扩展性与实时性。

5 应用场景

RAG 因其融合了知识检索与语言生成的优势,已在多个实际场景中展现出广泛的应用前景,尤其

<https://mc.spacejournal.cn>

在知识密集型任务中显示出优于传统生成模型的性能与可控性。

(1) 开放领域问答系统

RAG 最初被提出用于开放领域问答任务,以应对封闭式语言模型在面对事实性问题时因缺乏外部知识而产生幻觉的问题。典型工作如 Lewis 等^[9]提出的原始 RAG 框架在 Natural Questions 与 TriviaQA 等数据集上表现优越。Haystack 框架集成了多种检索器与生成器组合,构建了模块化的端到端问答系统^[60]。KILT benchmark 提供了统一评估框架,进一步推动 RAG 在多任务开放问答场景中的标准化发展^[23]。

(2) 智能客服与对话系统

企业级对话系统中广泛采用 RAG 以实现信息调用能力的增强^[61]。通过将用户查询与结构化 FAQ、产品手册等文档进行语义匹配,RAG 系统能够生成上下文相关的回答。例如,Linkedin 的 RAG 模型结合了多轮历史与外部文档,显著提升了面向任务的响应准确率^[62]。RAG 结构适用于需要知识记忆更新的场景,如电商产品问答、IT 支持等。

(3) 医疗、法律、金融等垂直领域问答

在专业问答任务中,RAG 能够结合结构化或半结构化知识源进行条件生成。医学领域的 MedQA 与 PubMedQA 任务已使用医学文献库构建 RAG 系统以提升回答准确性^[63-65]。法律领域中,LegalBench 与 CaseHOLD 等数据集促进了法律领域 RAG 的定制模型开发,如 LegalRAG 系统集成了法院判决书库与结构化案情描述,提升了生成合理性与事实支持程度。金融领域的 FinQA 与 TAT-QA 也显示出 RAG 在财务报表问答中的优势^[66-68]。

(4) 企业知识管理与智能助手

面向企业内部的知识管理,RAG 可以用于构建私有 Copilot 类系统,将企业文档、会议纪要、邮件内容等异构数据整合为可检索的知识库。Microsoft 365 Copilot 就采用了类似于 RAG 的系统架构,结合 SharePoint 与 Exchange 进行向量化索引与大模型生成^[69]。这一机制可有效减少员工的搜索负担,并提高知识访问效率。

(5) 教育场景中的自动答疑与内容生成

在教育场景中,已有研究将 RAG 与大型语言模型(Large Language Models, LLMs)结合,以实现更具个性化与可追溯性的教学反馈生成。例如,Dong 等^[70]提出的 KG-RAG(Knowledge Graph-enhanced RAG)框架将结构化知识图谱引入检索流程,并

应用于自适应教学系统中, 在人机交互实验中显著提升了学生对概念知识的掌握率与反馈满意度, 准确率提升达 35%。此外, Jacobs 与 Jaschke^[71]探索了基于 GPT-4 与 RAG 构建的教学辅助系统, 从课堂讲解转录文本中构建检索上下文, 用于生成面向编程学习任务的结构化反馈, 结果表明该系统在课堂理解、内容定位与学习路径优化方面均表现出优势。

(6) 指令数据生成与数据增强

在数据构造方面, RAG 可用于生成高质量的训练数据, 特别是在“自我指令微调”(Self-Instruct)框架中, RAG 用于提供语义相关文档上下文, 辅助生成 instruction-answer 对, 从而增强指令数据的多样性与真实性^[72]。此外, RAG 还可应用于推理链构

建、事实对齐验证与训练集去噪等过程, 增强模型训练阶段的可靠性。

6 评估方法

尽管 RAG 在多个自然语言处理任务中展现出显著性能优势, 但其系统结构的复合性也对评估方法提出了更高要求。目前尚缺乏统一的评估标准, 现有指标在覆盖检索与生成两个阶段时存在一定局限性, 难以全面衡量系统的实际效果。本章将梳理当前主流 RAG 系统的评估方法体系, 重点介绍其在检索质量、生成质量以及生成与检索的联合评估这 3 个层面的代表性指标与实践方法, 如表 2 所示。

表 2 RAG 的 3 种常用评估标准
Tab. 2 Three commonly used evaluation criteria for RAG

评估类别	代表指标	指标说明
检索质量指标	Recall@k	衡量模型在 Top-k 返回文档中命中“黄金答案段”的比例, 是当前检索模块的标准指标之一 ^[73]
	Mean Reciprocal Rank (MRR)	衡量第一个正确文档出现的位置, 适用于单跳问答任务
	normalized Discounted Cumulative Gain (nDCG)	引入文档排序权重, 反映候选文档的质量分布 ^[74]
	Context Sufficiency	近期研究提出的指标, 判断 retriever 返回的文档集合是否足以使生成器生成正确答案 ^[75]
生成质量指标	ROUGE/BLEU	经典的 n-gram 重叠指标, 适用于摘要与标准问答, 但无法捕捉语义多样性 ^[76]
	BERTScore	利用预训练语言模型的语义表示, 评估生成输出与参考答案的语义相似性 ^[77]
	Exact Match/F1	用于结构化问答任务, 衡量答案级的一致性 ^[78]
	Knowledge F1/Answer Groundedness	强调答案中信息是否确实来自相关上下文 ^[79, 80]
生成与检索的联合评估	Faithfulness/Factual Consistency	衡量生成内容是否忠实于输入文档, 尤其在多文档融合与多跳推理中显得尤为重要。可通过自动化工具(如 FactScore、QAG)或人工评估完成 ^[81-82]
	Hallucination Rate	统计生成内容中不真实信息的比例, 常用于对比 RAG 与 Closed-book 模型的事实鲁棒性 ^[81]

7 挑战和研究方向

尽管 RAG 技术取得了显著进展, 但在实际系统设计、训练与部署中仍面临多方面挑战, 主要包括检索误差传播(Retrieval Error Propagation)、冗余与冲突文档融合困难、事实一致性与可验证性缺失、知识库动态更新难题、训练成本高(资源依赖强)和统一评估与标准化基准缺失等多项问题。

(1) 检索误差传播是由于由于检索器通常作为生成器的前置模块, 其检索质量直接影响生成阶段的输入, 若检索文档缺失关键信息, 生成器将无法正确回答, 形成“不可纠错”的上游瓶颈^[83-84]。

(2) 冗余与冲突文档融合困难是由于多文档输入在结构上常包含重复、无关甚至冲突的信息, 早期拼接容易引发幻觉或偏差信息生成。如何进行信息选择、压缩与一致性建模, 是当前结构融合 RAG 的研究热点^[84-85]。

(3) 事实一致性与可验证性缺失是由于传统指标难以评估生成文本的真实性(truthfulness), 尤其在多模态、长链推理中, 模型可能生成结构正确但事实虚假的内容, 建立面向事实验证的细粒度评估框架仍属空白^[86]。

(4) 知识库动态更新难题是由于当前大多数 RAG 系统使用静态向量索引, 而现实世界知识是不

断变化的(新闻、法规、金融市场等)。如何实现低延迟、高一致性的文档增量更新机制,是构建实时问答系统的关键挑战^[83, 87]。

(5)训练成本高是由于 RAG 系统需同时训练/调用检索器与生成器两个大模型,特别是在 end-to-end 架构中,训练过程依赖大规模 GPU 集群。这限制了其在中小型机构或隐私场景中的可部署性^[44, 86, 88]。

(6)统一评估与标准化基准缺失是目前 RAG 系统的实验数据集、评估指标、任务设置存在严重不一致,导致不同工作之间可比性差。尽管如 KILT 等尝试构建统一框架,但尚未形成领域共识^[23]。

基于当前研究现状与发展趋势,业内学者正在从以下 6 个方向对 RAG 系统展开探索研究。

(1)更智能的检索方法—主动与自适应检索。当前主流 RAG 系统多依赖静态的 Top- k 文档检索策略,忽略了生成任务对文档相关性与内容粒度的动态需求。未来可探索主动检索(Active Retrieval)与自适应检索(Adaptive Retrieval)机制:通过生成器反馈动态调整检索查询,或在解码过程中迭代性地优化检索结果。类似 IRCot 所提出的多轮推理增强检索即是初步尝试;而近期引入强化学习、bandit 优化与 Uncertainty-Guided 检索策略的研究,也显示出提升语义对齐度的潜力^[46, 89-90]。

(2)检索-生成联合优化的新机制。传统管线式训练范式难以捕捉检索器与生成器之间的复杂语义耦合关系,导致误检文档引发生成偏差。未来可进一步发展可微分检索机制、对比学习驱动的检索器强化训练,或引入结构化中介表示(如思维链 CoT)以缓解梯度传播瓶颈,实现更深层次的协同优化^[9, 91]。

(3)多模态检索增强生成(Multimodal RAG)。当前 M-RAG 研究多集中于图文问答(VQA)任务,仍缺乏统一的模型架构与大规模基准。未来研究可朝多源异构模态统一表示建模(例如视觉-语言对齐、图像检索与文本生成协同编码)、跨模态对话生成与视频驱动内容生成等方向发展。文献^[92-93]提出的 RA-CM3 与 Multimodal-RAG 等工作可为该方向提供范式参考。

(4)小样本/无监督 RAG 训练机制。当前 RAG 方法依赖大规模标注数据与高质量知识库,限制了其在低资源场景的应用。未来可探索 few-shot RAG 与 unsupervised/self-supervised RAG 策略,通过引入合成指令、伪标签构造、self-querying 等机制,提升模型在新领域或新任务下的适应能力。例如 Self-

RAG 即通过模型自反推理构建训练语料,取得了良好迁移效果^[22]。

(5)与知识图谱、外部工具的深度融合。相比于纯文本检索,结构化知识图谱(KG)与外部工具-(如 SQL 查询、API 接口)能为生成过程提供更精准、可解释的支持。GraphRAG 初步展示了图结构在建模文档间实体关系方面的优势,而工具增强 RAG (如 ReAct、Toolformer)则强调模型的推理与调用能力协同优化^[54, 59]。未来可在图神经网络辅助结构聚合、动态知识交互接口建模等方面深入挖掘。

(6)模型评估机制与可解释性研究。当前 RAG 系统多依赖 BLEU、ROUGE、EM 等通用指标,无法全面刻画系统在“真实性、一致性、源依赖性”方面的行为。未来亟需构建多维度、任务相关的自动评估指标体系,并发展可解释性技术,以实现检索器-生成器协同机制的透明化分析。例如使用 attention 可视化、路径跟踪机制、source attribution score 等工具,对最终输出的生成路径与文档贡献进行量化分析,提升系统可信度与调试效率^[40]。

8 结束语

RAG 作为近年来自然语言处理领域的重要范式,在应对大语言模型知识封闭性、更新滞后与幻觉问题方面展现出巨大潜力。回顾其发展脉络,RAG 系统经历了从早期基于可训练编码器-解码器架构(如 FiD、REALM)向解耦式“Retriever+黑盒大模型”(如 REPLUG)演进的过程。在此过程中,系统结构逐步走向模块化、低耦合与高可控;训练机制则从静态管线式训练发展至端到端联合优化与多轮交互式生成,显著提升了系统的语义对齐与推理深度。

RAG 的核心优势在于其通过外部检索引入动态知识源,增强了大模型的事实一致性与任务泛化能力。这一能力在开放域问答、法律文档分析、医学推理、代码生成等高知识密度场景中得到了广泛应用。同时,结合 Prompt Engineering、参数高效微调(PEFT)与多模态融合等策略,RAG 已逐渐从研究原型走向实际部署,成为工业界构建可解释、高性能 AI 系统的重要支撑。

综上所述,RAG 不仅是当前语言生成技术中的关键模块,更是构建下一代知识驱动智能系统的核心支柱。未来,随着开放数据集、高效模型与可控生成技术的发展,RAG 将在理论研究与实际应用中展现其独特的学术与社会价值。

参考文献:

- [1] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]// Proceedings of 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. New York: Association for Computational Linguistics, 2019: 4171-4186. DOI: [10.18653/v1/N19-1423](https://doi.org/10.18653/v1/N19-1423).
- [2] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[R]. San Francisco: OpenAI, 2018.
- [3] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[C]// Proceedings of the 36th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2022: 2011.
- [4] CHOWDHURY A, NARANG S, DEVLIN J, et al. PaLM: Scaling language modeling with pathways[J]. The Journal of Machine Learning Research, 2023, 24(1): 240.
- [5] Team GLM. ChatGLM: A family of large language models from GLM-130B to GLM-4 all tools[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2406.12793>.
- [6] BAI J Z, BAI S, CHU Y F, et al. Qwen technical report[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2309.16609>.
- [7] DeepSeek-AI. DeepSeek-V3 technical report[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2412.19437>.
- [8] SHUSTER K, POFF S, CHEN M, et al. Retrieval augmentation reduces hallucination in conversation[C]// Proceedings of Findings of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2021: 3784-3803. DOI: [10.18653/v1/2021.findings-emnlp.320](https://doi.org/10.18653/v1/2021.findings-emnlp.320).
- [9] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]// Proceedings of the 34th Conference on Neural Information Processing Systems. [S.I.]: NeurIPS, 2020: 9459-9474.
- [10] GUU K, LEE K, TUNG Z, et al. Retrieval augmented language model pre-training[C]// Proceedings of the 37th International Conference on Machine Learning. Vienna: PMLR, 2020: 3929-3938.
- [11] IZACARD G, GRAVE E. Leveraging passage retrieval with generative models for open domain question answering[C]// Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2021: 874-880. DOI: [10.18653/v1/2021.eacl-main.74](https://doi.org/10.18653/v1/2021.eacl-main.74).
- [12] KARPUKHIN V, OGUZ B, MIN S, et al. Dense passage retrieval for open-domain question answering[C]// Proceedings of 2020 Conference on Empirical Methods in Natural Language Processing. New York: Association for Computational Linguistics, 2020: 6769-6781. DOI: [10.18653/v1/2020.emnlp-main.550](https://doi.org/10.18653/v1/2020.emnlp-main.550).
- [13] SHI W J, MIN S, YASUNAGA M, et al. REPLUG: Retrieval-augmented black-box language models[C]// Proceedings of 2024 Conference of the North American Chapter of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2024: 8371-8384. DOI: [10.18653/v1/2024.naacl-long.463](https://doi.org/10.18653/v1/2024.naacl-long.463).
- [14] JOHNSON J, DOUZE M, JÉGOU H. Billion-scale similarity search with GPUs[J]. IEEE Transactions on Big Data, 2021, 7(3): 535-547. DOI: [10.1109/TBDATA.2019.2921572](https://doi.org/10.1109/TBDATA.2019.2921572).
- [15] NAKANO R, HILTON J, BALAJI S, et al. WebGPT: Browser-assisted question-answering with human feedback[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2112.09332>.
- [16] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]// Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: 159.
- [17] ROBERTS A, RAFFEL C, SHAZEER N. How much knowledge can you pack into the parameters of a language model?[C]// Proceedings of 2020 Conference on Empirical Methods in Natural Language Processing. New York: Association for Computational Linguistics, 2020: 5418-5426. DOI: [10.18653/v1/2020.emnlp-main.437](https://doi.org/10.18653/v1/2020.emnlp-main.437).
- [18] JI Z W, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 248. DOI: [10.1145/3571730](https://doi.org/10.1145/3571730).
- [19] CHEN D Q, FISCH A, WESTON J, et al. Reading Wikipedia to answer open-domain questions[C]// Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2017: 1870-1879. DOI: [10.18653/v1/P17-1171](https://doi.org/10.18653/v1/P17-1171).
- [20] XIONG L, XIONG C Y, LI Y, et al. Approximate nearest neighbor negative contrastive learning for dense text retrieval[C]// Proceedings of the 9th International Conference on Learning Representations. [S.I.]: OpenReview.net, 2021.
- [21] MENICK J, TREBACZ M, MIKULIK V, et al. Teaching language models to support answers with verified quotes[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2203.11147>.
- [22] ASAI A, WU Z Q, WANG Y Z, et al. Self-rag: Self-reflective retrieval augmented generation[C]// Proceedings of 2023 Workshop on Instruction Tuning and Instruction Following. New Orleans: NeurIPS, 2023.

- [23] PETRONI F, PIKTUS A, FAN A, et al. KILT: A benchmark for knowledge intensive language tasks[C]// Proceedings of 2021 Conference of the North American Chapter of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2021: 2523-2544. DOI: [10.18653/v1/2021.naacl-main.200](https://doi.org/10.18653/v1/2021.naacl-main.200).
- [24] HAN H Y, WANG Y, SHOMER H, et al. Retrieval-augmented generation with graphs (GraphRAG)[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2501.00309>.
- [25] KHATTAB O, ZAHARIA M. ColBERT: Efficient and effective passage search via contextualized late interaction over BERT[C]// Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 39-48. DOI: [10.1145/3397271.3401075](https://doi.org/10.1145/3397271.3401075).
- [26] LIU X, LAI H Y, YU H, et al. WebGLM: Towards an efficient web-enhanced question answering system with human preferences[C]// Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2023: 4549-4560. DOI: [10.1145/3580305.3599931](https://doi.org/10.1145/3580305.3599931).
- [27] SANTHANAM K, KHATTAB O, SAAD-FALCON J, et al. ColBERTv2: Effective and efficient retrieval via lightweight late interaction[C]// Proceedings of 2022 Conference of the North American Chapter of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2022: 3715-3734. DOI: [10.18653/v1/2022.naacl-main.272](https://doi.org/10.18653/v1/2022.naacl-main.272).
- [28] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. The Journal of Machine Learning Research, 2020, 21(1): 140.
- [29] CHUNG H W, HOU L, LONGPRE S, et al. Scaling instruction-finetuned language models[J]. The Journal of Machine Learning Research, 2024, 25(1): 70.
- [30] TAY Y, DEGHANI M, TRAN V Q, et al. UL2: Unifying language learning paradigms[C]// Proceedings of the 11th International Conference on Learning Representations. [S.I.]: OpenReview. net, 2023.
- [31] OpenAI, ACHIAM J, ADLER S, et al. GPT-4 technical report[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2303.08774>.
- [32] ANTHROPIC. Introducing the next generation of Claude (Claude 3 model family)[EB/OL]. [2025-08-04]. <https://www.anthropic.com/news/claude-3-family>.
- [33] Gemini Team, Google. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context[R/OL]. [2025-08-04]. <https://arxiv.org/abs/2403.05530>.
- [34] LI Z H, HU X M, LIU A W, et al. Refiner: Restructure retrieval content efficiently to advance question-answering capabilities[C]// Proceedings of Findings of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2024: 8548-8572. DOI: [10.18653/v1/2024.findings-emnlp.500](https://doi.org/10.18653/v1/2024.findings-emnlp.500).
- [35] CHAN C M, XU C P, YUAN R B, et al. RQ-RAG: Learning to refine queries for retrieval augmented generation[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2404.00610>.
- [36] HOLTZMAN A, BUYS J, DU L, et al. The curious case of neural text degeneration[C]// Proceedings of the 8th International Conference on Learning Representations. Addis Ababa: OpenReview. net, 2020.
- [37] LI X L, LIANG P. Prefix-tuning: Optimizing continuous prompts for generation[C]// Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. New York: Association for Computational Linguistics, 2021: 4582-4597. DOI: [10.18653/v1/2021.acl-long.353](https://doi.org/10.18653/v1/2021.acl-long.353).
- [38] HU E J, SHEN Y L, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[C]// Proceedings of the 10th International Conference on Learning Representations. [S.I.]: OpenReview. net, 2022.
- [39] MANAKUL P, LIUSIE A, GALES M J F. SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models[C]// Proceedings of 2023 Conference on Empirical Methods in Natural Language Processing. New York: Association for Computational Linguistics, 2023: 9004-9017. DOI: [10.18653/v1/2023.emnlp-main.557](https://doi.org/10.18653/v1/2023.emnlp-main.557).
- [40] YUAN H Y, YUAN Z, TAN C Q, et al. RRHF: Rank responses to align language models with human feedback[C]// Proceedings of the 37th Conference on Neural Information Processing Systems. New Orleans: NeurIPS, 2023.
- [41] ZHANG H N, SONG J T, ZHU J, et al. RAG-Reward: Optimizing RAG with reward modeling and RLHF[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2501.13264>.
- [42] VERMA P, MIDIGESHI S P, SINHA G, et al. Plan*RAG: Efficient test-time planning for retrieval augmented generation[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2410.20753>.
- [43] GAO Y F, XIONG Y, GAO X Y, et al. Retrieval-augmented generation for large language models: A survey[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2312.10997>.
- [44] CHEN Y Q, YAN L Y, SUN W W, et al. Improving retrieval-augmented generation through multi-agent reinforcement learning[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2501.15228>.
- [45] HUANG J, MADALA S, SIDHU R, et al. RAG-RL: Ad-

- vancing retrieval-augmented generation via RL and curriculum learning[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2503.12759>.
- [46] TRIVEDI H, BALASUBRAMANIAN N, KHOT T, et al. Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-step questions[C]// Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2023: 10014-10037. DOI: [10.18653/v1/2023.acl-long.557](https://doi.org/10.18653/v1/2023.acl-long.557).
- [47] TANG Y X, YANG Y. MultiHop-RAG: Benchmarking retrieval-augmented generation for multi-hop queries[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2401.15391>.
- [48] ZHUANG Z Y, ZHANG Z Y, CHENG S T, et al. EfficientRAG: Efficient retriever for multi-hop question answering[C]// Proceedings of 2024 Conference on Empirical Methods in Natural Language Processing. New York: Association for Computational Linguistics, 2024: 3392-3411. DOI: [10.18653/v1/2024.emnlp-main.199](https://doi.org/10.18653/v1/2024.emnlp-main.199).
- [49] KWIATKOWSKI T, PALOMAKI J, REDFIELD O, et al. Natural questions: A benchmark for question answering research[J]. *Transactions of the Association for Computational Linguistics*, 2019, 7(7): 453-466. DOI: [10.1162/tacl_a_00276](https://doi.org/10.1162/tacl_a_00276).
- [50] JOSHI M, CHOI E, WELD D S, et al. TriviaQA: A large scale distantly supervised challenge dataset for reading comprehension[C]// Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2017: 1601-1611. DOI: [10.18653/v1/P17-1147](https://doi.org/10.18653/v1/P17-1147).
- [51] NI J M, QU C, LU J, et al. Large dual encoders are generalizable retrievers[C]// Proceedings of 2022 Conference on Empirical Methods in Natural Language Processing. New York: Association for Computational Linguistics, 2022: 9844-9855. DOI: [10.18653/v1/2022.emnlp-main.669](https://doi.org/10.18653/v1/2022.emnlp-main.669).
- [52] MAILLARD J, KARPUKHIN V, YIH W T, et al. Multi-task retrieval for knowledge-intensive tasks[C]// Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. New York: Association for Computational Linguistics, 2021: 1098-1111. DOI: [10.18653/v1/2021.acl-long.89](https://doi.org/10.18653/v1/2021.acl-long.89).
- [53] LANGCHAIN. LangChain: Building applications with LLMs through composability[EB/OL]. [2025-08-04]. <https://docs.langchain.com/>.
- [54] YAO S Y, ZHAO J, YU D, et al. ReAct: Synergizing reasoning and acting in language models[C]// Proceedings of the 11th International Conference on Learning Representations. Kigali: OpenReview. net, 2023.
- [55] QIN Y J, LIANG S H, YE Y N, et al. ToolLLM: Facilitating large language models to master 16000+ real-world APIs[C]// Proceedings of the 12th International Conference on Learning Representations. [S.I.]: OpenReview. net, 2024.
- [56] RUAN J Q, CHEN Y H, ZHANG B, et al. TPTU: Task planning and tool usage of large language model-based AI agents[C]// Proceedings of Foundation Models for Decision Making Workshop. New Orleans: NeurIPS, 2023.
- [57] ZHANG T J, PATIL S G, JAIN N, et al. RAFT: Adapting language model to domain specific RAG[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2403.10131>.
- [58] HU Y T, LEI Z H, ZHANG Z, et al. GRAG: Graph retrieval-augmented generation[C]// Proceedings of Findings of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2025: 4145-4157. DOI: [10.18653/v1/2025.findings-naacl.232](https://doi.org/10.18653/v1/2025.findings-naacl.232).
- [59] PENG B C, ZHU Y, LIU Y C, et al. Graph retrieval-augmented generation: A survey[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2408.08921>.
- [60] DEEPSET AI. Haystack: An open-source NLP framework[EB/OL]. [2025-08-04]. <https://haystack.deepset.ai>.
- [61] XU Z T, CRUZ M J, GUEVARA M, et al. Retrieval-augmented generation with knowledge graphs for customer service question answering[C]// Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024: 2905-2909. DOI: [10.1145/3626772.3661370](https://doi.org/10.1145/3626772.3661370).
- [62] EDGE D, TRINH H, CHENG N, et al. From local to global: A graph rag approach to query-focused summarization[EB/OL]. [2025-08-14]. <https://arxiv.org/abs/2404.16130>.
- [63] JIN T, DHINGRA B, LIU Z P, et al. PubMedQA: A dataset for biomedical research question answering[C]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. New York: Association for Computational Linguistics, 2019: 2567-2577. DOI: [10.18653/v1/D19-1259](https://doi.org/10.18653/v1/D19-1259).
- [64] PAL D, LIU T, ZHOU M, et al. MedQA: A large-scale medical QA benchmark[C]// Proceedings of Findings of the Association for Computational Linguistics: ACL 2020. Online: Association for Computational Linguistics, 2020.
- [65] WU J D, ZHU J Y, QI Y L, et al. Medical graph RAG: Towards safe medical large language model via graph retrieval-augmented generation[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2408.04187>.
- [66] GUHA N, NYARKO J, HO D E, et al. LegalBench: A collaboratively built benchmark for measuring legal reasoning[EB/OL]. [2025-08-04]. <https://mc.spacejournal.cn>

- oning in large language models[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2308.11462>.
- [67] CHALKIDIS I, ANDROUTSOPOULOS I, ALETRAS N. Legal judgment prediction: A survey[J]. *Artificial Intelligence Review*, 2023, 60(5): 415-432.
- [68] KABIR M R, SULTAN R M, RAHMAN F, et al. LegalRAG: A hybrid RAG system for multilingual legal information retrieval[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2504.16121>.
- [69] MICROSOFT. Microsoft 365 copilot: Your copilot for work[EB/OL]. [2025-08-04]. <https://www.microsoft.com/microsoft-365/blog/2023/03/16>.
- [70] DONG C X, YUAN Y M, CHEN K, et al. How to build an adaptive AI tutor for any course using knowledge graph-enhanced retrieval-augmented generation (KG-RAG)[C]// *Proceedings of the 2025 14th International Conference on Educational and Information Technology*. Piscataway: IEEE, 2025: 152-157. DOI: [10.1109/ICEIT64364.2025.10975937](https://doi.org/10.1109/ICEIT64364.2025.10975937).
- [71] JACOBS S, JASCHKE S. Leveraging lecture content for improved feedback: Explorations with GPT-4 and retrieval augmented generation[C]// *Proceedings of the 2024 36th International Conference on Software Engineering Education and Training*. Piscataway: IEEE, 2024: 1-5. DOI: [10.1109/CSEET62301.2024.10663001](https://doi.org/10.1109/CSEET62301.2024.10663001).
- [72] WANG Y Z, KORDI Y, MISHRA S, et al. Self-instruct: Aligning language models with self-generated instructions[C]// *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*. New York: Association for Computational Linguistics, 2023: 13484-13508. DOI: [10.18653/v1/2023.acl-long.754](https://doi.org/10.18653/v1/2023.acl-long.754).
- [73] DE VRIES B. Evaluating RAG: How to measure performance of retrieval-augmented generation pipelines[EB/OL]. [2025-08-04]. <https://weaviate.io/blog/rag-evaluation>.
- [74] PATRONUS AI. RAG evaluation metrics[EB/OL]. [2025-08-04]. <https://www.patronus.ai/llm-testing/rag-evaluation-metrics>.
- [75] JOREN H, ZHANG J Y, FERNG C S, et al. Sufficient context: A new lens on retrieval augmented generation systems[C]// *Proceedings of the 13th International Conference on Learning Representations*. [S.I.]: OpenReview. net, 2025.
- [76] GAN A R, YU H, ZHANG K, et al. Retrieval augmented generation evaluation in the era of large language models: A comprehensive survey[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2504.14891>.
- [77] ZHANG T Y, KISHORE V, WU F, et al. BERTScore: Evaluating text generation with BERT[C]// *Proceedings of the 8th International Conference on Learning Representations*. Addis Ababa: OpenReview. net, 2020.
- [78] The Deepset Team. Metrics for QA: Exact match and F1[EB/OL]. [2025-08-04]. <https://www.deepset.ai/blog/metrics-to-evaluate-a-question-answering-system>.
- [79] CHAUDHURI D, RONY R A H, LEHMANN J. Grounding dialogue systems via knowledge graph aware decoding with pre-trained transformers[C]// *Proceedings of the 18th European Semantic Web Conference*. Heidelberg: Springer, 2021: 323-339. DOI: [10.1007/978-3-030-77385-4_19](https://doi.org/10.1007/978-3-030-77385-4_19).
- [80] LI X C, OUYANG J. How does knowledge selection help retrieval augmented generation?[EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2410.13258>.
- [81] ES S, JAMES J, ANKE L E, et al. RAGAs: Automated evaluation of retrieval augmented generation[C]// *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. New York: Association for Computational Linguistics, 2024: 150-158. DOI: [10.18653/v1/2024.eacl-demo.16](https://doi.org/10.18653/v1/2024.eacl-demo.16).
- [82] FABBRI A, WU C S, LIU W H, et al. QAFactEval: Improved QA-based factual consistency evaluation for summarization[C]// *Proceedings of 2022 Conference of the North American Chapter of the Association for Computational Linguistics*. New York: Association for Computational Linguistics, 2022: 2587-2601. DOI: [10.18653/v1/2022.naacl-main.187](https://doi.org/10.18653/v1/2022.naacl-main.187).
- [83] OUYANG J, PAN T Y, CHENG M Y, et al. HoH: A dynamic benchmark for evaluating the impact of outdated information on retrieval-augmented generation[C]// *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics*. New York: Association for Computational Linguistics, 2025: 6036-6063. DOI: [10.18653/v1/2025.acl-long.301](https://doi.org/10.18653/v1/2025.acl-long.301).
- [84] DE VRIES B. Evaluating RAG: how to measure performance of retrieval-augmented generation pipelines[EB/OL]. [2025-08-04]. <https://blog.langchain.dev/deconstructing-rag>.
- [85] AWS. Challenges in source data that affect RAG applications[EB/OL]. [2025-08-04]. <https://docs.aws.amazon.com/prescriptive-guidance/latest/writing-best-practices-rag/challenges.html>.
- [86] AUZAI A J. RAG: A comprehensive survey[EB/OL]. [2025-08-04]. <https://medium.com/@auzair2011/retrieval-augmented-generation-rag-a-comprehensive-survey>.
- [87] EDEN A I. How RAG enables real-time knowledge updates[EB/OL]. [2025-08-04]. <https://www.newline.co/@zaoyang/how-rag-enables-real-time-knowledge-updates-c9635b8d>.
- [88] KAUSHIK E. Cost-effectiveness of retrieval-augmented generation (RAG) services[EB/OL]. [2025-08-04]. <https://medium.com/@kaushikeva0026/cost-effectiveness-of-retrieval-augmented-generation-rag-services-aaf5762da02e>.

- [89] TANG X Q, GAO Q, LI J, et al. MBA-RAG: A bandit approach for adaptive retrieval-augmented generation through question complexity[C]// Proceedings of the 31st International Conference on Computational Linguistics. New York: Association for Computational Linguistics, 2025: 3248-3254.
- [90] JI Y, MENG R, LI Z C, et al. Memory-aware and uncertainty-guided retrieval for multi-hop question answering [EB/OL]. [2025-08-04]. <https://arxiv.org/abs/2503.23095>.
- [91] LI R, HE L Y, LIU Q, et al. UniRAG: Unified query understanding method for retrieval augmented generation [C]// Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2025: 14163-14178. DOI: [10.18653/v1/2025.acl-long.693](https://doi.org/10.18653/v1/2025.acl-long.693).
- [92] YASUNAGA M, AGHAJANYAN A, SHI W J, et al. Retrieval-augmented multimodal language modeling[C]// Proceedings of the 40th International Conference on Machine Learning. [S.I.]: PMLR, 2023: 39755-39769.
- [93] ABOOTORABI M M, ZOBEIRI A, DEGHANI M, et al. Ask in any modality: A comprehensive survey on multimodal retrieval-augmented generation[C]// Proceedings of Findings of the Association for Computational Linguistics. New York: Association for Computational Linguistics, 2025: 16776-16809. DOI: [10.18653/v1/2025.findings-acl.861](https://doi.org/10.18653/v1/2025.findings-acl.861).

作者简介:

李子骏 硕士, 博士研究生, lizijun@tongji.edu.cn

李雪峰(通信作者) 博士, 副教授, lixuefeng@tongji.edu.cn