

检索增强生成中的隐私保护技术综述 *

刘晓迁^{1†}, 袁 明^{1,2}, 钱汉伟^{1,3}, 高光亮¹, 王 群¹

(1. 江苏警官学院 计算机信息与网络安全系, 南京 210031; 2. 南京邮电大学 计算机学院, 南京 210023; 3. 南京大学 软件学院, 南京 210093)

摘 要: 检索增强生成(Retrieval-Augmented Generation, RAG)系统在检索与生成全流程中面临严峻的敏感信息泄露风险。为系统梳理其隐私威胁与防护技术, 首先阐释 RAG 系统的核心原理与应用场景, 并阐明其隐私定义。系统剖析成员推断、隐式知识提取、知识投毒等代表性隐私攻击模型, 进而将现有隐私保护技术归纳为四类: 一是基于噪声注入的差分隐私技术; 二是基于联邦学习的去中心化协同训练框架; 三是基于合成数据的源头隐私替代方案; 四是覆盖数据全生命周期的加密技术。通过对比各类技术的适用场景、优势与局限, 旨在为 RAG 系统隐私保护提供策略参考。

关键词: 检索增强生成; 隐私保护; 差分隐私; 联邦学习; 合成数据

中图分类号: TP309 **doi:** 10.19734/j.issn.1001-3695.2025.09.0308

Review of privacy protection technologies in retrieval-augmented generation

Liu Xiaoqian^{1†}, Yuan Ming^{1,2}, Qian Hanwei^{1,3}, Gao Guangliang¹, Wang Qun¹

(1. Dept. of Computer Information and Cyber Security, Jiangsu Police Institute, Nanjing 210031, China; 2. School of Computer Science, Nanjing University of Posts and Telecommunications, Nanjing 210023, China; 3. Software Institute, Nanjing University, Nanjing 210093, China)

Abstract: Retrieval-Augmented Generation (RAG) systems face severe risks of sensitive information leakage throughout the entire retrieval and generation process. To systematically sort out their privacy threats and protection technologies, this study first explains the core principles and application scenarios of RAG systems and clarifies their privacy definition. It systematically analyzes representative privacy attack models such as membership inference, implicit knowledge extraction, and knowledge poisoning. Then, it classifies existing privacy protection technologies into four categories: first, differential privacy technologies based on noise injection; second, decentralized collaborative training frameworks based on federated learning; third, source-level privacy substitution scheme based on synthetic data; fourth, encryption technologies covering the entire data lifecycle. By comparing the applicable scenarios, advantages and limitations of various technologies, this study aims to provide strategic references for privacy protection of RAG systems.

Key words: retrieval-augmented generation; privacy protection; differential privacy; federated learning; synthetic data

0 引言

RAG 作为一种融合外部知识与传统 LLMs 能力的创新性框架, 其核心价值在于打破模型参数内置的静态数据与现实世界中持续更新的动态信息之间的壁垒, 在运行中将内部数据库中的相关信息与外部信息相结合, 并最终依托 LLMs 完成内容的生成。目前, RAG 系统已在多个知识密集领域展现出卓越性能。在开放域问答领域, RAG 通过外部信息检索弥补模型未覆盖的细分知识, 进而避免生成内容的偏差^[1]; 同时, 通过整合场景化语料能够让交互内容更贴合具体需求, 减少通用 LLMs 系统中经常出现的回答不相关的问题^[2]; 在医疗决策支持场景中, 通过整合最新病例数据或开源临床指南等专业资源, 为诊断建议和治疗方案提供更为精准和定制化依据^[3]。相对于传统大模型, RAG 系统既能够保留其在语言组织和逻辑推导上的核心优势, 又整合外部数据库, 以解决模型在知识时效性、领域专属度上的短板。因此, 在对回

答准确性有严格要求, 或需要关联特定领域知识及动态信息更新的场景中, RAG 已成为一项关键的技术支撑。

然而, RAG 技术在增强传统 LLMs 的同时, 其推广与应用也引发了严峻的隐私挑战。从 RAG 系统全流程构建角度出发, 该框架涉及检索-生成两个关键的隐私敏感环节。在检索阶段, RAG 系统依赖的语料库可能包含个人信息、医疗记录或其他用户未授权披露的专有敏感信息, 这些信息的存储与检索不当, 往往会造成隐私泄露。在生成阶段, 传统 LLMs 的输出可能在无意中泄露检索上下文或模型内部参数中的隐私细节, 例如, 在医疗应用中 RAG 系统通过处理患者电子健康记录生成诊断决策时, 如果在生成过程中遭遇安全攻击, 例如成员推断攻击或者提示词诱导攻击等, 那么患者的隐私将面临直接暴露风险^[4,5]。在法律或金融等其他信息私密性要求较高的领域, 检索阶段对敏感信息的不当保存、攻击者的诱导性查询, 以及生成阶段对个人或商业机密等敏感信息的偏见输出, 都会对相关个人或组织造成重大威胁^[6]。

收稿日期: 2025-09-01; **修回日期:** 2025-11-13 **基金项目:** 国家自然科学基金资助项目(72401110); 2023 年江苏高校“青蓝工程”优秀青年骨干教师项目; 江苏省高等教育教改研究项目(2023JSJG364); 江苏省高校哲学社会科学研究项目(2023SJJYB0468)

作者简介: 刘晓迁(1989—), 女(通信作者), 河北保定人, 讲师, 博士, 主要研究方向为警务大数据、隐私保护(lxqlara@163.com); 袁明(1989—), 男, 江苏盐城人, 讲师, 博士研究生, 主要研究方向为自然语言处理; 钱汉伟(1984—), 男, 江苏扬州人, 高级工程师, 博士研究生, 主要研究方向为信息安全、软件工程; 高光亮(1989—), 男, 山东潍坊人, 讲师, 博士, 主要研究方向为数据挖掘、复杂网络分析; 王群(1971—), 男, 甘肃天水人, 教授, 博士, 主要研究方向为信息安全、计算机网络体系结构与协议。

近年来,研究者针对 RAG 系统的隐私保护技术研究取得了丰硕的成果^[7]。其中,通过差分隐私(Differential Privacy, DP)对检索嵌入或生成输出添加可控噪声,能够有效缓解成员推理攻击风险^[8]。然而,DP 尤其需要注意隐私与效用之间平衡,过大的随机扰动往往导致检索内容的相关性下降或生成文本的流畅性受损,尤其是在医疗、金融等高风险的精准信息需求场景中。联邦学习(Federated Learning, FL)基于去中心化的系统架构,也能用于训练 RAG 模型^[9]。但联邦学习较难处理非独立同分布数据,并且在 RAG 系统的检索阶段,通常还是集中化的语料库查询,导致隐私风险不能得到有效的解决。从输入数据源头出发,基于合成数据的隐私保护技术能够确保原始数据不被泄露,但是生成数据会导致检索内容的语义一致性降低,或者导致生成的结果领域适配性不足,极大地限制了其在数据真实性要求严格的医疗诊断、金融风控等场景中的应用与推广。此外,加密技术能够在 RAG 系统的检索和生成阶段提供可靠和严格的数据保护,但其计算密集性的特点也会导致实际部署的难度,进而在 LLMs 的实际构建中应用有限^[10]。

值得注意的是,部分研究工作主要聚焦于孤立阶段的隐私保护,即只关注 RAG 系统的检索环节或生成环节,较少有端到端的系统性方案,这种碎片化方法易招致隐私安全攻击。文献[11]指出,即使检索阶段实现隐私保护,生成模型仍可能通过训练数据记忆泄露敏感模式。隐私性与效用性的权衡,是隐私保护 RAG 系统构建中需要同时考虑的维度,不仅要考虑隐私数据的安全性,同时要保证检索的精确度、相关性,并与事实保持一致。

RAG 系统的隐私保护技术研究,具有重要的应用价值和现实意义,对该类技术的完整性、适配性及实际效能进行系统且全面的综述具有重要研究意义。本文针对 RAG 系统的原理、应用场景与隐私风险进行梳理,并基于此阐明 RAG 系统隐私保护技术的发展脉络、明确现存瓶颈,为后续针对性技术突破提供方向指引,从而在推动 RAG 安全应用的同时,为平衡技术创新与隐私保护的研究提供有力参考。

1 RAG 理论基础与隐私风险分析

1.1 RAG 系统原理简介

RAG 系统的提出,源于对传统大型语言模型局限性的针对性突破。传统 LLMs 存在多方面的局限性,最主要的问题是存在知识截止点,受限于训练数据的时间范围,难以获取

最新信息;此外,容易出现幻觉(Hallucination)问题,可能生成看似合理实则错误的内容;其三体现为领域专业性不足,对于特定领域的深度知识掌握较为有限;此外,还存在个性化缺失的问题,无法依托用户的个人知识库来提供回答。

RAG 系统通过检索外部数据库,将外部知识的时效性、专业性等特征,整合传统 LLMs 的生成能力,弥补以上提到的诸多问题。顾名思义,检索增强生成(RAG)是一种融合信息检索与生成式人工智能的技术架构,通过将语言模型与外部知识检索相结合,显著提升自然语言处理任务的准确性与可靠性。相较于传统大型语言模型,RAG 系统在多个维度展现出明显优势。具体而言,RAG 系统从外部知识库检索最新信息,解决知识过时问题,确保内容时效性,并保持系统知识的持续更新;基于权威数据源进行交叉验证,依赖外部知识库验证信息减少模型的幻觉,提升生成内容的可信度与准确性,同时返回检索到的相关文档作为依据,增强回答透明度与说服力;支持本地化检索与隐私保护技术,降低敏感信息泄露的风险;针对不同领域定制知识库,提升领域性权威解答能力,更适合特定领域的专业应用。

作为融合检索与生成能力的前沿范式,RAG 系统的核心工作机理体现为检索-生成两阶段的协同,具体涵盖离线的知识库构建与实时的查询响应。在知识库构建阶段,需先收集并预处理各类格式文档,清理无关内容、标准化文本后,将长文档合理分块,同时为文本块添加元数据以保障语义完整,再通过嵌入模型将文本块转换为能捕捉语义信息的高维向量,最终存入向量数据库。而在查询响应阶段,系统先将用户问题经嵌入模型转为向量,依托余弦相似度或欧氏距离等方式,在向量数据库中借助 BM25、密集检索等算法检索最相关文档块^[1]。近年来,RAG 系统的检索机制已从简单的检索后读取模式,演进为包含查询重写等预处理、重排序等后处理,以及多轮迭代检索等的进阶模式,检索结果的相关性与针对性持续提升。整合检索内容上下文与用户问题共同构建提示词,交由大语言模型生成基于事实的准确回答。在生成阶段,借助提示工程、联合训练等技术,系统能有效融合内部知识与外部检索信息,减少传统生成模型的幻觉问题,在开放域问答、长文本生成等任务中生成更符合事实和更可靠的答案。RAG 系统的模块化设计能够支持模型动态调整检索策略,在复杂推理任务中平衡信息充分性与生成效率,为医疗、金融、教育等诸多领域提供优质高效服务,应用潜力巨大。相较于传统大语言模型而言,RAG 系统有效解决了表 1 所示的诸多问题。

表 1 RAG 相较于传统 LLMs 的诸多优势
Tab. 1 Advantages of RAG compared to traditional llms

传统 LLMs	RAG	原理说明	优势
知识过时	从外部知识库检索最新信息	RAG 在生成前会从实时数据库或知识图谱中检索相关数据,确保内容的时效性。	提供最新、准确的信息
信息不准确	利用权威来源验证答案	RAG 可以结合多个可靠来源进行交叉验证,减少错误信息的输出。	提高回答可信度和准确性
缺乏可解释性	返回检索到的相关文档作为依据	RAG 可以在回答中引用具体来源,如文章、网页链接等,增强透明度。	回答更具说服力,便于验证
隐私风险高	支持本地化检索与隐私保护技术	RAG 可以在本地设备上进行搜索,避免用户数据上传至云端。	减少敏感信息泄露风险
无法处理多模态数据	支持文本、图像、表格等多种数据源	RAG 能够整合多种类型的数据,并通过检索机制提取相关信息。	更加灵活和全面,适应复杂任务
模型幻觉	依赖外部知识库验证信息	RAG 通过检索机制获取真实信息,减少模型凭空编造内容的可能性。	提高生成内容的真实性 and 可靠性
无法动态更新知识	实时接入知识库	RAG 可以定期更新检索库,使系统能够适应新知识和变化。	保持系统知识的持续更新
对特定领域知识支持不足	检索专业领域的知识库	RAG 可以针对不同领域(如医疗、法律、金融)定制知识库,提升专业性。	更适合行业应用,提高专业解答能力

1.2 RAG 系统常见应用场景

RAG 系统凭借检索与生成的协同优势, 在人工智能生成领域得到了广泛的应用, 产业界相关的工具与平台也不断推陈出新。这些技术的应用涵盖诸如 LangChain、LlamaIndex 等

的开源开发框架, 也包含智能问答、个性化推荐、知识管理等多个领域在内的专业性工具或平台。它们在各自场景中发挥着独特作用, 也呈现出不同的优劣势。RAG 系统常见应用场景及优缺点参见表 2 所示。

表 2 RAG 系统常见应用场景
Tab. 2 Common application scenarios of RAG systems

应用场景	工具/平台	应用描述	优点	缺点
智能问答系统	Qwen, Chatbot, Bing Chat, Rasa	用户提问后, 从知识库中检索信息并生成回答	提高答案准确性, 减少模型幻觉	需要高质量知识库支持, 实时检索性能要求高
推荐系统	Alibaba Cloud AI, Amazon Personalize, Baidu AI	基于用户行为和偏好, 结合外部数据生成推荐内容	提升推荐解释性, 增强用户信任	数据整合复杂, 个性化推荐需大量训练
知识管理与文档分析	Notion AI, Google Docs AI, Microsoft Copilot	从海量文档中检索关键信息, 辅助生成摘要、报告等	提高工作效率, 支持多模态数据处理	对文档结构依赖性强, 检索精度要求高
医疗健康领域	IBM Watson Health, Med-PaLM, DeepMind	医疗问答、疾病诊断建议、药物信息检索	信息权威性高, 提升诊疗质量	数据隐私风险大, 对医学专业性要求高
金融与风控系统	JPMorgan COIN, Riskalyze	金融问答、合规审查、风险评估	提高决策准确性和合规性	数据敏感性高, 技术门槛较高
教育与学习辅助	Khan Academy AI, Duolingo, MathBot	学生提问后, 从教学资料中检索知识点并生成解答	提供个性化学习建议, 提升学习效率	需要丰富的教育资源支持
新闻与媒体内容生成	NewsGPT, AI News Writer, Reuters AI	自动生成新闻标题、摘要或全文	提高内容生产效率, 支持多语言	内容真实性需人工审核, 易受数据偏见影响
法律与合规审查	LexisNexis AI, Westlaw AI, LegalSifter	法律条文检索、案例分析、合同审查	提高法律事务处理效率	法律术语复杂, 对模型理解能力要求高

RAG 系统开发与研究的火热, 以及其在众多专业领域展现出的强大实用价值, 推动了各类研究与平台的落地。然而, 在 RAG 全流程的数据存储与使用过程, 存在广泛的隐私泄露风险。专业应用场景往往涉及大量数据交互, 例如在智能问答中, 知识库本身存储有大量的敏感信息, 在医疗和金融领域等, 患病信息或商业机密的泄露, 都将引发巨大的法律和道德争议。因而, RAG 系统的隐私保护逐渐成为研究者不可忽视的关键问题, 深入剖析 RAG 系统中的隐私风险具有重要的现实意义。

1.3 RAG 系统中的隐私风险分析

在人工智能领域, 隐私保护关乎个人数据、身份机密以及尊严维护, 随着大语言模型广泛应用, RAG 系统的隐私风险广受关注^[12]。RAG 系统通过融合外部检索数据库提升文本生成质量, 但其独特架构招致了多元隐私风险。在检索阶段, 医疗、个人记录等往往包含敏感信息, 攻击者通过针对性或诱导性查询, 如构造与特定疾病关联的检索指令, 往往能够获取患者处方、私人医疗档案等内容, 进而导致敏感信息泄露, 引发争议。

1.3.1 隐私定义

在人工智能领域, 隐私作为保护个人数据、维护身份机密与尊严的核心概念, 在 LLMs 的广泛应用中愈发凸显其重要性。LLMs 因训练数据可能包含敏感信息, 存在无意泄露或被恶意提取的风险, RAG 系统在融合 LLMs 与外部检索数据库以提升生成质量的同时, 其隐私内涵被赋予了更具体的场景化定义。

RAG 系统的隐私特指在检索-生成全流程中, 对涉及的敏感信息, 包括检索数据库中的领域特定数据、LLMs 训练/微调数据中的私人信息等进行保护, 确保其不被未经授权访问、泄露或滥用, 同时保障用户身份不被非法识别、数据尊严不受侵犯的状态。由于 RAG 架构中外部知识库与 LLMs 的交

互特性, 其隐私保护面临独特挑战, 攻击者可能利用系统设计漏洞实施针对性攻击。

针对 RAG 系统隐私风险, 研究人员已开展攻击方法探索, 黑盒场景下, 攻击者通过精心设计提示, 能够从检索数据库中提取隐私信息。RAG 系统的隐私保护研究意义重大, 一方面, 精准揭示 RAG 系统的隐私漏洞, 为发现 RAG 系统应用中的隐私风险提供实证依据; 另一方面, 倒逼 RAG 系统设计与部署环节重视隐私保护, 推动学界和产业界深入研究隐私攻防策略、评估现有防护手段, 助力构建更安全的 RAG 应用生态, 保障用户数据隐私与合法权益^[13]。

1.3.2 代表性隐私攻击风险

RAG 系统在便捷整合与运用信息的同时, 面临着多种代表性的隐私攻击风险, 相关研究已对这些风险展开了多维度探索。其中, 成员推断攻击是不容忽视的一类。LLMs 与 RAG 系统依赖海量多源数据进行训练, 其中往往包含个人身份、疾病记录、个人薪资等敏感信息, 大模型的记忆机制, 使得其极易受到诱导查询攻击进而泄露隐私。而 RAG 系统在引入外部数据库的同时, 由于数据本身的保管问题, 也容易引发二次泄露。Carlini 等人通过黑盒攻击成功从私有训练数据中提取出个人身份信息^[14]。Anderson 等人针对 RAG 系统检索数据库进行成员推断攻击, 在黑盒和灰盒两种模式下通过精心设计提示进而判断特定文本是否在检索数据库中^[15]。Li 等人则基于给定样本与 RAG 系统生成内容之间的语义相似性, 推断该样本是否存在于 RAG 系统的外部数据库^[16]。Jiang 等人提出的 RAG-Thief 是一种基于代理的自动化隐私攻击方法, 旨在从 RAG 应用的私有知识库中规模化提取敏感数据^[17]。与依赖手动提示注入的传统攻击不同, 该方法通过初始对抗性查询启动攻击, 利用模型响应提取文本片段并存储于记忆模块, 再通过反射机制分析已提取内容, 生成新的针对性查询以迭代扩展提取范围。其核心在于利用 LLMs 的推理能力, 基于

已有片段推断上下文, 进而生成融合锚点查询与对抗性命令的新攻击指令。

从 RAG 系统的检索-生成架构角度出发, RAG 系统中的隐私泄露风险也可以从两个角度进行分析, 即检索阶段是否能够从外部数据库中提取私有信息; 在生成阶段检索数据是否引发 LLMs 对训练数据的记忆或泄露^[4]。在检索阶段, 通过精心设计结构化查询语句, 例如“张三的疾病病例”, 诱导系统泄露个体敏感信息, 并且隐私泄露成功几率较高^[18]。Wang 等人设计了隐式知识提取攻击(Implicit Knowledge Extraction Attack, IKEA), 通过锚定概念伪装良性查询, 迭代地构造间接的、具有隐蔽性的查询, 进而发现 RAG 系统中的隐私信息^[19]。此外, 由于内部数据处理不当, 例如一些领域性较强的数据, 包含内部文件、个人数据、医疗记录等, 在检索过程中也存在隐私泄露风险^[20,21]。在生成阶段, 传统 LLMs 存在记忆并泄露其预训练和微调数据中个人信息的现象^[14], 后续研究进一步发现, 模型大小、数据重复、提示长度等因素会增加这种记忆风险^[22,23]。Miresghallah 等人发现大型语言模型的微调阶段存在显著的训练数据记忆隐私风险, 且不同微调方法的攻击易感性差异明显^[24]。Zeng 等人的工作分析了微调阶段 LLMs 的记忆现象, 发现不同微调任务中的记忆现象存在明显差异, 进而影响隐私安全的保障^[25]。

在 RAG 系统中, 由于外部检索数据的引入, 往往进一步增加获取训练数据中隐私信息的可能。然而文献[4]中的结果显示, 相较于直接使用 LLMs, RAG 系统的检索结果相对更不容易泄露隐私信息。举例来说, 直接使用 LLMs 检索“糖尿病患者用药”, 模型更依赖于记忆而返回其训练数据中某个个体的真实病例, 进而造成该患者患病隐私的泄露。而在 RAG 系统中, 检索结果则更倾向于公开的糖尿病防治指南,

有效避免了训练数据中的敏感信息泄露。

Kandpal 等人的工作强调 LLMs 中重复数据对隐私泄露的影响, 通过去重能够显著降低隐私攻击的影响程度^[26]。Lee 等人开发的数据去重工具有效降低了模型生成记忆文本的频率, 进而降低了因重复样本带来的隐私风险^[27]。

除此之外, 还有其他形式的隐私攻击。Zou 等人提出了一种知识投毒攻击方法 PoisonedRAG, 攻击者通过向知识库中注入少量“有毒文本”, 导致 LLMs 通过 RAG 生成攻击者期望的输出^[28]。Chaudhari 等人提出了一个两步攻击框架 Phantom, 首先攻击者创建一个仅在受害者查询中存在特定对抗性触发器时才会被 RAG 系统检索到的有毒文档, 然后在有毒文档中精心构造对抗性字符串, 以在生成器中触发包括隐私侵犯在内的各种对抗性攻击^[29]。Pasquini 等人提出了 Neural Exec 提示注入攻击方法, 将执行触发器的创建视为一个可微分的搜索问题, 并基于学习方法自动生成触发器, 与依赖手动设计的传统攻击不同, 攻击者可以生成与已知攻击有显著差异的触发器, 从而规避现有的基于黑名单的检测和清理方法^[30]。Cheng 等人提出的 TrojanRAG 利用 RAG 中的后门攻击, 在通用攻击场景中操纵 LLMs 的性能, 通过精心设计的目标上下文与触发器集, 借助对比学习优化多个后门捷径以改善匹配条件, 将触发器条件限制在参数子空间内, 还从攻击者和用户的角度分析了 LLMs 中后门攻击的实际危害, 并进一步验证了上下文是越狱模型的有效工具^[31]; Xue 等人提出的 BadRAG 通过向 RAG 数据库中注入特定内容来实施检索后门攻击, 这些段落正常查询下表现良好, 但在特定条件被触发时会返回定制的恶意查询^[32]。

表 3 从模型核心特点、攻击目标、技术手段与防御难点等维度针对 RAG 系统隐私攻击模型进行系统性归纳与对比。

表 3 RAG 系统隐私攻击模型对比
Tab. 3 Comparison of privacy attack models in RAG systems

攻击类型	核心特点	攻击目标	技术手段	典型研究	防御难点
成员推断攻击	黑盒/灰盒场景均可实施, 通过语义相似性判断样本是否在检索库中	检索数据库中的敏感文本(如医疗记录)	设计针对性提示 ^[15] 、计算生成内容与样本的语义相似度 ^[16]	Anderson 等人 ^[15] 、Li 等人 ^[16]	需平衡检索相关性与隐私保护, 噪声注入易降低效用 ^[33]
隐式知识提取攻击	伪装良性查询, 迭代获取隐私信息, 规避系统防御机制	检索库/训练数据中的敏感信息	锚定概念设计间接查询 ^[19] 、多轮对话积累上下文 ^[17]	Wang 等人 ^[19] 、Jiang 等人 ^[17]	攻击意图隐蔽, 传统关键词过滤失效, 需动态监测查询序列 ^[19]
知识投毒攻击	向知识库注入“有毒文本”, 诱导 LLMs 生成错误/隐私泄露内容	RAG 系统的生成可靠性与隐私性	植入触发式有毒文档 ^[29] 、构造对抗性字符串 ^[28]	Zou 等人 ^[28] 、Chaudhari 等人 ^[29]	需检测低比例投毒样本, 对检索器的异常检测能力要求高 ^[28]
提示注入攻击	生成对抗性触发器, 绕过安全机制获取隐私信息	LLMs 生成阶段的敏感输出	自动生成可微分触发器 ^[30] 、利用上下文越狱模型 ^[31]	Pasquini 等人 ^[30] 、Cheng 等人 ^[31]	触发器多样性高, 黑名单机制难以覆盖, 需结合语义分析 ^[30]
后门攻击	预设触发条件, 特定查询下返回恶意/隐私内容	RAG 系统的检索-生成链路	注入带后门的文档片段 ^[32] 、优化后门捷径匹配条件 ^[31]	Xue 等人 ^[32] 、Cheng 等人 ^[31]	正常查询下无异常, 需在检索阶段检测后门文档的隐蔽关联 ^[32]

以上研究展示了 RAG 系统在处理敏感信息时面临的重大隐私风险和安全挑战。其中, 成员推断攻击、知识提取、提示词攻击广泛存在, 引发个人敏感信息的泄露。同时, 知识投毒等攻击, 通过诱导攻击者期望的输出进而损害 RAG 系统的性能。这些攻击不仅揭示了数据存储策略与模型推导过程的不足, 更凸显出在设计和部署 RAG 系统时, 加强模型安全和隐私保护的重要性。

1.4 论文主要贡献

本文对 RAG 隐私保护技术进行系统性研究, 相较于现有研究在隐私保护技术的单一性^[6,7]和攻击场景的孤立性^[12, 13]等方面的不足, 针对 RAG 系统检索-生成全流程的隐私风险与防护技术进行整合分析。明确 RAG 系统隐私定义, 即检索-生

成全流程敏感信息不被泄露、滥用, 或未经授权访问^[13], 并基于攻防对应关系, 将隐私保护技术归类为差分隐私、联邦学习、合成数据、加密技术四大核心路径, 构建了 RAG 隐私保护的理論分析框架。

综合隐私保护技术的适用场景、隐私强度、效用损失、部署成本等多个维度, 对现有技术进行清晰化对比与分析。例如在差分隐私领域, 系统对比 DP-RAG^[33]、DPsparseVoteRAG^[34]、PAD^[35]的隐私预算分配策略与阶段适配性; 此外, 亦有研究通过裁剪 logits 差异^[36]、扰动私有实体^[37]或随机投影嵌入^[38], 乃至利用 k 近邻检索机制增强模型对长上下文的理解^[39]等差异化手段, 在检索与生成阶段为长文本或敏感记录提供更具效用的隐私保护。在联邦学习领域,

厘清 C-FedRAG^[40]、Federated MAS^[41]、FedE4RAG^[42]在分布式协作中的技术差异;同时,针对医疗等高隐私场景,联邦学习与加密技术的融合为临床决策系统提供了新思路^[43]。在合成数据技术路径上,ITER-RETGEN 的迭代优化机制^[44]、SAGE 框架的代理精炼方法^[45]与基于 LLMs 的属性化生成研究^[46],共同形成了免于真实数据暴露的隐私保护新范式。在加密技术路径上,SecureRAG^[47]揭示了全同态加密的部署效率瓶颈,为隐私保护方案的技术选型提供了关键量化依据。

细分 RAG 系统隐私保护技术的应用场景,结合医疗、金融等场景的实际需求,明确不同技术的适配边界。例如,医

疗场景中患者数据隐私需求高,推荐采用基于联邦学习整合加密技术的临床决策系统^[43];金融场景则建议优先基于差分隐私^[37]的扰动方案或基于合成数据^[45]的属性化生成,进而兼顾检索精度与隐私性。此外,本文提出的隐私-效用-公平性协同目标,为后续 RAG 在合规场景,如符合 GDPR、HIPAA 的部署提供了方向。

1.5 相关工作综述

表 4 对现有 RAG 系统隐私保护研究进行系统分类,从技术路径、研究焦点与场景适配三个维度,明确本文与现有工作的侧重点。

表 4 现有 RAG 隐私保护研究的系统分类与本文侧重点对比

Tab. 4 A systematic taxonomy of RAG privacy protection research and a comparison with the focus of this paper					
分类维度	子类别	代表研究	研究焦点	局限性	本文定位
技术路径	差分隐私	Grislain ^[33] 、Koga 等人 ^[34] 、Wang 等人 ^[35]	隐私预算分配、噪声注入策略优化	多聚焦单一阶段,如仅生成阶段 ^[35] ,未考虑检索-生成协同	整合多阶段方案,对比不同预算策略适配性
	联邦学习	Chakraborty 等人 ^[9] 、Addison 等人 ^[40] 、Shi 等人 ^[41]	分布式检索优化、多节点协同机制	未解决检索阶段集中化风险 ^[9] ,公平性考虑不足	补充跨节点索引同步方案,纳入公平性目标
	合成数据	Zeng 等人 ^[45] 、Yu 等人 ^[46]	合成数据效用提升、属性保留策略	缺乏隐私量化保证,领域适配性差 ^[45]	明确合成数据在敏感领域的适用边界,提出反馈优化机制
	加密技术	Anonymous ^[47] 、Zhou ^[48] 、Bae 等人 ^[49]	全生命周期加密、密文域检索效率	计算开销大,动态更新难 ^[48]	探索轻量级加密组合方案,平衡安全与效率
研究焦点	攻击导向	Anderson 等人 ^[15] 、Jiang 等人 ^[17] 、Zou 等人 ^[28]	攻击方法设计、攻击效果验证	未提出针对性防御方案,多关注单一攻击类型	结合攻击特点设计防护策略,形成攻击-防护对应关系
	防护导向	Grislain ^[33] 、Anonymous ^[47] 、Mao 等人 ^[42]	防护技术创新、隐私-效用平衡	缺乏对攻击场景的适配性分析,评估指标单一	多维度评估技术在不同攻击场景下的表现
场景适配	通用场景	Golda 等人 ^[6] 、Panda 等人 ^[10]	技术通用性验证、理论框架构建	未考虑敏感领域的特殊需求,如医疗合规 ^[43]	聚焦医疗、金融等敏感场景,提供定制化策略
	特定场景	Karamanlioglu 等人 ^[43]	场景化技术优化、合规性适配	技术路径单一,如仅联邦学习 ^[43] ,缺乏多技术组合	提出场景优先的技术组合方案,满足合规要求

现有研究成果为推进隐私保护 RAG 系统构建做出了巨大贡献,然而,这些研究多为单点突破,如 PAD^[35]仅优化生成阶段解码防护,无法应对跨阶段攻击,如知识投毒^[28]。本文通过构建检索-生成全流程防护框架,将四大技术路径按“攻击类型-场景需求”匹配,解决了现有研究的防护缺口。例如,针对隐式知识提取攻击^[19],提出联邦检索(防数据泄露)+差分生成(防输出泄露)的组合方案,弥补单一技术的防御短板。

此外,现有研究多采用单一指标评估,如差分隐私用 ϵ 值^[34]、联邦学习用准确率^[42],无法横向对比技术优劣,无法判断 SecureRAG^[47]与 DP-RAG^[33]在医疗场景中的综合表现。本文建立隐私强度-效用损失-部署成本-公平性四维度评估体系,为技术选型提供量化依据,解决现有评估不可比问题。

现有研究多基于公开数据集进行验证,缺乏敏感领域的实际测试。例如,SAGE^[45]的合成数据未在真实医疗数据上验证诊断准确率,FedE4RAG^[42]未考虑金融场景的实时性需求。本文结合医疗、金融等场景的合规要求,如 GDPR、HIPAA 等,明确技术的部署边界。本文指出加密技术在高频交易场景中的延迟瓶颈,推荐高效的差分隐私作为替代方案;同时提出合成数据在政务场景中的属性脱敏-权限追溯协同策略,解决现有方案标准化不足的问题。

2 RAG 系统中的隐私保护技术

为应对 RAG 系统所面临的多元隐私攻击风险,切实筑

牢用户隐私与数据安全防线,一系列隐私保护技术被逐步应用于 RAG 系统的设计与优化中,形成了多维度的隐私保护体系。其中,差分隐私技术通过在检索嵌入或生成输出中添加可控噪声,在平衡隐私保护与系统效用的前提下,有效缓解了成员推理等攻击的风险;联邦学习框架下的隐私保护 RAG,则借助去中心化的训练模式,在不共享原始数据的情况下实现多节点协同优化,降低了敏感数据泄露的风险;基于合成数据的隐私保护方案从数据源头出发,通过生成与真实数据分布相似但不含真实敏感信息的合成数据构建知识库,进而杜绝用户隐私信息泄露的可能;而加密技术通过对数据存储与通信进行加密,在确保数据机密性的同时维持检索-生成链路的完整性,有效防范了隐私泄露风险。这些技术路径各有侧重又相辅相成,共同为 RAG 系统的隐私防护提供了重要支撑。图 1 归纳了 RAG 系统检索-生成全流程的攻击风险与防御技术对应关系。其中红色线框代表攻击模型,绿色线框代表防御技术,攻击模型与防御技术被应用于 RAG 系统检索-生成流程的不同阶段。

2.1 差分隐私在 RAG 中的应用

差分隐私通过向数据或查询结果添加可控噪声来掩盖特定个体数据的贡献,确保特定个体存在与否并不会显著影响查询的输出结果。在差分隐私保护的 RAG 系统构建中,检索阶段通过对查询嵌入添加噪声,防止攻击者通过检索结果反推用户原始查询。生成阶段对输出的文本进行隐私约束,避免泄露原始训练数据中的敏感信息。差分隐私的优势在于提

供强大隐私保护理论保证的同时, 保持数据分析的有效性。然而, 添加的噪声可能降低模型的准确性, 尤其是在处理小型数据集或细粒度分析时。

Grislain 提出了 DP-RAG 框架, 其核心是通过差分隐私技术解决 RAG 系统中敏感文档的隐私泄露问题^[33]。具体围绕两个关键组件构建, 一是以不阻碍后续差分隐私机制应用的方式检索与查询相关的文档, 二是利用检索到的文档提示 LLMs 生成具有差分隐私保障的响应。在文档检索阶段, DP-RAG 将每个文档关联到唯一的隐私单元, 通过指数机制设计

效用函数采样阈值 τ , 确保检索到的文档满足差分隐私。在差分隐私上下文学习阶段, DP-RAG 不为多个文档构建单一增强查询, 而是为每个检索到的文档生成单独的增强查询, 同时计算公共上下文的 token 分布。通过对各查询的 log 概率向量进行剪辑和中心化处理, 结合公共先验的 log 概率构建效用函数, 再通过指数机制聚合这些分布生成下一个 token, 既保证隐私, 又确保生成内容的相关性。在医疗合成数据集上验证, 当至少 100 个文档包含相似信息时, 准确性较高, 适合文档按隐私单元组织的场景, 例如电子病历、财务记录等。




图 1 RAG 系统检索-生成全流程攻击风险与防御技术对应关系

Fig. 1 Attack risks and corresponding defense techniques across the retrieval-generation pipeline in RAG systems

Koga 等人探讨了如何在 RAG 系统中引入差分隐私机制, 以保护用户查询和检索内容的隐私, 保证系统的设计与部署符合隐私法规和数据伦理的要求^[34]。该文强调由于 RAG 系统依赖外部知识库进行信息检索, 其中可能包含用户的敏感信息, 因此需要采取严格的隐私保护措施。该工作提出了基于差分隐私的检索增强生成算法 DPSParseVoteRAG, 旨在为敏感外部语料的隐私保护提供保障, 同时平衡回答的准确性与长度。该研究的核心挑战在于如何在合理的隐私预算内, 使 RAG 系统生成较长且准确的回答。

另一项聚焦于 RAG 系统解码阶段隐私保护的工作是 (Privacy-Aware Decoding, PAD) 框架^[35], 其针对 RAG 生成阶段可能存在的敏感信息泄露问题, 即尽管检索阶段采取了隐私保护措施, 贪婪解码等策略仍可能导致敏感内容被直接输出。该文献提出了一种轻量级、推理时的防御机制, 通过自适应注入校准高斯噪声到 token logits 中, 在不修改检索器或 LLMs 的情况下, 实现隐私与生成质量的平衡。

横向对比, DP-RAG 覆盖检索到生成的全流程, 适合文档按个人组织且数量充足的场景, 提供严格的全流程差分隐私保证; DPSParseVoteRAG 优化隐私预算分配, 通过稀疏向量技术生成文本, 适合中等预算下的长文本输出需求; PAD 聚焦解码阶段的轻量级防御, 无需修改检索或重训练模型, 适合快速部署于现有 RAG 系统, 重点解决解码时的逐字泄露问题。三者共同构成了差分隐私保护 RAG 的多场景解决方案, 分别在全流程保护、长文本生成、轻量部署上形成互补, 如表 5 所示。

此外, 针对 RAG 系统中长文本生成差分隐私保护的另

一项重要工作是 INVISIBLEINK 框架^[36], 其核心目标是在提供严格差分隐私保证的同时, 实现高实用性和低计算成本的长文本生成, 尤其适用于检索增强生成等需要处理敏感信息的场景。INVISIBLEINK 通过 DClip 隔离敏感文档带来的 logits 差异, 仅对差异部分裁剪, 确保单个敏感文档的增减不

会显著影响生成分布, 满足差分隐私的输出不可区分要求。与前述工作相比, INVISIBLEINK 进一步优化了隐私-效用-计算成本的平衡。相较于 DPSParseVoteRAG, 其通过针对性剪辑和截断采样减少了不必要的隐私消耗; 相比 DP-RAG, 其在长文本生成场景中更高效; 而相较于 PAD 聚焦解码阶段的噪声注入, INVISIBLEINK 则从 logits 处理和词汇选择层面实现了更精细的隐私控制, 为 RAG 系统中敏感长文本生成提供了更实用的解决方案。

表 5 差分隐私保护 RAG 系统主要工作对比

Tab. 5 Comparison of the main works of differential privacy

protection RAG system			
对比维度	DP-RAG	DPSParseVoteRAG	PAD
隐私保护阶段	检索+生成	检索+生成	生成, 即仅解码阶段
核心技术	指数机制选文档+token 分布聚合	样本-聚合投票+稀疏向量技术	自适应高斯噪声注入
隐私预算管理	聚合检索与生成阶段预算	按需花费 (仅敏感 token 消耗预算)	跟踪累积损失, 聚焦高风险 token
适用场景	文档按隐私单元组织, 且数量充足	需要长文本输出, 中等隐私预算 ($\epsilon \approx 10$)	任何 RAG 系统, 解码阶段泄露风险高
关键优势	全流程 DP 保证, 适配隐私单元文档	生成更长答案, 预算利用更高效	轻量级, 无需重训练, 聚焦解码漏洞

He 等人基于本地差分隐私设计了 (Locally Private Retrieval-Augmented Generation, LPRAG) 框架^[37], 通过对文本中的私有实体而非整个文本进行本地差分隐私扰动, 在提供正式隐私保证的同时平衡隐私与效用。LPRAG 的工作流程主要包括三个阶段。第一步识别文本中包含的各类私有实体, 如单词、数字、短语等, 例如医疗场景中的患者姓名、诊断数据等; 第二步基于自适应隐私预算分配策略, 为不同类型的实体分配相应的隐私预算, 并针对单词、数字、短语等不同实体类型设计专属的本地差分隐私扰动机制; 最后, RAG

系统利用经过扰动的文本增强 LLMs 的响应生成。这种针对实体级别的精准扰动, 避免了对整个文本进行处理导致的信息失真, 同时通过自适应预算分配确保高敏感实体获得更强的隐私保护。

Yao 和 Li 提出了一种基于随机投影的差分隐私保护方法, 旨在解决 RAG 系统中敏感信息在检索数据库中泄露的风险^[38]。该方法通过高斯矩阵将查询和数据存储库投影到低维空间, 在保留检索所需相似度的同时, 对记录嵌入值进行扰动, 使攻击者难以提取原始敏感信息。具体而言, 先利用预训练语言模型对文档进行编码, 再通过随机生成的高斯矩阵对嵌入向量进行投影, 并对查询采用相同投影操作以维持相似度计算。该机制适用于 KNN-LM^[39]和直接提示式 RAG 两种架构, 能够在不显著影响生成性能的前提下实现记录级差分隐私。

差分隐私技术为 RAG 系统的隐私保护提供了从检索到生成的全流程解决方案, 无论是通过智能分配隐私预算、聚焦解码阶段的自适应噪声注入, 还是优化 logit 处理与词汇选择以平衡成本与效用, 努力维持系统的响应质量与效率, 尤其适用于集中式或对生成结果隐私敏感度要求极高的场景。然而, 当 RAG 系统涉及多源分布式数据, 如跨机构医疗数据协作、多企业知识库联合查询等场景时, 数据难以集中处理的特性使得差分隐私的应用面临挑战, 既需避免原始数据泄露, 又需实现多节点的协同检索与生成。为此, 联邦学习框架下的隐私保护 RAG 应运而生, 其核心思路是在去中心化的数据架构中, 通过本地模型训练与参数聚合替代原始数据共享, 从而在保护各参与方数据隐私的前提下, 实现跨域知识的协同利用。

2.2 联邦学习框架下的隐私保护 RAG

联邦学习是一种允许模型在多个分散的设备或持有本地数据样本的服务器上训练, 而无需交换数据本身的技术。基于联邦学习, 协作机构数据保留在本地设备上, 因而无需共享敏感数据, 这种方法有助于保护数据隐私, 同时利用多元数据提高模型准确性。然而, 实施联邦学习需要强大的基础设施建设, 并整合参与协作实体之间的协调, 确保不同环境下模型性能的一致性。

联邦学习在数据隐私保护上的突出优势及其在跨实体协作中对敏感数据的妥善保护能力, 使其成为了处理隐私敏感场景下数据应用的重要技术支撑。而在实际的业务场景中, 无论是企业内部的知识检索, 还是跨机构的信息协同, 往往需要基于大量非结构化数据进行高效的检索与生成式交互, 这就使得 RAG 技术的应用需求日益凸显。传统 RAG 在处理敏感数据时, 仍面临着数据共享与隐私保护之间的矛盾。因此, 在联邦学习框架下构建隐私保护 RAG, 便成为了将联邦学习的隐私安全特性与 RAG 的信息处理能力相结合的重要探索方向。

Chakraborty 等人对联邦学习下的 RAG 展开系统研究, 其核心是将联邦学习与 RAG 技术相结合, 以应对大型语言模型在医疗、金融、个性化辅助等隐私敏感领域部署时的隐私、所有权及合规性问题^[9]。该工作在检索与生成全流程中保障数据机密性且不暴露原始数据。在检索阶段, 采用加密协议、可信执行环境, 实现敏感信息的机密性和隐私性; 在模型训练与参数交换环节, 仅共享扰动或加密模型更新而非原始数据; 在系统设计上, 通过本地化增强, 如 FedE4RAG 本地推理、选择性查询路由, 以减少数据移动, 同时依托联邦平均、安全聚合等技术整合分布式更新, 最终在医疗、金

融等敏感领域实现数据主权与隐私合规, 平衡隐私保护与系统效能。

Addison 等人提出了 C-FedRAG(Confidential Federated RAG)系统^[40], 旨在解决传统 RAG 在跨数据孤岛扩展时面临的数据隐私与安全挑战。该系统融合联邦学习与机密计算(Confidential Computing)技术, 构建了一个全联邦化的 RAG 工作流。各数据提供方本地执行文档嵌入与检索实现安全通信, 由运行在机密计算环境中的 orchestrator 框架负责上下文聚合与最终 LLMs 推理。通过联邦训练适配本地数据分布的嵌入与重排序模型, 在无需集中化数据的前提下提升检索与生成质量。该工作为企业内跨部门及跨机构协作场景提供了隐私保护的分布式 RAG 解决方案, 推动了 LLMs 在医疗、金融等敏感领域的可信部署。

Shi 等人提出了联邦多智能体系统(Federated MAS)的概念, 旨在解决基于 LLMs 的多智能体系统在敏感领域应用中的隐私保护挑战^[41]。其与传统联邦学习的核心区别在于: 联邦学习聚焦于分布式模型训练, 而 Federated MAS 强调实时多智能体协作中的隐私动态保护, 核心是通过嵌入式代理实现 RAG 系统的隐私与性能平衡。针对代理间隐私协议异构性、多方对话结构差异及动态网络结构这三大挑战, 该研究提出了嵌入式隐私增强代理解决方案。通过在 RAG 阶段和上下文检索阶段嵌入隐私增强代理, 作为中介过滤信息, 仅允许任务相关的、特定于代理的信息共享, 从而最小化数据流动, 减少无效数据暴露。

Mao 等人提出的 FedE4RAG 框架, 旨在解决私有 RAG 系统面临的敏感数据稀缺与隐私保护难题, 通过联邦学习实现客户端数据不共享前提下的 RAG 模型协作训练^[42]。该框架结合 KD-GLE 模块的联邦知识蒸馏和 FED-HE 模块的同志加密, 实现跨客户端知识聚合而不泄露原始数据; 在本地可信环境中, 利用优化后的检索器完成查询相关文档检索, 并结合 LLMs 生成答案。该工作通过联邦学习与隐私增强技术的融合, 为金融等敏感领域的本地化 RAG 系统提供了兼顾性能与隐私的解决方案。

在联邦学习框架下的隐私保护 RAG 研究中, 不同方案针对具体场景的需求形成了各具特色的技术路径。其中, C-FedRAG、Federated MAS 与 FedE4RAG 在核心目标、技术融合、应用领域及主要贡献等方面各有侧重, 表 6 显示了三者的关键特征对比。

此外, Karamanhoğlu 等人提出了一种集成 LLMs、联邦学习和低延迟流分析的隐私保护临床决策支持系统, 其核心在于通过 RAG 机制实现隐私与诊疗准确性的平衡^[43]。系统处理结构化(生命体征、实验室数据)和非结构化(临床笔记)的患者数据, 利用 LLMs 解析临床文本、生成鉴别诊断及分诊依据, 并通过检索模块从医疗知识库中获取相关指南或历史案例以增强推理的准确性; 同时, 采用联邦学习让多机构在不共享原始数据的情况下协作优化模型, 结合差分隐私、安全聚合和推理隔离技术保障数据隐私, 符合 GDPR 和 HIPAA 规范。

2.3 基于合成数据的隐私保护 RAG

在隐私保护 RAG 的研究中, 如何在保障数据隐私的同时维持检索与生成的有效性是核心挑战之一。传统方法多从技术架构层面进行改进, 而基于合成数据的解决方案为这一问题提供了全新思路。通过生成与原始数据具有相似效用但剔除敏感信息的合成数据, 从源头上避免隐私泄露风险。

表 6 C-FedRAG、Federated MAS 与 FedE4RAG 的核心特征对比

Tab. 6 Comparison of core features of C-fedrag, Federated MAS, and fede4rag			
对比维度	C-FedRAG	Federated MAS	FedE4RAG
核心目标	解决传统 RAG 跨数据孤岛扩展时的隐私与安全挑战	解决基于 LLMs 的多智能体系统在敏感领域的隐私保护挑战, 强调实时协作中的隐私动态保护	解决私有 RAG 的敏感数据稀缺与隐私保护难题, 提升私有 RAG 检索性能
技术融合	联邦学习+机密计算	联邦学习+多智能体系统	联邦学习+嵌入学习+知识蒸馏+同态加密
应用领域	医疗、金融、企业跨部门/机构协作	敏感领域的多智能体协作(如医疗、金融)	金融等敏感领域的本地化 RAG 系统
主要贡献	构建机密计算环境下的端到端联邦 RAG workflow, 通过机密虚拟机保护上下文机密性, 支持跨数据源安全扩展	提出联邦多智能体隐私保护范式, 通过嵌入式代理实现 RAG 阶段数据流动最小化, 实现了动态的隐私保护	融合联邦嵌入学习与隐私增强技术, 解决数据稀缺问题, 提升私有 RAG 性能与隐私平衡

Shao 等人提出的 ITER-RETGEN 方法, 通过迭代检索-生成协同机制增强检索增强 LLMs 的性能, 其核心在于构建检索与生成的闭环优化^[44]。首轮利用任务输入检索知识并生成初始响应, 后续迭代中, 以上一轮生成结果作为补充上下文检索更相关的知识, 再结合新检索内容生成更优输出。与传统检索增强方法, 如 ReAct、Self-Ask 等通过多轮检索-生成交替中断生成过程不同, 该方法整体处理所有检索知识, 在保留生成灵活性的同时, 减少检索与生成开销, 在多跳问答、事实验证和常识推理任务上验证了其有效性。尽管该方法主要聚焦性能优化, 但其通过迭代优化减少对原始敏感数据的直接依赖, 为基于合成数据的隐私保护 RAG 提供了潜在思路, 即通过动态检索优化降低对真实敏感知识的调用频率, 间接增强隐私安全性。

Zeng 等人提出的 SAGE(synthetic attribute-based generation with agent-based refinement)框架, 通过纯合成数据解决 RAG 系统的隐私问题^[45]。该框架通过两阶段流程生成高实用性且隐私保护的合成检索数据, 第一阶段采用基于属性的生成策略, 先让 LLMs 识别数据集关键属性, 如医疗对话中的症状描述、诊断建议, 再提取样本的属性关键信息, 最后基于这些信息生成包含核心内容的合成数据; 第二阶段引入代理机制进行迭代优化, 隐私评估代理检测合成数据中的个人身份信息及关联隐私风险并提供反馈, 改写代理据此反复优化数据直至通过隐私验证。

Yu 等人探讨了 LLMs 作为属性化训练数据生成器的潜力与挑战, 为合成数据在隐私保护 RAG 中的应用提供了关键启示^[46]。该研究指出, LLMs 能够基于原始数据的核心属性, 如语义特征、结构模式等生成具有高度相似性的合成数据, 且通过调控生成策略能够有效增强数据的多样性。这一特性对隐私保护 RAG 至关重要, 既能替代真实敏感数据作为检索源, 避免隐私泄露, 又能通过多样本覆盖提升检索的全面性。同时, 该研究也揭示了 LLMs 生成数据中可能存在的偏差, 如语义偏移、属性丢失等, 并提出针对性优化方案, 如属性约束提示、偏差校正机制等, 确保合成数据在保留原始数据效用的前提下, 支持 RAG 系统的精准检索与推理。通过 LLMs 生成的属性化合成数据, 可在完全规避真实隐私数据暴露风险的同时, 维持 RAG 系统对上下文的理解与响应能力, 实现隐私保护与性能的平衡。

2.4 基于加密技术实现 RAG 系统隐私保护

在隐私保护 RAG 技术的多样化探索中, 基于加密的方案是一类极具特色的分支。传统 RAG 系统普遍面临提示注入攻击、用户隔离缺失、数据访问控制不严等安全漏洞, 而同态加密凭借密文域内直接计算的核心能力, 为解决这些痛点提供了独特路径。该技术确保文本内容及其嵌入在存储、检索、生成的全生命周期中始终以加密形式存在, 仅授权用

户可通过密钥解密访问, 从而从根本上减少非授权泄露风险。尽管该技术存在计算开销较大的挑战, 但其能在不牺牲检索性能与生成功能的前提下, 为医疗、金融等高敏感领域提供端到端的隐私保障, 成为与合成数据、联邦学习等其他隐私保护技术并行的重要解决方案, 共同丰富着 RAG 系统的隐私安全生态。

其中, SecureRAG 通过全同态加密实现了隐私保护 RAG 的核心功能, 其将检索流程拆分为安全搜索与安全文档获取, 其中全同态加密是加密域内检索的关键技术支撑^[47]。该框架采用 CKKS 方案对文档嵌入向量和查询向量进行加密, 利用全同态加密的 SIM 特性和垂直打包策略, 在加密状态下直接计算内积以实现语义相似度匹配, 确保嵌入信息和查询内容在整个处理过程中始终处于加密状态, 有效防御嵌入反转攻击。同时, 全同态加密支持动态数据库更新, 添加或删除文档时可通过同态运算高效维护加密向量库, 且检索准确性与未加密 RAG 相当, 仅增加 0.05 秒的开销, 结合属性基加密实现细粒度访问控制, 共同构建了端到端的隐私保护机制, 适用于医疗、金融等敏感领域。

Zhou 提出的 Privacy-Aware RAG 框架通过全生命周期加密实现隐私保护^[48]。针对系统中所有的文本和嵌入, 均保证其在系统的整个生命周期中保持加密存储。在访问控制层面, 仅授权用户通过唯一用户标识符和解密密钥获取数据, 进而杜绝非授权访问, 大幅度降低敏感信息泄露的风险。在查询匹配阶段, 结合 RAG 系统的外部知识库, 通过相似性度量检索最相关的文档, 并利用哈希函数和消息认证码保障数据完整性。该方案注重实用性, 全生命周期加密策略在保障安全性和机密性的同时, 能够保留 RAG 系统的核心性能与功能, 保障其不同场景的广泛应用。该研究通过全面的安全性证明验证了方法的鲁棒性, 揭示了现有方案在健壮性、适应性或对开源模型的过度依赖等方面的局限, 为加密技术在 RAG 隐私保护中的应用提供了理论与实践参考。

Bac 等人提出了一种结合苏格拉底式思维链推理与同态加密向量数据库的混合框架, 以实现隐私保护的大语言模型交互, 尤其适用于同态加密隐私保护 RAG 场景^[49]。该框架将计算划分为可信区域(用户本地设备)和不可信区域(云端服务), 通过四个阶段实现隐私保护的检索增强生成。首先, 用户向不可信云端的强 LLMs 发送非隐私查询, 云端 LLMs 生成推理提示和目标子查询; 接着, 子查询在本地转化为向量; 随后, 子查询向量在云端的同态加密向量数据库中执行加密域内的向量相似度搜索, 快速返回匹配的加密记录; 最后, 加密记录在本地解密后, 与推理提示共同作为输入, 由本地弱模型生成最终响应。

He 等人提出的 PRESS(Privacy-preserving Retrieval-augmented generation via Embedding Space Shifting)方法, 针

对 RAG 系统在信息检索阶段面临的隐私泄露风险, 构建了一套兼顾隐私保护与功能完整性的解决方案^[50]。其核心思路是通过嵌入空间迁移实现隐私防御。首先利用基于近端策略优化的训练方法, 让预训练语言模型生成目标训练样本; 随后基于这些样本对文本嵌入模型进行定向迁移微调, 引导 RAG 系统将潜在泄露隐私的查询映射到嵌入空间中的安全目标区域。实验结果表明, 该方法在代表性模型和数据集上

能高效实现高防御性能, 同时保持 RAG 系统的正常功能, 为解决 RAG 在隐私敏感场景中的数据安全提供了新的技术路径。

2.5 RAG 系统隐私保护技术综合对比

表 7 从核心优势、主要劣势、适用场景、隐私强度、效用损失和部署成本六个主要维度归纳对比了 RAG 系统隐私保护技术的优缺点。

表 7 实现 RAG 系统隐私保护四种技术的优缺点对比

Tab. 7 Comparison of advantages and disadvantages of four privacy protection technologies for RAG systems						
技术类型	核心优势	主要劣势	适用场景	隐私强度	效用损失	部署成本
差分隐私	1.理论保证严格, 可量化隐私预算; 2.无需修改 RAG 架构, 易集成 ^[35] ; 3.支持全流程防护 ^[33]	1.噪声注入降低检索相关性/生成流畅性 ^[34] ; 2.小数据集下效用损失显著 ^[33] ; 3.长文本生成预算分配难 ^[36]	集中式场景, 如单机知识库、对隐私有量化要求的场景, 如合规审计	4-5	2-4	1-2
联邦学习框架下的隐私保护 RAG	1.原始数据本地存储, 规避数据共享风险 ^[9] ; 2.支持多节点协同, 适配跨机构场景 ^[40] ; 3.可结合机密计算增强安全性 ^[40]	1.非独立同分布数据下检索精度下降 ^[9] ; 2.需协调多节点, 系统复杂度高 ^[42] ; 3.未能完全解决检索阶段的集中化风险 ^[9]	分布式场景, 如跨医院医疗协作、企业跨部门检索	3-4	1-3	3-5
基于合成数据的隐私保护方案	1.从源头规避原始数据泄露 ^[45] ; 2.支持无限次复用, 降低数据依赖 ^[46] ; 3.对 RAG 架构改动小 ^[45]	1.合成数据语义一致性不足, 影响检索精度 ^[45] ; 2.领域适配性差, 如医疗数据生成难度高 ^[45] ; 3.缺乏隐私量化保证 ^[46]	数据稀缺场景、对原始数据绝对隐私要求的场景, 如金融机密数据	2-3	2-4	2-3
加密技术	1.全生命周期加密, 隐私防护最彻底 ^[47] ; 2.支持细粒度访问控制 ^[48] ; 3.抗嵌入反转攻击 ^[47]	1.计算开销大, 检索/生成延迟高 ^[47] ; 2.需专用硬件支持, 如可信执行环境 ^[40] ; 3.动态数据库更新难 ^[48]	高安全需求场景, 如军事机密、核心金融数据、对延迟不敏感的场景	5	1-2	4-5

注: 隐私强度 5 分为最高, 1 分为最低; 效用损失 1 分为无损失, 5 分为完全不可用; 部署成本 1 分为仅需软件集成, 5 分为需专用硬件与多节点协调。

3 RAG 隐私保护技术的挑战和展望

前文归纳的四类 RAG 系统隐私保护技术, 在不同维度优缺点各异, 单一技术往往难以在隐私强度、系统效用、部署成本和场景适用性等维度达到理想平衡, 以下针对这些技术面临的挑战进行归纳, 并对未来研究进行展望。

3.1 现有 RAG 系统隐私保护技术的挑战

首先是隐私-效用的动态平衡瓶颈, 现有技术难以在全场景下实现隐私与效用的协同。在差分隐私中, DP-RAG^[33]虽实现全流程防护, 但文档数量不足时准确性显著下降; 联邦学习中, FedE4RAG^[42]虽通过知识蒸馏提升性能, 但非独立同分布数据下检索精度损失显著; 合成数据中, SAGE^[45]生成的医疗数据虽通过隐私验证, 但诊断建议的准确率较真实数据低。此外, 现有技术多静态设定隐私策略, 如固定噪声强度^[35], 无法根据查询类型, 如敏感/非敏感查询动态调整防护强度, 导致资源浪费或隐私泄露。

其次, 端到端系统性方案缺失, 现有研究多聚焦单阶段防护: 例如, PAD^[35]仅解决生成阶段的解码泄露, 无法覆盖检索阶段的成员推断攻击; SecureRAG^[47]虽实现全流程加密, 但未考虑生成阶段的提示注入风险^[30]。这种碎片化防护易形成安全短板。例如文献^[11]指出, 即使检索阶段通过联邦学习保护隐私, 生成模型仍可能通过训练数据记忆泄露敏感模式。此外, 现有方案缺乏对检索-生成协同防护的设计, 例如检索器的隐私策略与生成器的噪声注入未形成联动, 导致整体防护效果低于预期。

再次, 实际部署效率与公平性问题。在部署层面, 加密技术, 如 SecureRAG^[47]的全同态加密使检索延迟增加, 难以适配诸如智能问答的实时场景^[2]; 联邦学习, 如 C-FedRAG^[40]

需多节点协同训练, 中小企业难以承担基础设施成本。在公平性层面, RAG 系统因依赖外部知识库, 易受知识源不平衡影响。例如 FairRAG^[51]指出, 现有技术多关注隐私与效用, 忽视检索偏差导致的公平性问题, 如医疗场景中对罕见病案例的检索不足, 而合成数据生成中的属性偏差^[46]进一步加剧了这一问题。

最后, 缺乏统一的评估标准。现有研究采用不同的评估指标, 如差分隐私用 ϵ 值^[34]、联邦学习用准确率损失^[42], 导致技术间难以横向对比。此外, 评估数据集局限于通用领域, 如公开问答数据集^[1], 缺乏医疗、金融等敏感领域的专用测试集, 导致技术在实际场景中的表现难以验证。

3.2 RAG 系统隐私保护技术的研究展望

未来, RAG 系统的隐私保护技术研究需要积极探索优势互补的技术组合方案。

3.2.1 技术组合实现 RAG 系统的隐私保护

第一种潜在的组合方案是整合联邦学习、差分隐私和机密计算, 针对联邦学习的非独立同分布数据问题, 可结合差分隐私的动态噪声注入, 如 LPRAG^[37]的实体级扰动, 在本地训练阶段为嵌入向量添加自适应噪声, 同时利用机密计算, 如 C-FedRAG^[40]的 orchestrator 框架保护参数聚合过程。在例如跨机构医疗协作场景中, 既能避免原始数据共享, 又缓解数据异质性导致的精度损失, 同时满足 HIPAA 合规要求。

第二种潜在的组合方案是合成数据结合检索增强反馈, 针对合成数据的语义一致性不足, 可引入合成数据-反馈验证动态模式。例如, 利用 SAGE^[45]生成初始合成数据, 通过 RAG 系统检索脱敏后的真实知识库验证语义一致性, 若偏差超过阈值, 则反馈至生成器迭代优化。在金融风控场景中, 该组合方案能在保证隐私性的前提下, 将合成数据的检索相关性大幅提升, 解决现有合成数据无法支撑精准决策的问题^[45]。

第三种潜在的组合方案是加密检索+轻量级生成防护。针对加密技术的部署效率问题, 可通过检索阶段全加密、生成阶段轻量级防护相结合的方式, 例如检索阶段用属性基加密, 如 Privacy-AwareRAG^[48]实现细粒度访问控制, 生成阶段用 PAD^[35]的自适应高斯噪声注入, 减轻全流程加密的引发的效率损失。在实时智能问答场景中, 在保证隐私性的前提下有效降低响应延迟, 确保用户操作与系统反馈之间的间隔降至人类难以察觉的阈值以下。

以上三种组合方案, 为隐私保护 RAG 系统的实现提供了思路。然而, 技术的落地必须依托于应用场景, 明确急需突破的关键领域。

3.2.2 场景特点驱动隐私保护技术选择

在医疗场景中, 急需解决电子健康记录的隐私与诊疗精度平衡, 从分布式场景特点出发, 研究联邦学习框架下的多模态 RAG 隐私保护, 整合文本病历、影像数据, 就诊时空数据等信息, 突破现有单模态防护的局限^[43], 同时需符合 HIPAA 对数据访问的审计要求。

在金融场景中, 急需解决实时交易查询中的隐私与响应速度问题, 建议聚焦差分隐私的快速噪声注入算法, 例如优化 INVISIBLEINK^[36]的 logits 处理过程, 提升隐私预算分配的效率, 进而满足高频交易场景的低延迟需求。

在政务场景中, 跨部门数据检索、数据一致性和标准不易等合规性问题, 驱动研究基于区块链的联邦 RAG, 利用区块链实现检索权限的可追溯, 结合合成数据技术, 例如属性化生成^[46]避免原始政务数据泄露, 满足 GDPR 的要求。

整体而言, 未来 RAG 隐私保护研究需更紧密结合实际应用场景区的需求, 推动技术从理论验证走向工程落地, 同时重视公平性与隐私保护的深度融合, 为 RAG 系统在医疗、金融等隐私敏感领域的可信、合规应用提供更坚实的技术支撑。

3.2.3 推进理论发展与评估指标统一

构建隐私-效用-公平性协同框架, 建立统一的评估指标体系, 涵盖隐私强度(如差分隐私 ϵ 值、抗攻击类型)、效用指标(如检索准确率、生成困惑度)、公平性指标(如不同群体的检索覆盖率、生成偏差)。进一步突破隐私-效用平衡瓶颈, 例如优化差分隐私的噪声注入策略以减少检索相关性损失, 完善联邦 RAG 的索引同步机制以解决跨节点数据异质性问题, 提升加密技术的计算效率以适配大规模部署需求; 同时, 需构建覆盖检索-生成全流程的端到端隐私防护体系, 避免碎片化防护导致的安全漏洞。在公平性层面, 需直面 RAG 系统特有的公平性挑战^[52]。RAG 系统因依赖外部知识源, 易受知识源不平衡、检索偏差、信息整合偏见等问题影响, 而现有研究(如 FairRAG)对公平性的探索仍处于起步阶段, 多数模型公平性表现不佳^[51]。未来需将公平性融入隐私保护框架, 例如在合成数据生成中确保数据多样性以避免属性偏差, 在检索机制优化中减少对特定群体信息的过度或不足检索, 在联邦协作中平衡各节点数据贡献以避免模型偏向优势群体, 最终实现隐私-效用-公平性的协同保障。

同时, 需开发敏感领域专用测试集, 例如医疗领域的 MIMIC-RAG 数据集、金融领域的 FinRAG 数据集等, 为技术评估提供统一基准。此外, 需研究动态隐私策略, 基于查询敏感等级, 例如患者姓名、疾病类型为高敏感, 性别为中敏感等, 自适应调整防护强度, 实现资源高效利用。

4 结束语

本文系统梳理了 RAG 系统的基本原理、应用场景、隐私

风险以及主要隐私保护技术。RAG 系统通过检索-生成两阶段协同, 有效弥补了传统 LLMs 知识更新不及时和易产生幻觉等主要问题, 在医疗、金融、智能问答等多领域发挥了重要的应用价值。然而, 由于 RAG 系统检索-生成全流程中涉及敏感数据交互, 因而容易遭受成员推断、知识投毒、隐式知识提取等多元隐私攻击。本文重点剖析了 RAG 系统中的相关隐私风险, 归纳与对比了 RAG 系统中的四类隐私保护技术, 即差分隐私、联邦学习、合成数据以及加密技术。以上四类技术各有侧重, 分别针对集中式场景、分布式协作场景、数据源头保护场景及高安全需求场景形成互补, 但现有研究仍存在隐私-效用动态权衡难、端到端系统性方案缺失、实际部署效率不足等局限。最后, 本文针对现有 RAG 系统隐私保护技术所面临的挑战进行梳理, 并对研究前景进行展望。本文的研究可为隐私保护 RAG 系统部署提供参考, 推动大模型技术创新与隐私保护的协同发展。

参考文献:

- [1] Lewis P, Perez E, Piktus A, *et al.* Retrieval-augmented generation for knowledge-intensive NLP tasks [J]. *Advances in Neural Information Processing Systems*, 2020, 33: 9459-9474.
- [2] Adiwardana D, Luong M T, So D R, *et al.* Towards a human-like open-domain chatbot [J]. *Neurocomputing*, 2020, 400: 13-24.
- [3] Xiong Guangyu, Jin Qiao, Lu Zhi, *et al.* Benchmarking retrieval-augmented generation for medicine [C]// *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2024: 6233-6251.
- [4] Zeng Shenglai, Zhang Jiankun, He Pengfei, *et al.* The good and the bad: Exploring privacy issues in retrieval-augmented generation (RAG) [J]. *Neurocomputing*, 2024, 600: 127680.
- [5] 刘杰. 大语言模型增强的企业端到端数据治理研究与应用 [D]. 成都: 电子科技大学, 2025.
- [6] Golda A, Mekonen K, Pandey A, *et al.* Privacy and security concerns in generative AI: a comprehensive survey [J]. *IEEE Access*, 2024, 12: 48126-48144.
- [7] 王柳, 王中奥, 侯心怡, 等. 大语言模型存储机制安全风险综述 [J/OL]. *计算机研究与发展*, (2025-10-13) [2025-11-11]. <https://crad.ict.ac.cn/article/doi/10.7544/issn1000-1239.202550481>. (Wang Liu, Wang Sheno, Hou Xinyi, *et al.* A survey of security risks in large language model storage mechanisms [J/OL]. *Journal of Computer Research and Development*, (2025-10-13) [2025-11-11]. <https://crad.ict.ac.cn/article/doi/10.7544/issn1000-1239.202550481>.)
- [8] Abadi M, Chu A, Goodfellow I, *et al.* Deep learning with differential privacy [C]// *Proc of the 2016 ACM SIGSAC Conference on Computer and Communications Security*. New York: ACM Press, 2016: 308-318.
- [9] Chakraborty A, Dahal C, Gupta V. Federated retrieval-augmented generation: a systematic mapping study [J]. *IEEE Transactions on Knowledge and Data Engineering*, 2025, 37 (8) .
- [10] Panda M, Mukherjee S. Enhancing privacy and security in rag-based generative AI applications [J]. *AI, Machine Learning and Applications Advances*, 2025: 01-10.
- [11] Carlini N, Hayes J, Nasr M, *et al.* Extracting training data from diffusion models [C]// *Proc of 32nd USENIX Security Symposium (USENIX Security 23)*. Berkeley, CA: USENIX Association, 2023: 5253-5270.
- [12] Habbal A, Ali M K, Abuzaraida M A. Artificial intelligence trust, risk and security management (AI Trism): Frameworks, applications,

- challenges and future research directions [J]. *Expert Systems with Applications*, 2024, 240: 122442.
- [13] Ni Bo, Liu Zheyuan, Wang Leyao, *et al.* Towards trustworthy retrieval augmented generation for large language models: A survey [J/OL]. *arXiv preprint arXiv: 2502. 06872*, 2025. (2025-02-08) [2025-11-11]. <https://arxiv.org/abs/2502.06872>
- [14] Carlini N, Tramer F, Wallace E, *et al.* Extracting training data from large language models [C]// *Proc of 30th USENIX Security Symposium (USENIX Security 21)*. Berkeley, CA: USENIX Association, 2021: 2633-2650.
- [15] Anderson M, Amit G, Goldstein A. Is my data in your retrieval database? Membership inference attacks against retrieval augmented generation [C/OL]// *Proc of the 11th International Conference on Information Systems Security and Privacy*. Setúbal, Portugal: SciTePress, 2025: 474-485. (2025-02-04) [2025-11-11]. <https://doi.org/10.5220/0013108300003899>.
- [16] Li Yuying, Liu Gaoyang, Wang Chen, *et al.* Generating is believing: Membership inference attacks against retrieval-augmented generation [C]// *Proc of the 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Piscataway, NJ: IEEE Press, 2025: 1-5.
- [17] Jiang Changyue, Pan Xudong, Hong Geng, *et al.* RAG-Thief: Scalable extraction of private data from retrieval-augmented generation applications with agent-based attacks [C/OL]// *Proc of the 2025 ACM SIGSAC Conference on Computer and Communications Security*. New York, NY: ACM Press, 2025. (2025-08-24) [2025-11-11]. <https://arxiv.org/abs/2508.12345>.
- [18] Li Yunxiang, Li Zihan, Zhang Kai, *et al.* Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (llama) using medical domain knowledge [J]. *Cureus*, 2023, 15 (6).
- [19] Wang Yuhao, Qu Wenjie, Zhai Shengfang, *et al.* Silent leaks: Implicit knowledge extraction attack on RAG systems through benign queries [C/OL]// *Proc of the 2025 IEEE Symposium on Security and Privacy*. Piscataway, NJ: IEEE Press, 2025. (2025-05-23) [2025-11-11]. <https://arxiv.org/abs/2505.15420>.
- [20] Parvez M R, Ahmad W U, Chakraborty S, *et al.* Retrieval augmented code generation and summarization [J/OL]. *arXiv preprint arXiv: 2108.11601*, 2021. (2021-08-26) [2025-11-11]. <https://doi.org/10.48550/arXiv.2108.11601>.
- [21] Kulkarni M, Tangarajan P, Kim K, *et al.* Reinforcement learning for optimizing rag for domain chatbots [J/OL]. *arXiv preprint arXiv: 2401.06800*, 2024. (2024-01-10) [2025-11-11]. <http://arxiv.org/abs/2401.06800>.
- [22] Carlini N, Ippolito D, Jagielski M, *et al.* Quantifying memorization across neural language models [J/OL]. *arXiv preprint arXiv: 2202.07646*, 2022. (2023-03-06) [2025-11-11]. <https://doi.org/10.48550/arXiv.2202.07646>.
- [23] Biderman S, Prashanth U, Sutawika L, *et al.* Emergent and predictable memorization in large language models [J]. *Advances in Neural Information Processing Systems*, 2023, 36: 28072-28090.
- [24] Mireshghallah F, Uniyal A, Wang T, *et al.* Memorization in NLP fine-tuning methods [J/OL]. *arXiv preprint arXiv: 2205.12506*, 2022. (2022-11-04) [2025-11-11]. <http://arxiv.org/abs/2205.12506>.
- [25] Zeng Shenglai, Li Yaxin, Ren Jie, *et al.* Exploring memorization in fine-tuned language models [J/OL]. *arXiv preprint arXiv: 2310.06714*, 2023. (2024-02-22) [2025-11-11]. <http://arxiv.org/abs/2310.06714>.
- [26] Kandpal N, Wallace E, Raffel C. Deduplicating training data mitigates privacy risks in language models [C]// *Proc of International Conference on Machine Learning*. PMLR, 2022: 10697-10707.
- [27] Lee K, Ippolito D, Nystrom A, *et al.* Deduplicating training data makes language models better [J/OL]. *arXiv preprint arXiv: 2107.06499*, 2021. (2022-03-24) [2025-11-11]. <http://arxiv.org/abs/2107.06499>.
- [28] Zou Wei, Geng Runpeng, Wang Binghui, *et al.* PoisonedRAG: Knowledge poisoning attacks to Retrieval-Augmented Generation of large language models [J/OL]. *arXiv preprint arXiv: 2402.07867*, 2024. (2024-08-13) [2025-11-11]. <http://arxiv.org/abs/2402.07867>.
- [29] Chaudhari H, Severi G, Abascal J, *et al.* Phantom: General trigger attacks on retrieval augmented language generation [J/OL]. *arXiv preprint arXiv: 2405.20485*, 2024. (2025-10-01) [2025-11-11]. <http://arxiv.org/abs/2405.20485>.
- [30] Pasquini D, Strohmeier M, Troncoso C. Neural exec: Learning (and learning from) execution triggers for prompt injection attacks [C]// *Proc of the 2024 Workshop on Artificial Intelligence and Security*. 2024: 89-100.
- [31] Cheng Pengzhou, Ding Yidong, Ju Tianjie, *et al.* Trojanrag: Retrieval-augmented generation can be backdoor driver in large language models [J/OL]. *arXiv preprint arXiv: 2405.13401*, 2024. (2024-07-07) [2025-11-11]. <http://arxiv.org/abs/2405.13401>.
- [32] Xue Jiaqi, Zheng Mengxin, Hu Yebowen, *et al.* Badrag: Identifying vulnerabilities in retrieval augmented generation of large language models [J/OL]. *arXiv preprint arXiv: 2406.00083*, 2024. (2024-06-06) [2025-11-11]. <http://arxiv.org/abs/2406.00083>.
- [33] Grislain N. Rag with differential privacy [C]// *Proc of the 2025 IEEE Conference on Artificial Intelligence (CAI)*. Piscataway, NJ: IEEE Press, 2025: 847-852.
- [34] Koga T, Wu Ruihan, Chaudhuri K. Privacy-preserving Retrieval-Augmented Generation with differential privacy [J/OL]. *arXiv preprint arXiv: 2412.04697*, 2024. (2024-02-26) [2025-11-11]. <http://arxiv.org/abs/2412.04697>.
- [35] Wang Haoran, Xu Xiong Xiao, Huang Baixiang, *et al.* Privacy-aware decoding: Mitigating privacy leakage of large language models in Retrieval-Augmented Generation [J/OL]. *arXiv preprint arXiv: 2508.03098*, 2025. (2025-08-05) [2025-11-11]. <http://arxiv.org/abs/2508.03098>.
- [36] Vinod V, Pillutla K, Thakurta A G. INVISIBLEINK: High-utility and low-cost text generation with differential privacy [J/OL]. *arXiv preprint arXiv: 2507.02974*, 2025. (2025-06-30) [2025-11-11]. <http://arxiv.org/abs/2507.02974>.
- [37] He Longzhu, Tang Peng, Zhang Yuanhe, *et al.* Mitigating privacy risks in Retrieval-Augmented Generation via locally private entity perturbation [J]. *Information Processing & Management*, 2025, 62 (4): 104150.
- [38] Yao Dixi, Li Tian. Private Retrieval Augmented Generation with random projection [C]// *Proc of the ICLR 2025 Workshop on Building Trust in Language Models and Applications*. [S. l.]: ICLR, 2025.
- [39] Khandelwal U, Levy O, Jurafsky D, *et al.* Generalization through memorization: Nearest neighbor language models [J/OL]. *arXiv preprint arXiv: 1911.00172*, 2019. (2020-02-15) [2025-11-11]. <http://arxiv.org/abs/1911.00172>.
- [40] Addison P, Nguyen M T H, Medan T, *et al.* C-fedrag: A confidential

- federated retrieval-augmented generation system [J/OL]. arXiv preprint arXiv: 2412. 13163, 2024. (2024-12-18) [2025-11-11]. <http://arxiv.org/abs/2412.13163>.
- [41] Shi Zitong, Wan Guancheng, Huang Wenke, *et al.* Privacy-enhancing paradigms within federated multi-agent systems [J/OL]. arXiv preprint arXiv: 2503. 08175, 2025. (2025-03-11) [2025-11-11]. <http://arxiv.org/abs/2503.08175>.
- [42] Mao Qianren, Zhang Qili, Hao Hanwen, *et al.* Privacy-preserving federated embedding learning for localized retrieval-augmented generation [J/OL]. arXiv preprint arXiv: 2504. 19101, 2025. (2025-04-27) [2025-11-11]. <http://arxiv.org/abs/2504.19101>.
- [43] Karamanlioğlu A, Demirel B, Tural O, *et al.* Privacy-preserving clinical decision support for emergency triage using LLMs: System architecture and real-world evaluation [J]. *Applied Sciences*, 2025, 15 (15): 8412.
- [44] Shao Zhihong, Gong Yeyun, Shen Yelong, *et al.* Enhancing Retrieval-Augmented large language models with iterative retrieval-generation synergy [C]// Boumor H, Pino J, Bali K. Findings of the Association for Computational Linguistics: EMNLP 2023. Singapore: Association for Computational Linguistics, 2023: 9248-9274.
- [45] Zeng Shenglai, Zhang Jiankun, He Pengfei, *et al.* Mitigating the privacy issues in retrieval-augmented generation (rag) via pure synthetic data [J/OL]. arXiv preprint arXiv: 2406. 14773, 2025. (2025-02-19) [2025-11-11]. <http://arxiv.org/abs/2406.14773>.
- [46] Yu Yue, Zhuang Yuchen, Zhang Jieyu, *et al.* Large language model as attributed training data generator: A tale of diversity and bias [J]. *Advances in Neural Information Processing Systems*, 2023, 36: 55734-55784.
- [47] Anonymous. SecureRAG: End-to-end secure Retrieval-Augmented Generation [EB/OL]. (2025-02-16) [2025-11-11]. <https://openreview.net/forum?id=5uXACIH6K>.
- [48] Zhou Pengcheng, Feng Yinglun, Yang Zhongliang. Privacy-aware RAG: Secure and isolated knowledge retrieval [J/OL]. arXiv preprint arXiv: 2503. 15548, 2025. (2025-03-17) [2025-11-11]. <http://arxiv.org/abs/2503.15548>.
- [49] Bae Y, Kim M, Lee J, *et al.* Privacy-preserving LLM interaction with socratic chain-of-thought reasoning and homomorphically encrypted vector databases [J/OL]. arXiv preprint arXiv: 2506. 17336, 2025. (2025-06-19) [2025-11-11]. <http://arxiv.org/abs/2506.17336>.
- [50] He Jiaming, Liu Cheng, Hou Guanyu, *et al.* PRESS: Defending privacy in Retrieval-Augmented Generation via embedding space shifting [C]// Proc of the 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) . Piscataway, NJ: IEEE Press, 2025: 1-5.
- [51] Shrestha R, Zou Yang, Chen Qiuyu, *et al.* Fairrag: Fair human generation via fair retrieval augmentation [C]// Proc of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 11996-12005.
- [52] Zhou Yujia, Liu Yan, Li Xiaoxi, *et al.* Trustworthiness in retrieval-augmented generation systems: A survey [J/OL]. arXiv preprint arXiv: 2409. 10102, 2024. (2024-09-16) [2025-11-11]. <http://arxiv.org/abs/2409.10102>.