

基于检索增强生成的主题推理模型*

潘理虎, 李 婕, 赵红燕[†]

(太原科技大学 计算机科学与技术学院, 太原 030024)

摘要: 针对大语言模型在主题建模中面临的主题多样性和模型可解释性不足的挑战,提出了一种基于检索增强生成的主题推理模型(TIM_RAG),采用三阶段架构实现主题生成与分布推理。首先,在 RAG 检索阶段设计多维文档相似度检索方法,筛选兼具词频相关性与深层语义关联的相似文档,增强单篇文档的主题信息,提升主题多样性;其次,在 RAG 生成阶段构建多视角主题生成策略,借助思维链引导 LLM 提取多角度主题词,并生成中间步骤以提高该过程透明度;最后,在独立推理阶段提出嵌入传输计划机制,通过最优传输理论建模文档-主题与主题-词汇的语义关系,进一步提升模型可解释性。在 WikiText-103、BBC News 和 20 Newsgroups 数据集上的实验表明,TIM_RAG 模型有效缓解了主题多样性不足的问题,提升了主题模型的性能。

关键词: 主题模型; 大语言模型; 检索增强生成; 思维链; 最优传输理论

中图分类号: TP391

文献标志码: A

文章编号: 1001-3695(2025)10-016-3019-08

doi: 10.19734/j.issn.1001-3695.2025.03.0059

Topic inference model based on retrieval augmented generation

Pan Lihu, Li Jie, Zhao Hongyan[†]

(College of Computer Science & Technology, Taiyuan University of Science & Technology, Taiyuan 030024, China)

Abstract: To address the challenges of insufficient topic diversity and limited model interpretability faced by large language models (LLMs) in topic modeling, this paper proposed a topic inference model based on retrieval augmented generation (TIM_RAG), which achieved topic generation and distribution inference through three-stage architecture. Firstly, in the RAG retrieval phase, it designed a multi-dimensional document similarity retrieval method that filtered similar documents exhibiting both term-frequency relevance and deep semantic associations, thus enriching the topic information of individual document and enhancing topic diversity. Secondly, in the RAG generation phase, it implemented a multi-perspective topic generation strategy, which used chain-of-thought prompting to guide the LLM in extracting multi-angle topic terms and generated intermediate reasoning steps to increase process transparency. Finally, in the independent inference phase, it introduced an embedding transport plan based on optimal transport theory to model semantic relationships between document-topic and topic-word, significantly improving model interpretability. Experiments on the WikiText-103, BBC News, and 20 Newsgroups datasets show that TIM_RAG effectively mitigates topic diversity limitations while enhancing topic modeling performance.

Key words: topic model; large language model; retrieval augmented generation; chain-of-thought; optimal transport theory

0 引言

随着信息技术的高速发展,文本数据呈爆炸式增长,如何有效地从文档集合中自动推断潜在的主题结构(即主题推理)已成为文本分析领域的核心挑战。主题模型(topic model, TM)作为一种基于概率论的强大统计工具,旨在从大规模文本数据中自动揭示潜在的主题结构,在信息检索、文本分类、情感分析等自然语言处理(natural language processing, NLP)任务中有着广泛的应用前景^[1]。

主题模型经历了从简单的统计方法逐步过渡到复杂的深度学习技术的演变过程。经典模型如 LDA(latent Dirichlet allocation)^[2],通过概率模型将文档表示为主题分布的混合物,并将每个主题表示为词分布的多项式分布。近年来,神经主题模型结合了传统主题模型和深度学习的优势,实现了更高效的主题提取,例如,基于循环神经网络的模型可捕捉文本的序列信息,适用于处理长文本和时序数据^[3];基于变分自编码器的模型将其作为生成模型框架,在潜在主题发现方面取得了显著

成果^[4];此外,还探索了 GNN^[5]和注意力机制^[6]在主题模型中的应用,提升了模型在处理复杂结构和长距离依赖关系方面的能力。这些神经主题模型各有侧重,共同推动了主题建模技术的进步和发展。

大语言模型(large language models, LLMs)的涌现显著革新了自然语言处理的各个任务^[7,8],基于 LLMs 的主题模型研究也不例外。然而,现有方法主要采用逐个文档提示策略,即通过 LLMs 为数据集中的每个文档独立生成主题^[9]。这种方法存在两个核心问题:

a)单文档分析导致的主题多样性不足。当 LLMs 被要求对单个文档进行逐一分析时,由于缺乏对整个数据集的宏观视角,其生成的主题往往无法充分涵盖数据集中众多文档的多元主题,从而导致主题多样性不足。

b)黑盒推理引发的模型可解释性低下。LLMs 固有的黑盒特性进一步增加了主题生成过程的不透明度,严重限制了模型的可解释性。

检索增强生成(retrieval augmented generation, RAG)因其阶段性设计,天然适合解决这些问题:其检索阶段通过全局文

收稿日期: 2025-03-19; **修回日期:** 2025-05-08 **基金项目:** 山西省自然科学基金资助项目(202203021211199);山西省重点实验室开放基金资助项目(CICIP2022004);太原科技大学博士科研启动基金资助项目(20212075)

作者简介: 潘理虎(1974—),男,河南驻马店人,教授,博导,博士,CCF 高级会员,主要研究方向为人工智能;李婕(1999—),女,山西临汾人,硕士,主要研究方向为主题模型;赵红燕(1977—),女(通信作者),山西太原人,副教授,硕导,博士,主要研究方向为自然语言处理(hongyanzhao@tyust.edu.cn)。

档检索补充主题信息,生成阶段结合思维链(chain-of-thought, CoT)技术可保留中间推理步骤。为了克服上述局限性,本文提出一种基于RAG的主题推理模型TIM-RAG,它既是一种新型主题模型,更是一个优化的主题推理框架。其核心贡献在于:

a) 针对LLMs在处理单个文档时生成主题多样性不足的问题,在RAG检索阶段设计了多维文档相似度检索方法,通过混合检索方法来整合BM25字符检索和文档向量检索以增强检索性能,从而扩展单篇文档的主题信息,缓解单文档孤立分析的主题多样性局限。

b) 针对LLMs推理过程不透明的问题,在RAG生成阶段借助CoT构建了多视角主题生成策略,引导LLMs从不同角度提取文档主题并生成中间推理步骤,增强了主题提取过程的透明性,解决了LLMs的幻觉问题,生成质量更高的主题,间接提升了模型可解释性;同时,融合数据蒸馏技术训练轻量化模型,进一步优化主题生成过程。

c) 为进一步提升模型可解释性,在独立推理阶段提出嵌入传输计划推理机制,将文档、主题和词汇的嵌入表示映射到统一向量空间,通过最优传输理论建模其语义关系;并通过最小化传输成本平衡文档-主题与主题-词汇分布之间的差异性,以更准确地推断文档-主题与主题-词汇分布。

1 相关工作

1.1 基于LLMs的主题模型

随着LLMs技术的不断进步,研究人员日益关注将LLMs应用于主题模型的构建与优化。Rijcken等人^[10]评估了ChatGPT在解释主题模型生成主题方面的能力,结果表明其在提供准确和连贯的解释方面表现出色,证实了LLMs在主题建模领域的潜在应用价值。Wang等人^[11]采用提示LLMs从单个文档中提取句子级别的主题,并将其汇总和压缩为预定义的数量,这种方法能够为不同长度的文本生成连贯的主题表示,进一步扩展了LLMs在主题建模中的应用范围。

然而,现有方法仍存在显著局限性,例如,TopicGPT^[12]虽能通过指令引导生成主题,但其依赖单一模板(如“请总结文档核心主题”)导致分析视角固化,难以捕捉多维度语义特征,尤其在处理复杂文档时易产生片面性主题;而LLMs-for-TM^[13]虽然通过细化人工规则提升主题质量,但其依赖的硬编码逻辑(如关键词匹配阈值、主题词权重公式)缺乏灵活性。相比之下,TIM-RAG通过多视角主题生成策略可覆盖文档分析的多重视角,借助嵌入传输计划推理机制建模文档-主题-词汇的联合语义对齐关系,通过模块化设计增强了模型的灵活性与通用性。

1.2 检索增强生成(RAG)

RAG最早由Lewis等人^[14]提出,旨在应对知识密集型NLP任务中知识获取的挑战;随后发展为一种结合了信息检索与语言生成模型的人工智能技术,主要解决LLMs在生成文本时可能会出现的幻觉问题。Gao等人^[15]探讨了LLMs中RAG的概念,着重于如何通过检索从外部知识库中获取相关信息来提升答案的准确性和减少模型幻觉。Wang等人^[16]详细分析了RAG的各个模块,如检索、重排、生成等,并通过广泛的实验探索了优化RAG技术的有效策略。在实际应用中,RAG的流程可依据特定需求灵活构建,但核心始终包含两个阶段:a)检索阶段,即从外部知识库中检索与输入相关的信息;b)生成阶段,即利用检索到的信息生成回答。这两个阶段相互协作,确保生成的文本既准确又丰富。总之,RAG作为一种创新的人工智能技术,通过检索与生成的有机结合,有效应对了LLMs在文本生成任务中的挑战,并在不断的应用与优化中展现出巨大的潜力。本文在RAG框架中重新设计了检索和

生成阶段,以增强单篇文档的主题信息,并优化大语言模型的主题生成推理过程,从而提升主题多样性和可解释性。

1.3 思维链(CoT)

CoT是一种旨在提高LLMs在复杂推理任务中性能的技术,在解决推理问题时,模型并非直接输出答案,而是通过生成一系列中间推理步骤(即思维链)来引导生成答案。文献[17]首次提出了CoT提示方法,通过在提示中嵌入推理过程显著增强了LLMs的推理能力。Kojima等人^[18]通过一系列广泛的实验验证了零样本思维链(zero-shot CoT)的可行性,仅需在提示中添加特定的引导短语,如“让我们一步步来”,LLMs便能在零样本条件下执行逐步推理。Zhang等人^[19]提出一种自动思维链(Auto-CoT)提示方法,利用LLMs生成推理链,从而避免了手动设计示例的繁琐工作。CoT技术的应用不仅能提升模型的推理性能,还可以增强模型的可解释性和透明度。本文运用CoT技术,设计多模板任务提示引导LLMs从不同角度提取文档主题,并生成中间的推理步骤以增强模型的可解释性。

1.4 数据蒸馏(data distillation)

数据蒸馏是一种通过从大规模数据集中提取关键信息,生成一个小规模但信息量相近的数据集的技术,广泛应用于模型压缩、数据压缩和加速训练等领域。其核心思想是通过训练一个轻量化模型(学生模型)来模仿大规模模型(教师模型)的行为,从而在保持模型性能的同时显著减少计算资源的消耗。例如,Hinton等人^[20]提出的知识蒸馏方法,通过使用教师模型的输出作为软标签来训练学生模型,显著提升了学生模型的性能。此外,数据蒸馏还可以结合生成模型(如生成对抗网络GAN或变分自编码器VAE)来生成与原始数据集分布相似的小规模数据集,从而进一步减少数据存储和计算资源的消耗。本文利用数据蒸馏技术训练轻量化生成模型GLM-7B,以优化主题生成过程,降低计算成本、提升推理效率。

2 TIM-RAG 模型

针对基于LLMs的主题模型在主题多样性和模型可解释性方面所遭遇的双重挑战,本文提出了一种基于RAG的主题推理模型TIM-RAG,其模型架构如图1所示。




图1 TIM-RAG 模型

Fig. 1 TIM-RAG model

2.1 多维文档相似度检索

多维文档相似度检索旨在解决 LLMs 单文档分析导致的主题多样性不足问题。通过融合 BM25 字符检索与文档向量检索,混合检索策略能够筛选出既符合词频相关性又具备深层语义关联的相似文档,从全局数据集中补充单篇文档的主题信息,突破单文档分析的局限性从而提升主题多样性。

2.1.1 字符检索

BM25 (best matching 25)^[21] 是一种基于概率检索模型的文档排名方法,通过考虑关键词频率 (term frequency, TF)、逆频率 (inverse document frequency, IDF) 以及文档长度等因素来评估文档的相关性,通过式 (1) 来计算查询文档 q 与候选文档 d 之间的相关性得分。

$$\text{score}(d, q) = \sum_{i=1}^n \text{IDF}(q_i) \times \frac{\text{TF}(q_i, d) \times (k_1 + 1)}{\text{TF}(q_i, d) + (1 - b + b \times \frac{|d|}{\text{avg}_d})} \quad (1)$$

其中: $d \in D$, 是除查询文档 q 之外数据集 D 中的任一文档; q_i 表示查询文档 q 中的第 i 个词, n 为总词数; $\text{TF}(q_i, d)$ 表示查询词 q_i 在文档 d 中的词频; $\text{IDF}(q_i)$ 为词 q_i 的逆文档频率; $|d|$ 是文档 d 的长度; avg_d 是所有文档的平均长度; k_1 是一个正系数,用来控制词频的饱和度,较高的 k_1 意味着词频对评分的影响更大,通常取值在 1.2~2; b 是用于控制文档长度对评分影响的可调参数,取值在 0~1,通常设为 0.75。

最后,根据 $\text{score}(d, q)$ 得分,筛选出 top_d 篇与 q 最为相似的文档。

2.1.2 向量检索

为了更有效地捕捉文档的深层语义特征,本文设计了一种文档对比编码器 (document contrastive encoder, DCE)。DCE 参考了 ConSERT^[22] 的研究,用对比学习促使模型学习到更具区分度的文档语义特征表示,从而提升文档向量的表达能力。其框架如图 2 所示。




图 2 文档对比编辑器框架

Fig. 2 Framework of the document contrastive encoder

对于每个输入文档 doc , 通过打乱词序 (token shuffling) 的数据增强技术进行处理, 分别应用两种变换 T_1 和 T_2 以生成两个版本的令牌嵌入; 然后将它们分别输入到 Sentence-BERT 中的多个 Transformer 块中, 通过平均池化层生成相对应的两个版本的文档表示。跟随原文, 使用 NTXent 损失函数来优化模型的表示能力。该损失函数的公式如下:

$$\mathcal{L}_{\text{NTXent}} = - \sum_{p=1}^P \log \frac{\exp(\text{sim}(r_m, r_n) / \tau_1)}{\sum_{k=1}^P \mathbb{I}_{[k \neq m]} \exp(\text{sim}(r_m, r_k) / \tau_1)} \quad (2)$$

其中: $\text{sim}(\cdot)$ 表示余弦相似函数; τ_1 为温度控制参数; $\mathbb{I}$ 为指示函数; P 为每批次所包含的文档数量, 也为样本对的数量; r_m 和 r_n 为同一文档的表示, 即正样本对; r_m 和 r_k 为不同文档的表

示, 即负样本对。

在生成文档向量后, 通过余弦相似度计算查询文档 q 与候选文档 d 之间的相似度, 公式为

$$\text{cosine}(d, q) = \frac{d \times q}{\|d\| \times \|q\|} \quad (3)$$

其中: d 和 q 分别表示查询文档 q 与候选文档 d 的向量表示。最后, 根据 $\text{cosine}(d, q)$ 的值筛选出 top_d 篇与 q 最为相似的文档。

2.1.3 混合检索

向量相似度模型在语义理解方面具有优势, 但易陷入局部最优语义的困境, 导致检索结果不够准确; BM25 评分公式考虑了词频率和文档长度等因素, 能够有效避免这一问题。为了充分融合两者的长处并弥补各自的不足, 本文采用了倒数排名融合 (reciprocal rank fusion, RRF) 的混合检索策略。RRF 方法的核心思想是利用每个检索方法返回文档的排名信息, 通过倒数排名的计算来提高相关文档的排名。

首先, 将生成的多个主题 (关于主题的生成方法将在 2.2.1 和 2.3.2 节中详细阐述) 作为查询 q' , 将已经通过字符检索和向量检索得到的 $2 \times \text{top}_d$ 篇文档 $d' \in D'$ 作为候选文档, 计算 $\text{score}(d', q')$ 并对其进行排序, 得到候选文档 d' 的字符检索排名 $\text{rank}_{\text{score}}(d')$; 其次, 计算查询文档 q 与 $d' \in D'$ 之间文档相似度 $\text{cosine}(d', q)$ 并对其进行排序, 得到候选文档向量 $d' \in D'$ 的向量检索排名 $\text{rank}_{\text{cosine}}(d')$ 。最后, 文档 d' 的组合 RRF 分数的计算公式如下:

$$\text{RRF}(d' \in D') = \sum_{m \in M} \frac{1}{k + \text{rank}_m(d')} = \frac{1}{k + \text{rank}_{\text{score}}(d')} + \frac{1}{k + \text{rank}_{\text{cosine}}(d')} \quad (4)$$

其中: k 为参数, 默认 $k = 60$; M 指参与混合检索的检索方法, 在此处指字符检索和向量检索。最后, 根据 RRF 得分对文档进行重新排序, 筛选出最相关的 top_d 篇文档作为最终检索结果。

2.2 多视角主题生成

为解决 LLMs 黑盒推理导致模型可解释性不足的问题, 构建了多视角主题生成, 通过多模板提示设计引导 LLMs 从不同视角深入解析文档, 生成多角度主题词及中间步骤, 在提升主题多样性的同时提升生成过程的透明性。

2.2.1 多模板提示设计

多模板提示设计借鉴了 Auto-CoT 理念, 其核心思想是生成多样化的任务提示模板, 引导 LLMs 从不同视角深入解析文档内容, 从而生成准确且多样的主题词。具体来说, 首先为 LLMs 设计一个初始提示, 要求其生成三个适用于任意文档主题提取的任务模板。这些模板分别聚焦于关键词频率、主题句提炼和内容归纳三个分析视角, 每个模板都明确说明了任务需求和简要步骤, 确保 LLMs 能够根据模板生成相应的主题词。表 1 展示了设计的初始提示以及 LLMs 生成的三个任务提示模板。

表 1 初始提示及生成的多模板任务提示

Tab. 1 Initial prompts and generated multi-template task prompts

项目	内容
初始提示	请生成三个通用的任务模板, 适用于任意文档的主题提取/生成, 分别聚焦于关键词频率分析、主题句提炼、内容归纳三个分析维度。每个模板需明确说明任务需求和简要步骤, 并保证其输出是该文档的主题词
模板 1 关键词 词频	请根据以下步骤从文档中提取主题词: 1. 阅读全文, 识别并统计文章中出现频率最高的关键词 2. 根据这些关键词, 提炼出代表文章主题的词汇
模板 2 主题句 提炼	请根据以下步骤从文档中提取主题词: 1. 阅读全文, 识别文章中的主题句, 特别是段落的开头或结尾句 2. 从这些主题句中提炼核心词汇, 形成文章的主题词
模板 3 内容归纳	请根据以下步骤从文档中提取主题词: 1. 阅读全文, 分析文章的各个部分, 归纳每部分的主要内容 2. 根据内容归纳, 提取出能够概括文章主题的词汇

2.2.2 候选主题词生成

该阶段将字符检索和向量检索得到的 $2 \times top_d$ 篇文档分别与多模板任务提示相结合,引导 LLMs 从不同角度深入分析文档内容,提取出准确且多样的主题词。具体示例如表 2 所示。

表 2 主题生成的具体示例

Tab. 2 A specific example of topic generation

项目	内容
输入文档	Three Chinese items- the Li ethnic group's traditional textile techniques of spinning, dyeing, weaving, and embroidering; the Qiang New Year festival, a traditional annual event of the Qiang ethnic group in China; and traditional design and practices for building Chinese wooden arch bridges- were added to the UNESCO heritage list during the 19th session of the Intergovernmental Committee for the Safeguarding of the Intangible Cultural Heritage held in Asuncion, Paraguay.
模板 1 关键词词频	高频关键词: Chinese, UNESCO, heritage list, Li ethnic group, textile techniques, spinning, dyeing, weaving, embroidering, Qiang New Year festival, Qiang ethnic group, traditional design, wooden arch bridges. 主题词: Chinese, UNESCO, heritage, Li, textile, spinning, dyeing, weaving, embroidering, Qiang, festival, design, bridges.
模板 2 主题句提炼	主题句核心词汇: Three Chinese items, UNESCO heritage list, Li ethnic group, textile techniques, Qiang New Year festival, wooden arch bridges, added, Intergovernmental Committee, Intangible Cultural Heritage. 主题词: Chinese, UNESCO, heritage, Li, textile, Qiang, festival, bridges, added, committee, cultural heritage.
模板 3 内容归纳	内容归纳词汇: UNESCO recognition, Chinese cultural heritage, Li ethnic textile arts, Qiang ethnic festival, wooden arch bridge construction, intangible heritage, traditional practices, cultural preservation. 主题词: UNESCO, Chinese, heritage, Li, textile, Qiang, festival, bridges, traditional, preservation.

在表 2 的示例中,模板 1 关键词频率分析可快速锁定文章的核心词汇,如 UNESCO 和 heritage list,直观展现讨论焦点;模板 2 主题句提炼可明确文章中心事件,如 added to the UNESCO heritage list,直接揭示主旨;模板 3 内容归纳可深入挖掘文化价值与保护措施的多层次内涵,如 Chinese cultural heritage,凸显文章的深度与思考。三者互补,形成全面、立体的主题理解,有效提升了文章主旨的把握和深入认识,避免了单一角度的局限性,增强了主题提取的准确性和完整性。

2.2.3 生成模块优化

在 TIM_RAG 模型中,采用数据蒸馏技术来优化主题生成的过程。首先,以 2.2.2 节中的 LLMs 作为教师模型,生成的初步主题作为对应文档的软标签;其次,在本地搭建轻量化学生模型 GLM-7B,并通过这些软标签进行训练,使其学习教师模型的生成行为;最后,将训练完成的 GLM-7B 作为 ChatGPT 的代替,为混合检索筛选出的 top_d 篇文档重新生成最终主题。GLM-7B 使 TIM_RAG 模型在保持主题生成质量的同时,显著降低了计算成本,提升了推理效率。图 3 所示为生成模型 GLM-7B 的一个案例。

2.3 嵌入传输计划推理

为进一步提升模型的可解释性,本文参考 FASTopic^[23] 提出了嵌入传输计划(embedding transport plan, ETP)推理,通过最优传输理论来建模文档-主题和主题-词汇之间的关系,从而解决 RAG 生成阶段中可能存在的语义偏差问题。ETP 示意图如图 4 所示。

2.3.1 文档到主题的传输计划

为了使关系规范化,将文档与主题的关系建模为一个特定定义的最优传输问题^[23],具体步骤如下:

a) 定义离散测度。对于文档-主题关系,设文档嵌入和主题嵌入的离散测度分别为

$$\gamma_1 = \sum_{i=1}^N \frac{1}{N} \delta_{d_i}, \quad \rho_1 = \sum_{k=1}^K s_k \delta_{t_k} \quad (5)$$

其中: d_i 为文档向量; t_k 为主题向量; δ_x 表示 x 上的狄拉克单位质量; 本文设置每个文档嵌入的权重为 $1/N$, N 为数据集的文档总数量; 设置每个主题嵌入的权重为 s_k , $s = (s_1, s_2, \dots, s_K)$ 是一个和为 1 的权重向量,且 $s = \text{softmax}(s_0)$, 统一均匀初始化为 $s_0 = \mathbf{I}_K/K$ 。

Instruction:

Please extract the topics from the document according to the following steps:

- (1) Read the entire text and identify the keywords that occur most frequently;
- (2) Based on these keywords, Extract the words that best represents the topic of the text.

Input:

OpenAI has asked the Trump administration to protect AI companies from state regulations in exchange for voluntary model sharing with the federal government. In a 15-page policy proposal, OpenAI warned that hundreds of pending state AI bills could undermine US technological leadership, especially against China. OpenAI suggested offering relief from state rules to AI companies that provide model access. This proposal was part of OpenAI's response to the White House Office of Science and Technology Policy's request for input on securing US dominance in AI.

Output:

Step 1: High-Frequency Keywords

OpenAI (3 times), AI (3 times), state regulations (2 times), federal government (1 time), technological leadership (1 time), China (1 time), model sharing (1 time), policy proposal (1 time)

Step 2: Extracted Topic Words

OpenAI, AI, State Regulations, Technological Leadership, Model Sharing

Step 3: Reasoning for Each Topic Word

- 1 **OpenAI** Reason: OpenAI is the main actor in the document, driving the policy proposal and central to the discussion.
- 2 **AI** Reason: The document focuses on AI technology and its regulation, making AI a core topic.
- 3 **State Regulations** Reason: A key part of OpenAI's proposal is to protect AI companies from state-level regulations, which is a major focus of the document.
- 4 **Technological Leadership** Reason: OpenAI warns that state bills could undermine U.S. technological leadership, especially in competition with China, making this a critical theme.
- 5 **Model Sharing** Reason: OpenAI suggests voluntary model sharing with the federal government in exchange for regulatory relief, which is a central mechanism in the proposal.

图 3 GLM-7B 生成模型的具体案例

Fig. 3 A specific example of the GLM-7B generation model




图 4 ETP 示意图

Fig. 4 Diagram of ETP

b) 构建最优传输问题。将 γ_1 和 ρ_1 的距离度量最小化问题建模为最优传输问题,并引入熵正则化项以获得可计算的近似解。具体公式如下:

$$\argmin_{\pi \in \mathbb{R}_+^{N \times K}} \mathcal{L}_{OT}(\gamma_1, \rho_1; \varepsilon_1) = \sum_{i=1}^N \sum_{k=1}^K C_{ik}^{(1)} \pi_{ik} + \varepsilon_1 \pi_{ik} (\log \pi_{ik} - 1) \quad (6)$$

$$\pi \mathbf{I}_K = \frac{\mathbf{I}_N}{N}, \quad \pi^\top \mathbf{I}_N = s \quad (7)$$

式(6)的第一项是原始的最优传输问题,第二项是用超参数 ε_1 进行熵正则化。式(6)旨在找到一种传输计划 π , 满足式(7)中的两个条件,即确保每个文档被平等地考虑和所有主题嵌入的权重向量等于 s 。其中: $\mathbf{I}_K$ 表示 K 维列向量; π_{ik} 是指从 d_i 到 t_k 的传输权重,它们之间的传输成本用 $C_{ik}^{(1)} = \|d_i - t_k\|^2$ 表示,以 $\mathbf{C}^{(1)}$ 为传输成本矩阵。

c) Sinkhorn 算法求解。通过 Sinkhorn 算法迭代求解上述优化问题,具体步骤为

(a) 初始化传输计划矩阵 π 为均匀分布: $\pi_{ik}^{(0)} = 1/(N \times K)$;

(b) 迭代更新:对每行归一化,确保文档权重和为 $1/N$;对每列归一化,确保主题权重和为 s_k 。

$$\pi_{ik}^{(t+1)} \leftarrow \pi_{ik}^{(t)} \cdot \frac{1/N}{\sum_{k=1}^K \pi_{ik}^{(t)}}; \pi_{ik}^{(t+1)} \leftarrow \pi_{ik}^{(t)} \cdot \frac{s_k}{\sum_{i=1}^N \pi_{ik}^{(t)}} \quad (8)$$

重复以上两步,直到收敛,即 $\|\pi^{(t+1)} - \pi^{(t)}\| < \delta, \delta = 1E-5$ 或者 $t \geq I_{\max}, I_{\max} = 100, \delta$ 为收敛阈值, $I_{\max}$ 为最大迭代次数。

(c) 输出最终的传输计划 π^* 。

2.3.2 主题到词汇的传输计划

与文档-主题分布的推理类似,将主题与词的关系也建模为一个特定定义的最优传输计划^[23]:

a) 定义离散测度。对于主题-词汇关系,设主题嵌入和词嵌入的离散测度分别为

$$\gamma_2 = \sum_{k=1}^K \frac{1}{K} \delta_{t_k}, \rho_2 = \sum_{j=1}^V u_j \delta_{w_j} \quad (9)$$

其中: w_j 为词向量;本文设置每个主题嵌入的权重为 $1/K$,每个词嵌入的权重为 u_j ; u 是一个和为 1 的权重向量; V 是数据集的词汇量。

b) 构建最优传输问题。将 γ_2 和 ρ_2 的距离度量最小化问题建模为最优传输问题,并引入熵正则化项以获得可计算的近似解。具体公式如下:

$$\operatorname{argmin}_{\phi \in \mathbb{R}^{K \times V}} \mathcal{L}_{OT}(\gamma_2, \rho_2; \varepsilon_2) = \sum_{k=1}^K \sum_{j=1}^V C_{kj}^{(2)} \phi_{kj} + \varepsilon_2 \phi_{kj} (\log \phi_{kj} - 1) \quad (10)$$

$$\phi \mathbf{I}_K = \frac{\mathbf{I}_K}{K}, \phi^\top \mathbf{I}_N = \mathbf{u} \quad (11)$$

与式(6)相似,式(10)旨在找到一种传输计划 ϕ ,满足式(11)中的两个条件。在该公式中, ϕ_{kj} 是指从 t_k 到 w_j 的传输权重,它们之间的传输成本用 $C_{kj}^{(2)} = \|t_k - w_j\|^2$ 表示,以 $C^{(2)}$ 为传输成本矩阵。设置 $\mathbf{u} = \operatorname{softmax}(\mathbf{u}_0)$, $\mathbf{u}_0$ 为可学习变量,统一均匀初始化为 $\mathbf{u}_0 = \mathbf{I}_V/V$ 。

c) Sinkhorn 算法求解。通过 Sinkhorn 算法迭代求解上述优化问题,具体步骤为

(a) 初始化传输计划矩阵 ϕ 为均匀分布: $\phi_{kj}^{(0)} = 1/(K \times V)$;

(b) 迭代更新:对每行归一化,确保主题权重和为 $1/K$;对每列归一化,确保词汇权重和为 u_j 。

$$\phi_{kj}^{(t+1)} \leftarrow \phi_{kj}^{(t)} \cdot \frac{1/K}{\sum_{j=1}^V \phi_{kj}^{(t)}}; \phi_{kj}^{(t+1)} \leftarrow \phi_{kj}^{(t)} \cdot \frac{u_j}{\sum_{k=1}^K \phi_{kj}^{(t)}} \quad (12)$$

重复以上两步,直到收敛,即 $\|\phi^{(t+1)} - \phi^{(t)}\| < \delta, \delta = 1E-5$ 或者 $t \geq I_{\max}, I_{\max} = 100$ 。

(c) 输出最终的传输计划 ϕ^* 。

2.3.3 ETP 的优化目标

将上述传输计划作为语义关系,可将文档 x_i 的文档-主题分布写为

$$\theta^{(i)} = N\pi_i^*, \pi^* = \operatorname{Sinkhorn}(\mathcal{L}_{OT}(\gamma_1, \rho_1; \varepsilon_1)) \quad (13)$$

将主题-词汇分布写为

$$\beta = K\phi^*, \phi^* = \operatorname{Sinkhorn}(\mathcal{L}_{OT}(\gamma_2, \rho_2; \varepsilon_2)) \quad (14)$$

本文使用 Sinkhorn 算法来计算两个最优传输问题的近似解 π^* 和 ϕ^* ,并通过最小化近似传输计划加权的总传输成本来制定 ETP 的目标函数:

$$\mathcal{L}_{ETP} = \sum_{i=1}^N \sum_{k=1}^K C_{ik}^{(1)} \pi_{ik}^* + \sum_{k=1}^K \sum_{j=1}^V C_{kj}^{(2)} \phi_{kj}^* \quad (15)$$

ETP 算法如算法 1 嵌入传输计划所示。

算法 1 嵌入传输计划

输入:数据集 $D = \{x_1, x_2, \dots, x_N\}$, 文档对比编辑器 DCE。

输出:主题嵌入 T , 单词嵌入 W , 主题权重 s , 词汇权重 u 。

初始化 $s_0 \leftarrow \mathbf{I}_K/K$;

初始化 $u_0 \leftarrow \mathbf{I}_V/V$;

初始化 $d_i \leftarrow \operatorname{DCE}(x_i), i = \{1, 2, \dots, N\}$; // 初始化 D

初始化 T ; // GLM-7B 生成主题及嵌入

随机初始化 W ;

for 1 to n epoch;

$s = \operatorname{softmax}(s_0)$;

$u = \operatorname{softmax}(u_0)$;

$C_{ik}^{(1)} = \|d_i - t_k\|^2$; // 文档到主题的传输成本矩阵

$\pi^* = \operatorname{Sinkhorn}(\mathcal{L}_{OT}(\gamma_1, \rho_1; \varepsilon_1))$; // 文档到主题的传输计划

$C_{kj}^{(2)} = \|t_k - w_j\|^2$; // 主题到词汇的传输成本矩阵

$\phi^* = \operatorname{Sinkhorn}(\mathcal{L}_{OT}(\gamma_2, \rho_2; \varepsilon_2))$; // 主题到词汇的传输计划

$\beta = K\phi^*$;

$\theta^{(i)} = N\pi_i^*, i = \{1, 2, \dots, N\}$;

计算损失函数式(15);

使用梯度下降更新 T, W, s, u ;

end for

2.3.4 新文档主题推断

给定新文档 x' , 使用 DCE 生成其文档嵌入 d' 。ETP 的训练过程只关注于学习文档和主题之间的语义关系,而 x' 并未参与训练,ETP 无法利用 d' 来进行主题分布的预测。

因此,通过以下方式推断 d' 的主题分布 θ' :

$$\theta'_k = \frac{p_k}{\sum_{k'=1}^K p_{k'}} \quad (16)$$

$$p_k = \frac{\exp(-\|t_k - d'\|^2/\tau)}{\sum_{i=1}^N \exp(-\|t_k - d_i\|^2/\tau)} \quad (17)$$

其中: τ 是一个温度超参数。将 d' 和 t_k 之间的关系建模为欧几里德距离,并通过 t_k 和所有训练文档的总关系来正则化,以近似 ETP 的主题权重;最后对所有主题进行归一化来计算 θ'_k 。

3 实验与分析

3.1 数据集与评价指标

实验采用了三个广泛应用于主题模型的经典数据集: WikiText-103、BBC News、20 Newsgroups。WikiText-103 是一个源自维基百科的大型文本数据集;BBC News 是源自英国广播公司(BBC)2004—2005 年发布的各类新闻文章,涵盖了商业、娱乐、政治、体育和技术等五个主要类别;20 Newsgroups 是从 20 个不同的新闻组中收集的文本数据集。表 3 提供了这些数据集的详细统计数据。

表 3 数据集详情

Tab. 3 Dataset details

数据集	文档数量	类别数量	平均长度
WikiText-103	28 532	—	1 355.4
BBC News	2 225	5	120.1
20 Newsgroups	18 846	20	110.5

3.2 基准模型

为了验证 TIM_RAG 模型生成主题的质量,将其与以下基线模型进行对比:

a) BERTopic^[24]: 利用预训练语言模型和基于类别的 TF-IDF 过程进行神经主题建模的方法。

b) ECRIM^[25]: 通过将主题嵌入作为单独聚合的词嵌入聚类中心来缓解主题坍塌问题。

c) FASTopic^[23]: 利用预训练 Transformer 和嵌入传输计划进行双语义关系重建的自适应、稳定且可迁移的主题模型。

d) TopicGPT^[12]: 基于提示的文本主题建模框架,利用 LLMs 从文本集合中发现潜在主题。

e) LLMs-for-TM^[13]: 利用 LLMs 生成主题的框架,并通过手动指令和规则指导 LLMs 进行主题细化和合并。

f) PromptTopic^[11]: 基于提示的主题建模方法, 提示 LLM 提取句子级别的主题并聚合压缩成预定义的数量, 从而为不同长度的文本提供连贯的主题。

g) TRM^[26]: 与模型无关的机制, 利用 LLMs 对从短文本中提取的主题进行评估和细化, 从而提高主题的质量。

3.3 评价指标

为了评估模型的性能, 采用了几种广泛认可的指标, 包括主题连贯性(topic coherence, TC)、主题多样性(topic diversity, TD)、主题质量(topic quality, TQ)^[26, 27]以及评估主题聚类实验的纯度(purity)和规范化互信息(normalized mutual information, NMI)。

TC 是指一个主题中词语的连贯程度, 本文选择 Gensim 提供的 C_v 作为计算 TC 的方法, TC 越高代表主题越连贯。TD 反映主题之间的区分度和独特性, TD 越高, 表明模型能够更好地捕捉到数据集中的语义差异。本文通过计算所有主题中最频繁的 25 个词中有多少个独特词来衡量主题多样性, 其计算公式为

$$TD = \frac{N_u}{25K} \quad (18)$$

其中: N_u 为出现在所有主题中的唯一单词的数量。

TQ 的评估不能仅单一地关注主题连贯性或者是主题多样性的表现。跟随刘阳^[28]的研究, 取 TC 和 TD 的乘积作为主题质量的评估指标, 即 $TQ = TC \times TD$ 。purity 和 NMI 共同用于评估文档主题分配的质量, 其值越高表示聚类效果越好。

3.4 实验设置

实验环境为运行在 NVIDIA GeForce RTX 4090 GPU 服务器上的 Ubuntu 22.04 系统, 配置包括 Python 3.8 和 PyTorch 1.12。DCE 模块使用 Sentence-BERT 作为预训练模型, 最大序列长度设置为 64, 打乱词序的比率设置为 0.15, 模型训练 64 个 epoch, 优化器为 Adam, 学习率为 $5E-7$ 。生成阶段使用 ChatGPT 进行推理, 其温度参数设置为 0。

3.5 实验结果及分析

本节采用实验对比八种主题模型在三个数据集上的多个评价指标, 实验结果如表 4 和 5 所示。

表 4 TC、TD 和 TQ 的实验结果

Tab. 4 TC, TD and TQ results for experiments

模型	WikiText-103			BBC News			20 Newsgroups		
	TC	TD	TQ	TC	TD	TQ	TC	TD	TQ
BERTopic	0.43	0.61	0.26	0.17	0.82	0.14	0.17	0.64	0.12
ECRTM	0.42	0.92	0.39	0.39	0.9	0.35	0.43	0.9	0.39
FASTopic	0.57	0.97	0.55	0.55	0.92	0.5	0.58	0.95	0.55
TopicGPT	0.43	0.93	0.4	0.54	0.91	0.49	0.53	0.93	0.49
LLMs-for-TM	0.55	0.95	0.52	0.51	0.89	0.45	0.55	0.95	0.52
PromptTopic	0.52	0.94	0.49	0.51	0.91	0.46	0.54	0.93	0.5
TRM	0.55	0.95	0.52	0.54	0.91	0.49	0.55	0.95	0.52
TIM_RAG(7B)	0.58	0.97	0.56	0.54	0.91	0.49	0.57	0.96	0.55
TIM_RAG	0.57	0.97	0.55	0.55	0.92	0.5	0.58	0.97	0.56

表 5 purity 和 NMI 的实验结果

Tab. 5 purity and NMI results for experiments

模型	WikiText-103		BBC News		20 Newsgroups	
	purity	NMI	purity	NMI	purity	NMI
BERTopic	0.67	0.34	0.56	0.34	0.67	0.34
ECRTM	0.7	0.36	0.56	0.63	0.56	0.53
FASTopic	0.73	0.4	0.58	0.56	0.62	0.47
TopicGPT	0.71	0.35	0.58	0.71	0.6	0.5
LLMs-for-TM	0.71	0.39	0.55	0.66	0.55	0.53
PromptTopic	0.61	0.35	0.54	0.49	0.56	0.45
LLM-TM	0.67	0.39	0.56	0.52	0.61	0.53
TIM_RAG(7B)	0.74	0.4	0.59	0.72	0.63	0.55
TIM_RAG	0.75	0.41	0.59	0.73	0.63	0.56

表 4 展示了 TIM_RAG 与基线模型在 TC、TD 和 TQ 指标上的对比结果。在所有数据集中, TIM_RAG 模型在 TC、TD 和 TQ 指标上均表现最佳, 这一结果表明, TIM_RAG 通过多维文档相似度检索机制和多视角主题生成能够更全面地捕捉文档的语义信息, 生成更具多样性和连贯性的主题。特别是在 BBC News 数据集上, TQ 相较于 LLMs-for-TM 提升了 11.1%, 这一显著提升主要得益于其文本结构特性与模型机制的高度适配。其文本通常采用倒金字塔结构, 即最重要的信息位于文本开头, 随后是细节描述, 这种结构使得 TIM_RAG 的多模板提示设计能够精准捕捉文本的核心语义信息。此外, TIM_RAG 在 WikiText-103 和 20 Newsgroups 数据集上的 TQ 相较于 LLMs-for-TM 分别提升了 5.8% 和 7.7%, 进一步验证了模型在处理不同规模和复杂度文本数据时的适应性和优越性。值得注意的是, TIM_RAG 与当前最优神经主题模型 FASTopic 的所有指标几乎持平, 表明基于 LLMs 的主题建模方法已具备与神经主题模型竞争的能力。

表 5 展示了 TIM_RAG 与基线模型在 purity 和 NMI 指标上的对比结果, 进一步凸显了本文模型在文档聚类效果上的显著优势。在所有数据集中, TIM_RAG 的 purity 和 NMI 指标均表现最佳, 表明 TIM_RAG 模型通过 ETP 模块精确建模文档-主题和主题-词汇分布, 能够更准确地进行文档聚类。特别是在 WikiText-103 数据集上, purity 达到了 0.75, 显著高于其他基线模型。该数据集的平均文本长度为 1 355.4, 其文本内容丰富、语义复杂, TIM_RAG 通过多视角主题生成策略和 ETP 推理机制, 增强了模型对复杂语义的理解能力, 从而更准确地识别和区分不同主题。在 20 Newsgroups 数据集上, TIM_RAG 的 purity 和 NMI 相较于 LLMs-for-TM 分别提升了 14.5% 和 5.7%, 验证了模型在处理多类别文本数据时的优越性。以上结果表明, TIM_RAG 不仅在主题生成质量上表现优异, 还在文档聚类任务中展现出更高的准确性和一致性, 充分证明了其在提升主题建模整体性能方面的显著优势。

另外, 在所有实验结果中, TIM_RAG(7B) 表现出了与 TIM_RAG 几乎相同的性能, 所有指标最大差距仅为 0.01, 证实了轻量化生成模型 GLM-7B 经训练后已达到其教师模型 ChatGPT 的效果, 在保持主题生成质量和聚类效果的同时, 显著降低了计算成本。

3.6 消融实验

为了验证生成阶段和推理阶段的性能, 本文进行了以下消融实验, 结果如表 6 和 7 所示。其中, -CoT 表示移除 RAG 生成阶段的多视角主题生成过程, 直接通过 ChatGPT 生成文档的候选主题; -ETP 表示移除 ETP 推理模块, 利用简单的 TF-IDF 方法进行计算; (7B) 表示将 GLM-7B 作为生成模型。

表 6 的结果表明, -CoT 的主题质量 (TC、TD、TQ) 显著下降, 特别是在 BBC News 数据集上, TC 指标的降幅最大, 达到了 7.3%。这一结果直接验证了多视角主题生成模块在解决 LLMs 黑盒推理导致的模型可解释性低下问题中的关键作用。具体而言, 该模块通过多模板任务提示引导 LLMs 从不同视角提取主题词并生成中间推理步骤, 而 -CoT 依赖 ChatGPT 直接生成主题词, 无法捕捉多角度语义信息, 导致主题多样性降低; 同时主题生成路径的缺失进一步削弱了模型的可解释性。-ETP 的下降程度要稍高于 -CoT, 表明 ETP 模块是增强模型可解释性的核心设计, 通过最优传输理论能够更精确地建模文档-主题和主题-词汇分布。而移除 ETP 后, 模型仅使用简单的 TF-IDF 方法计算主题分布, 无法捕捉深层语义关系, 导致主题分布偏离真实语义结构, 进而降低主题质量。此外, 完整的 TIM_RAG 在所有数据集中表现最佳, 验证了 CoT 和 ETP 模块的协同作用对主题生成的重要性。

表 6 TC、TD 和 TQ 的消融实验结果

Tab. 6 TC, TD and TQ results for ablation experiments

模型	WikiText-103			BBC News			20 Newsgroups		
	TC	TD	TQ	TC	TD	TQ	TC	TD	TQ
TIM_RAG	0.57	0.97	0.55	0.55	0.92	0.51	0.58	0.97	0.56
TIM_RAG(7B)	0.58	0.96	0.56	0.54	0.91	0.49	0.57	0.96	0.55
-CoT	0.55	0.95	0.52	0.51	0.88	0.45	0.54	0.95	0.51
-ETP	0.52	0.93	0.48	0.48	0.90	0.43	0.52	0.93	0.48
-ETP(7B)	0.52	0.92	0.48	0.49	0.89	0.44	0.52	0.91	0.47

表 7 purity 和 NMI 的消融实验结果

Tab. 7 purity and NMI results for ablation experiments

模型	WikiText-103		BBC News		20 Newsgroups	
	purity	NMI	purity	NMI	purity	NMI
TIM_RAG	0.75	0.41	0.59	0.73	0.63	0.56
TIM_RAG(7B)	0.74	0.40	0.59	0.71	0.63	0.55
-CoT	0.71	0.37	0.57	0.68	0.57	0.53
-ETP	0.73	0.39	0.54	0.70	0.60	0.52
-ETP(7B)	0.71	0.38	0.54	0.70	0.59	0.50




图 5 不同主题数量对模型 purity 分数的影响

Fig. 5 Influence of different topic numbers on model purity scores

通过对比不同主题数量下各模型的 purity 分数,发现在 [10,100] 内,主题数量的增加普遍提升了模型的主题划分性能。特别值得一提的是,TIM_RAG 在所有数据集和主题数量设置下均表现出了较高的 purity 分数,显示出其在处理不同数据集和主题数量时具有良好适应性。另外,WikiText-103 数据集的 purity 分数普遍高于 BBC News 和 20 Newsgroups,这可能与其文本特性、规模以及主题分布的多样性有关。WikiText-103 数据集包含了大量的文本数据,其文本内容丰富且涵盖了广泛的主题,为模型提供了更多的信息来学习和区分不同的主题。

3.8 案例研究

为了进一步验证 TIM_RAG 在实际应用中的价值,本节通过两个典型案例分析其在文本分类和舆情监测任务中的表现,展示其在实际场景中的适用性和优势。

3.8.1 基于主题分布的文本分类

为了评估 TIM_RAG 在主题表示学习中的有效性,本文将模型生成的主题分布应用于文本分类任务。该实验直接采用主题模型生成的文档-主题分布 $\theta^{(i)}$ 作为分类特征,将 WikiText-103、BBC News 和 20 Newsgroups 数据集的文档-主题分布按 8:2 划分训练测试集,并采用 SVM 分类器进行文本分类。结果如表 8 所示,TIM_RAG 在文本分类任务中表现出色,accuracy 和 F_1 分数均高于 FASTopic 和 TopicGPT 模型。这表明 TIM_RAG 生成的主题分布能够更好地捕捉文档的语义信息,从而提高分类性能。

表 8 accuracy 和 F_1 的文本分类结果Tab. 8 Accuracy and F_1 results for text classification

模型	WikiText-103		BBC News		20 Newsgroups	
	accuracy	F_1	accuracy	F_1	accuracy	F_1
FASTopic	0.74	0.70	0.72	0.70	0.60	0.53
TopicGPT	0.70	0.64	0.69	0.65	0.53	0.51
TIM_RAG	0.75	0.73	0.73	0.72	0.60	0.55

表 7 展示了消融实验的 purity 和 NMI 结果,主要从聚类效果的角度评估模型性能。-CoT 模型的聚类效果 (purity、NMI) 显著下降,例如在 WikiText-103 数据集上,purity 从 0.75 降至 0.71,NMI 从 0.41 降至 0.37。这表明直接依赖 ChatGPT 生成主题时,缺乏多模板提示引导的中间步骤,主题提取角度单一、多样性和准确性降低,导致模型聚类性能较差,进一步验证了多视角主题生成模块对解决黑盒推理问题的必要性。另一方面,-ETP 模型的性能同样出现明显衰减,表明最优传输理论的缺失导致的主题质量下降,进而影响了聚类效果,这充分验证了 ETP 通过最优传输理论建立的语义关系框架,对于提升模型可解释性具有不可替代的作用。

3.7 主题数量对模型性能的影响

为探究主题数量对模型性能的影响,本文分别在 10、20、50、100 个主题下进行了实验。鉴于 purity 能更准确评估模型在主题划分上的性能,这里采用 purity 作为主要评估指标。结果如图 5 所示。

3.8.2 基于主题分布的舆情监测

该案例研究旨在验证 TIM_RAG 在动态舆情监测场景下的语义捕捉能力。实验选取微博 36 h 内与“AI 伦理治理”相关的 10 万条实时文本作为监测对象,重点考察模型对舆情主题演化规律的捕捉能力。实验将监测周期划分为 0~12 h (初期讨论)、12~24 h (热点发酵) 和 24~36 h (观点分化) 三个时段,分别计算主题分布的聚合度与离散度,以此评估模型对舆情动态平衡特征的建模能力。表 9 的结果分析表明,TIM_RAG 在舆情监测任务中表现突出,其聚合度和离散度指标均优于 FASTopic 和 TopicGPT 模型,表明 TIM_RAG 能够更准确地识别核心主题并有效捕捉新兴主题的演变趋势。

表 9 主题聚合度和离散度的舆情监测结果

Tab. 9 Topic coherence and dispersion results for public opinion monitoring

模型	0~12 h		12~24 h		24~36 h	
	聚合度	离散度	聚合度	离散度	聚合度	离散度
FASTopic	-0.49	3.73	-0.68	3.29	-0.41	4.29
TopicGPT	-0.53	3.41	-0.73	2.75	-0.49	3.57
TIM_RAG	-0.49	3.79	-0.67	3.33	-0.39	4.42

案例研究表明,TIM_RAG 模型能够有效地应用于文本分类和舆情监测等实际应用场景。这表明 TIM_RAG 模型不仅能够生成高质量的主题,还能够将主题信息有效地应用于实际问题,并取得良好的效果。

4 结束语

本文提出了一种基于 RAG 的主题推理模型 TIM_RAG,旨在解决现有基于 LLMs 的主题建模方法中存在的两大核心问题:单文档分析导致的主题多样性不足与黑盒推理引发的模型可解释性低下。首先,在 RAG 检索阶段设计了多维文档相似度检索机制,通过检索相似文档丰富单篇文档的主题信息,缓解单文档分析导致的主题多样性局限。其次,在 RAG 生成阶段构建多视角主题生成,通过 CoT 引导 LLMs 从多视角生成中间推理步骤,生成质量更高的主题,间接提升模型可解释性;并

利用数据蒸馏技术训练了轻量化生成模型 GLM-7B, 实现效率优化。最后, 在独立推理阶段, 提出了嵌入传输计划推理方法, 将文档、主题与词汇嵌入统一向量空间, 并基于最优传输理论建模三者之间的语义关联, 从而显著提升模型可解释性。

TIM_RAG 的优势在于其模块化设计的灵活性与可扩展性。在 RAG 检索阶段的多维文档相似度检索机制中, 可以按照需求对检索方法进行增减; 在 RAG 生成阶段的多模板任务提示中, 可以针对不同的文本选择不同的角度, 只需要修改初始提示即可。但是, 模型计算的复杂度也主要来源于这两个阶段, 限制了其在大型数据集中的应用。在未来工作中, 将致力于降低模型的计算复杂度, 并探索更有效的 CoT 提示模板生成和优化方法, 以提高模型的泛化能力和效率。

参考文献:

- [1] Boyd-Graber J, Hu Yuening, Minmo D. Applications of topic models [J]. *Now Foundations and Trends in Information Retrieval*, 2017, 11(2-3): 143-296.
- [2] Blei D M, Ng A Y, Jordan M I. Latent Dirichlet allocation [J]. *Journal of Machine Learning Research*, 2003, 3(4-5): 993-1022.
- [3] Vargas C, Ponce H. Recurrent embedded topic model [J]. *Applied Sciences*, 2023, 13(20): 11561.
- [4] 刘佳琦, 李阳. 基于信息最大化变分自编码器的孪生神经主题模型 [J]. *计算机应用与软件*, 2020, 37(9): 118-125. (Liu Jiaqi, Li Yang. A siamese neural topic model based on information maximizing variational autoencoder [J]. *Computer Applications and Software*, 2020, 37(9): 118-125.)
- [5] Rajendran B, Vidya C G, Sanil J, et al. A local explainability technique for graph neural topic models [J]. *Human-Centric Intelligent Systems*, 2024, 4(1): 53-76.
- [6] 覃婷婷, 刘峥, 陈可佳. 结合主题词嵌入和注意力机制的主题模型 [J]. *计算机工程*, 2020, 46(11): 104-108. (Qin Tingting, Liu Zheng, Chen Kejia. Topic model combining topic word embedding and attention mechanism [J]. *Computer Engineering*, 2020, 46(11): 104-108.)
- [7] Touvron H, Martin L, Stone K, et al. Llama2: open foundation and fine-tuned chat models [EB/OL]. (2023-07-18) [2025-03-15]. <https://arxiv.org/abs/2307.09288>.
- [8] 龙禹辰, 勾智楠, 陈宇欣, 等. 基于大语言模型的多任务生成式重构对话情绪识别 [J]. *计算机应用研究*, 2025, 42(7): 1964-1971. (Long Yuchen, Gou Zhihan, Chen Yuxin, et al. Multi-task generative emotion recognition in conversation based on large language models [J]. *Application Research of Computers*, 2025, 42(7): 1964-1971.)
- [9] Yang Xiaohao, Zhao He, Xu Weijie, et al. Neural topic modeling with large language models in the loop [EB/OL]. (2024-11-13) [2025-03-15]. <https://arxiv.org/abs/2411.08534>.
- [10] Rijcken E, Scheepers F, Zervanou K, et al. Towards interpreting topic models with ChatGPT [C]// Proc of the 20th World Congress of the International Fuzzy Systems Association. 2023: 269-275.
- [11] Wang Han, Prakash N, Hoang N K, et al. Prompting large language models for topic modeling [C]// Proc of IEEE International Conference on Big Data. Piscataway, NJ: IEEE Press, 2023: 1236-1241.
- [12] Pham C, Hoyle A, Sun Simeng, et al. TopicGPT: a prompt-based topic modeling framework [C]// Proc of Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg, PA: Association for Computational Linguistics, 2024: 2956-2984.
- [13] Mu Yida, Dong Chun, Bontcheva K, et al. Large language models offer an alternative to the traditional approach of topic modelling [C]// Proc of Joint International Conference on Computational Linguistics, Language Resources and Evaluation. 2024: 10160-10171.
- [14] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks [C]// Proc of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2020: 9459-9474.
- [15] Gao Yunfan, Xiong Yun, Gao Xinyu, et al. Retrieval-augmented generation for large language models: a survey [EB/OL]. (2024-12-18) [2025-03-15]. <https://arxiv.org/abs/2312.10997>.
- [16] Wang Xiaohua, Wang Zhenghua, Gao Xuan, et al. Searching for best practices in retrieval-augmented generation [C]// Proc of Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2024: 17716-17736.
- [17] Wei J, Wang Xuezh, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models [C]// Proc of the 36th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2022: 24824-24837.
- [18] Kojima T, Gu S S, Reid M, et al. Large language models are zero-shot reasoners [C]// Proc of the 36th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2022: 22199-22213.
- [19] Zhang Zhuosheng, Zhang A, Li Mu, et al. Automatic chain of thought prompting in large language models [C]// Proc of the 11th International Conference on Learning Representations. 2025.
- [20] Hinton G E, Vinyals O, Dean J. Distilling the knowledge in a neural network [EB/OL]. (2015-03-09) [2025-03-15]. <https://arxiv.org/abs/1503.02531>.
- [21] Robertson S, Zaragoza H. The probabilistic relevance framework: BM25 and beyond [J]. *Foundations and Trends® in Information Retrieval*, 2009, 3(4): 333-389.
- [22] Yan Yuanmeng, Li Rumei, Wang Sirui, et al. ConSERT: a contrastive framework for self-supervised sentence representation transfer [C]// Proc of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2021: 5065-5075.
- [23] Wu Xiaobao, Nguyen T T, Zhang D Z, et al. FASTopic: pretrained transformer is a fast, adaptive, stable, and transferable topic model [C] // Proc of the 38th Annual Conference on Neural Information Processing Systems. 2024.
- [24] Grootendorst M. BERTopic: neural topic modeling with a class-based TF-IDF procedure [EB/OL]. (2022-03-11) [2025-03-17]. <https://arxiv.org/abs/2203.05794>.
- [25] Wu Xiaobao, Dong Xinshuai, Nguyen T, et al. Effective neural topic modeling with embedding clustering regularization [C]// Proc of the 40th International Conference on Machine Learning. [S. l.]: JMLR. org, 2023: 37335-37357.
- [26] Chang Shuyu, Wang Rui, Ren Peng, et al. A large language model guided topic refinement mechanism for short text modeling [EB/OL]. (2024-03-26) [2025-04-25]. <https://arxiv.org/abs/2403.17706>.
- [27] 刘良选, 黄梦醒. 融合词向量特征的双词主题模型 [J]. *计算机应用研究*, 2017, 34(7): 2055-2058. (Liu Liangxuan, Huang Mengxing. Biterm topic model with word vector features [J]. *Application Research of Computers*, 2017, 34(7): 2055-2058.)
- [28] 刘阳. 基于预训练 BERT 的神经主题模型研究 [D]. 长春: 长春工业大学, 2024. (Liu Yang. Research on neurotopic model based on pre-training BERT [D]. Changchun: Changchun University of Technology, 2024.)