

融合大语言模型的政策文本检索增强生成研究^{*}

沈 思¹ 冯暑阳¹ 吴 娜² 赵志泉²

¹(南京理工大学经济管理学院 南京 210094)

²(南京农业大学信息管理学院 南京 210095)

摘要:【目的】为提高政务信息资源的利用效率及推动政府服务智能化转型,本文针对通用大语言模型在处理政策文本时存在的知识局限,探索融合大语言模型的政策文本检索增强生成技术的有效性,旨在构建更精准、可靠的智能政策问答模型。【方法】基于政策大模型 ChpoGPT,提出一种政策文本检索增强生成框架 Policy-RAG,将政策文档知识库与用户提问进行语义相似度匹配检索,并将检索结果与 ChpoGPT 相结合以增强模型下游任务能力。【结果】该框架在事实一致性、答案相关性和语义相似性等指标上均优于现有模型,其中 ChpoGPT 模型在事实一致性得分达到近 90%;答案相关性得分达到 80.2%,较 Gemini-1.0-pro 模型提高 2.1 个百分点;答案语义相似性得分达到 56.4%,相较于 ERNIE 4.0 模型和 Gemini-1.0-pro 模型分别提升 4.1 和 2.8 个百分点。【局限】通过分析相应实验结果,发现语言模型在回答输出上仍存在一定不可控性。【结论】融合大语言模型的政策文本检索增强生成在政府服务智能化转型中具有一定的应用参考价值,但仍需要进一步改进和优化。

关键词: 大语言模型 检索增强生成 自然语言处理 政策文本

分类号: TP391 G250

DOI: 10.11925/infotech.2096-3467.2024.0670

引用本文: 沈思,冯暑阳,吴娜等.融合大语言模型的政策文本检索增强生成研究[J].数据分析与知识发现,2025,9(9):37-48.(Shen Si, Feng Shuyang, Wu Na, et al. Retrieval-Augmented Generation of Policy Texts Based on Large Language Models[J]. Data Analysis and Knowledge Discovery, 2025, 9(9): 37-48.)

1 引言

数字信息时代,政务信息资源承载着政府的重要业务活动信息,是政府服务智能化转型发展中的核心要素^[1]。作为政务信息资源中必不可少且关键的一类资源,政策文本的挖掘和利用是当前研究的一大热点。对于政策文本的组织 and 利用,由于其体系庞大、篇幅较长、信息量大、冗余度高且内涵价值分布不均,造成信息组织加工困难、信息检索及利用效率低下、语义理解不足等问题^[2],不利于大规模政策文本的信息挖掘及政策价值发挥。传统检索系统虽对政策文本进行一定的序化和加工,但返回的结

果往往也与用户的实际需求有所出入。因此,如何提高政策文本的检索和利用效率,以及如何改善生成质量和用户体验,是当前亟待解决的问题。

近年来,大语言模型(Large Language Model, LLM)在自然语言处理领域的成功应用为解决这些问题提供了新的可能性。政策文本的语义复杂性和主题多领域性使其对检索精确性的要求更为严格,而大语言模型通过其出色的语义理解和上下文理解能力,为政策文本的组织 and 利用带来了新的契机。大语言模型在自然语言处理、图像处理等领域的通用任务中取得了一系列突破,主要包括检索增强、语

通讯作者(Corresponding author): 沈思(Shen Si), ORCID: 0009-0003-3554-4307, E-mail: shensi@njust.edu.cn。

^{*}本文系国家自然科学基金面上项目(项目编号: 71974094)的研究成果之一。

The work is supported by the National Natural Science Foundation of China (Grant No. 71974094).

义推理、案例分析、机器翻译等,被广泛用于文本生成、智能助手等实际场景中^[3]。然而,对于专业垂直领域,其语义表示和理解生成能力受训练语料影响较大,因此需要针对特定领域进行微调和优化,才能取得更好的效果。在上述背景下,本文提出一种基于大模型的政策文本检索增强生成框架 Policy-RAG,旨在挖掘大语言模型在政策文本领域检索的潜在优势,探索提升政策文本检索和利用效率的有效方法;同时,从事实一致性、答案相关性和语义相似性几个角度,验证了该框架的合理性。

2 相关研究

2.1 政策文本的相关定量研究

目前,对政策文本的研究主要包括数据统计和数据分析,涵盖了从基于单篇文本的微观统计到特定领域大规模文本的宏观计量等多种方法。数据统计主要采用文献计量、社会网络分析等量化分析方法,而数据分析则侧重于从政策文本的标题、发布部门等外部特征和具体内容入手,通过政策文本挖掘等方法,发掘其分布规律和潜在知识。

文献计量研究旨在将传统的文献计量方法应用于政策文本,并在此基础上进行创新。裴雷等^[4]提出政策文本计算,将自然语言处理技术与传统的社会科学研究方法相结合,为政策文本分析提供了新的视角。李江等^[5]提出运用政策计量(Policimetrics)的研究思路揭示政策引用、主题共现以及机构共现等政策关系。

社会网络分析同样采用文献计量方法,但其更侧重于从宏观视角揭示政策文本中的关系网络和语言关联,关注行为主体之间的联系。吴建南等^[6]采用社会网络分析方法,以搭建治理主体与治理举措之间的二模关系网络为出发点,从而描绘国家治理体系现代化的整体思路。李小宇^[7]借助情报学的文本挖掘和内容分析方法建立三维政策演化模型,揭示网络信息内容监管体制的功能结构特征和演化脉络,进而构建三层级的政策体系结构以描绘监管政策的历史演变。

然而,传统的定量分析方法存在人力成本高、信息抽取方式过于简单、内容细节容易被忽视等问题。为了克服这些局限性,部分学者尝试将文本挖掘技

术应用于政策研究。杨慧等^[8]对政策文本数据进行基于语义的主题挖掘,并同时融合词频及分布形态研究、时间离散化、实证研究等方法综合对比分析中国与美国、欧盟的气候政策情况。张祥祥^[9]使用领域命名实体识别技术获取科技领域政策文本中的关键实体知识,以提高模型在科技领域政策文本上的摘要生成质量。

上述研究为政策文本的量化分析提供了重要的参考价值。然而,传统的定量分析方法仍然存在一定的局限性,限制了对政策文本的深层次理解和利用。而本文结合大语言模型和检索增强生成技术,为政策文本的分析和应用提供新的思路和方法。

2.2 政策文本检索的相关研究

在检索领域,传统算法模型,如倒排索引^[10]、TF-IDF(Term Frequency-Inverse Document Frequency)^[11]算法、BM25^[12]等仍广泛应用,但深度学习模型也展现出巨大的潜力。通过使用神经网络模型^[13],特别是Transformer架构,检索系统能够更精准地匹配文档与用户查询。此外,知识图谱^[14]和语义理解技术的发展进一步提升了系统对文本语义信息的理解能力,从而提高检索结果的质量。在政策领域,由于政策文本涵盖政府部门机构制定和发布的具有法律效力或指导意义的各种法规、规章、政策文件等,其数据量巨大且内容复杂多样,涉及政治、经济、社会和文化等多个领域。而政策的不断更新与废止又增加了政策的动态性,需要及时跟踪和更新。针对大量政策数据,传统检索方法存在信息处理效率低、语义理解不足等问题。

此外,在实际应用场景中,传统的政策文本检索也难以满足用户的需求。例如,国内许多省市的政务服务平台为用户提供了智能政策服务助手,其初衷是帮助用户解答政策相关的问题,然而基于统计学的问答模型往往难以完全满足用户的需求。这类模型通常使用关键词匹配等传统检索方法,但在跨领域、多主题的政策文本中,很难准确找到符合用户语义需求的目标。

近年来,以Transformer架构为基础的大语言模型,如GPT(Generative Pre-trained Transformer)等,推动了信息检索技术的革新。特别是基于密集向量的检索(Dense Retrieval)方法,为解决传统检索难以

处理的语义匹配、长尾查询^[15-16]等问题提供了有效的方案^[17]。检索增强生成(Retrieval-Augmented Generation, RAG)^[18]这一技术通过结合检索和生成两个关键点,为政策文本这类特定领域提供了新的解决方案。相较于传统的检索技术,检索增强生成技术能够更好地理解问句语义,根据来自多个文档的相关信息回答,而不是提前编制好答案或者返回单纯的文档内容。其可通过搜索外部信息源(如网页或数据库)针对相关知识进行检索,并将外部信息通过构建提示词(Prompt)融入大模型生成的回答中,从而提供更准确、更贴近用户语义需求的答案。同时,大语言模型强大的语义理解能力使其能够准确把握政策文本中的语义关系,通过关键词和主题的抽取,帮助用户理解政策文本中的关键条款或

政策内容。大模型与检索的结合也为个性化推荐^[19]、多语言检索^[20]等方面带来了新的机遇,使得检索系统能够更好地适应不同用户和多样化需求^[21]。然而,大模型与检索结合也面临挑战。例如,如何在保证检索效率的同时,运用大模型处理复杂的语义匹配和推理问题^[22]。此外,大模型问答系统在资源受限的设备和场景下的部署和应用也面临难题^[23]。

本文重点探讨大语言模型和检索增强技术在政策文本检索领域内的运用以及效果,为政策文本检索提供新的思路和方法。

3 融合大模型的政策文本检索增强生成

3.1 研究框架

整体研究框架如图 1 所示。




图 1 研究框架图

Fig.1 Research Framework

(1)数据收集:使用网络爬虫技术获取政策正文数据和政策问答数据,对数据进行人工清洗、标注和校验,构建高质量的政策领域数据集。

(2)检索增强生成流程设计:可细分为知识库构

建管理与检索生成框架设计两部分。知识库构建管理模块负责将清洗后的政策文本进行结构化处理和向量化,构建成一个可供高效检索的向量数据库。检索生成框架则负责处理用户的实时请求。它首先

优化用户查询,即查询重写(Query Rewriting);然后从知识库中检索语义最相关的政策上下文。检索到的内容与查询被用于共同构造提示词,送入大语言模型生成答案。最后,通过事实性校验环节,将生成的答案与原始检索文档进行比对,以确保最终输出的准确性和可靠性。

(3)下游任务验证:将本文提出的 Policy-RAG 框架与政策领域的下游任务相结合,如政策问答、观点总结、政策文件阅读理解和政策主题分类等,以考查其在下游任务中的应用效果和性能。

3.2 Policy-RAG 框架

在此研究框架的基础上,本文提出的 Policy-

RAG 框架流程如图2所示。RAG 的运作机制可概括为检索-排序-生成三步骤。即先针对输入文本,从知识库中检索语义相关的文档段落;再对检索到的文本片段进行排序,以筛选出与输入文本最相关的候选信息;最后将经过筛选的文本片段作为上下文语境,使大语言模型根据用户输入生成最终的输出文本。

Policy-RAG 框架由索引器、检索器和生成器三大组件构成,索引器负责从政策文档中提取文本数据,并将其转换为向量索引,进而创建政策文档库;检索器根据用户查询从政策文档库中检索相关上下文信息;生成器,即大语言模型(LLM),根据检索到的上下文信息和用户输入生成最终的答案。




图2 Policy-RAG 流程图

Fig.2 Policy-RAG Progress

(1) RAG 文本索引器

为应对政策文本的长文本、多主题特性,本文索引器采用滑动窗口机制处理文本。使用 bge-base-zh-v1.5 词嵌入模型将每个窗口的文本片段转换为向量,并存入向量数据库。检索时,通过计算查询向量与窗口向量的相似度,找出最相关的文本块作为上下文,以解决长文本处理难题并提升检索精度。

(2) RAG 检索器

本研究的 RAG 检索器遵循一个精细化的检索流程。首先,使用与索引器相同的嵌入模型将用户查询向量化,以保证向量空间的一致性。然后,通过余弦相似度计算,检索出 Top-K 个最相关的候选文档片段。

为进一步优化性能,引入查询重写和重新排序(Re-ranking)两种策略。查询重写即在检索前,利用大语言模型对原始查询进行语义扩展和重写,从而将用户输入转换为更具专业性、领域性的检索表达。

重新排序即在检索后,使用一个重新排序模型对初步检索到的 Top-K 文档片段进行二次排序,确保最终输入给生成器的上下文是与问题最相关的,从而提升生成答案的质量。

(3) RAG 生成器

本文的生成模块负责整合用户查询与检索到的上下文,并构建提示词以生成最终答案。该模块采用可插拔式设计,支持接入多种大语言模型 API(如 GPT-3.5、文心一言等),便于进行性能对比。

在 Policy-RAG 框架中,选用 ChpoGPT^[24] 作为核心生成器。ChpoGPT 中文政策大语言模型基于通义千问 Qwen-7B 模型在政策领域微调得到,该开源模型托管于 ModelScope。

最终,Policy-RAG 框架通过政策文本索引构建、相关知识检索和大模型生成三个模块的协同工作,实现基于检索增强生成的政策文本问答功能。该框架利用向量嵌入模型和语义相似度检索策略,保证

检索结果的准确性和效率。同时,模块化的设计使得 Policy-RAG 框架能够灵活地接入不同的预训练大语言模型,便于进行性能对比和优化。此外,通过多次调整检索及模型参数,检索模型输出相关参数如表 1 所示。

表 1 检索及模型输出参数

Table 1 Parameters Settings

参数名称	参数含义	参数值
retrieve_topk	保留作为候选的最高概率结果的数量	100
window_size	生成文本时考虑的前后文本片段的长度	4
rerank_topk	保留作为候选的重排最高概率结果的数量	15
Embedding_dim	嵌入模型的维度	768
temperature	控制 Softmax 输出的差距	0.05

通过将训练得到的政策大模型接入, Policy-RAG 框架能够结合检索和生成技术,实现高效的政策信息获取和处理。

4 实验

4.1 数据集

(1) 数据源

本文使用的政策数据来源于中国政府网、外交部、国防部、国家发展和改革委员会、教育部、科学技术部等官方网站。数据收集工作借助网络爬虫工具八爪鱼平台完成。首先确定目标网站和数据采集范围,包括国务院政策问答平台、问答专题网站、政策解读专栏以及各部门网站公布的政策信息和问答专栏等。然后制定针对性的数据爬取规则,自动提取目标网页中的政策文本内容,包括政策标题、正文、发布时间、发布机构等信息。

收集到的数据主要包括两类:政策正文数据和政策问答数据。政策正文数据涵盖法规、政策文件、行政命令等政府发布的正式政策文本,其内容通常经过严谨的法律和政策制定程序,具有较高的客观性和权威性。政策问答数据则包含公众和政策制定者提出的与政策相关的问题和解答,以问答形式展现,内容更具多样性和主观性。

原始数据存在格式不统一、信息冗余、噪声数据等问题。为了提高数据质量,本文对原始数据进行以下清洗操作:数据去重,通过比对文本内容,去除重复的政策文本数据;格式清理,统一文本格式,删

除无关字符,处理 HTML 标签等,使文本内容更加规范;噪声数据处理,识别并删除与政策无关的文本信息,如网站导航、广告信息等;数据校验,对清洗后的数据进行人工校验,确保数据的准确性和完整性。

经过数据采集和清洗,最终得到政策正文数据集和政策问答数据集。其中,政策正文数据集包含 167 998 份政策文本,政策问答数据集包含 15 859 条问答数据。

(2) 检索增强数据集

为了引导大语言模型生成更符合政策问答规范和用户需求的答案,本文构建一个包含 300 条数据的政策检索增强数据集。与预训练阶段使用的海量数据不同,该数据集并非用于向模型注入新的政策知识,而是用于微调模型,使其学习政策问答的特定格式、语言风格和信息组织方式。

该数据集基于高质量的政策问答数据,采用人工标注 JSON 文件的方式进行构建,并使用 GPT-4 作为辅助工具,以确保标注的准确性和一致性。检索增强数据集的标注格式为<reference, instruction, input, output>。其中,reference 为与用户输入相关的政策条文,instruction 为构造的提示信息,input 代表用户提问,output 代表模型的回答。该数据集示例如表 2 所示。

该数据集为每个问题提供了相关的政策条文引用和构造的提示信息,为模型微调提供更丰富的上下文信息,有利于模型更好地理解政策文本和用户查询语句之间的语义关系。最终模型能够拥有从政策条文中提取关键信息、组织连贯且易于理解的政策解释等能力。

(3) 验证数据集

为了验证 RAG 应用的性能,需要使用数据集进行评估。为了实现准确的评估,本文依据 RAG 三元组规则构建了验证数据集。该数据集独立于检索增强数据集,其包含 Query、Context 和 Response 三元组,其中用户提出 Query 问题,RAG 系统检索召回 Context 文本,最后 LLM 通过 Context 生成符合 Query 的 Response 结果。其基本关系如图 3 所示。

基于图 3 中的 RAG 三元组结构,本文加入 Ground-Truth 基准事实回答,从而可以将 RAG 应用生成的回答与 Ground-Truth 基准事实进行相关性对

表2 检索增强数据集示例

Table 2 RAG Datasets Example

属性	文本
reference	《生态环境部建设项目环境影响报告书(表)审批程序规定》### 第六条 建设单位向生态环境部申请报批环境影响报告书(表)的,除国家规定需要保密的情形外,应当…… 《生态环境部建设项目环境影响报告书(表)审批程序规定》### 第七条 生态环境部对建设单位提交的申请材料,根据下列情况分别作出处理: (一)依法不需要编制环境影响报告书(表)的,应当即时告知建设单位不予受理……
instruction	假如你是一名政府部门的工作人员,请根据以下提问,引用相关政策中的内容,保持耐心并且详细具体地回答相关问题。
input	建设项目环评文件申请受理需要提交哪些材料?
output	建设单位在报送环评文件申请受理时,需提交环境影响报告书(表),审查的请示文及删除涉密内容的说明等……




图3 基本RAG三元组

Fig.3 Basic RAG Triplet

比,更能体现用户体验度。

通过对前文收集的政策问答数据进行标注和整理,并结合以上原理,最终构建包含100条数据的验证集。该验证集的基本属性为<question, contexts, answer, ground_truths>,其中 contexts 和 answer 由RAG程序自动生成,question与ground_truths来自国务院问答平台的问答对。验证集示例如表3所示,最终RAG应用的效果将通过相关指标进行评估。

4.2 评测指标

本文重点关注信息检索与垂直领域大模型的融合,因此更注重对大模型生成效果的评估,即RAG的评测,而非传统评估方法。部分重要指标如下。

(1) 事实一致性

事实一致性(Faithfulness)指标衡量生成答案与给定上下文之间的事实一致性。该指标通过对答案和检索到的上下文进行计算得出。答案的值被缩放到(0,1)区间,值越高表示事实一致性越好。

如果生成答案中提出的所有表述都能从给定上下文中推断出来,则认为该答案是与事实一致的。为了计算该指标,首先需要识别出生成答案中的一组表述。然后,将这些表述分别与上下文进行交叉检查,以确定其是否可以从给定上下文中推断出来。

事实一致性得分的计算如公式(1)所示。

$$F = \frac{1}{|C_a|} \sum_{i=1}^{|C_a|} I(C_{a_i} \in C_c) \quad (1)$$

其中, F 表示事实一致性得分; C_a 表示从生成答案中识别出的所有表述集合; C_c 表示给定上下文; I 表示生成答案中可以从给定上下文中推断出的论点。

(2) 答案相关性

答案相关性(Answer Relevance)旨在评估生成答案与给定问题的相关程度。不完整、包含冗余信息或与问题无关的答案会获得较低的答案相关性分数,而较高的分数则表示答案与问题相关性更高。该指标的公式定义为原始问题与一系列基于答案逆

表3 验证集示例

Table 3 Validation Datasets Example

属性	文本
question	建设项目环评文件申请受理需要提交哪些材料?
contexts	RAG程序自动生成
answer	RAG程序自动生成
ground_truths	建设单位在报送环评文件申请受理时,需提交环境影响报告书(表),审查的请示文及删除涉密内容的说明等……

向生成的人工问题之间的平均余弦相似度,具体计算如公式(2)所示。

$$\begin{aligned} \text{Answer Relevancy} &= \frac{1}{N} \sum_{i=1}^N \cos(\mathbf{E}_{g_i}, \mathbf{E}_o) \\ &= \frac{1}{N} \sum_{i=1}^N \frac{\mathbf{E}_{g_i} \cdot \mathbf{E}_o}{\|\mathbf{E}_{g_i}\| \|\mathbf{E}_o\|} \end{aligned} \quad (2)$$

其中, $\mathbf{E}_{g_i}$ 为生成问题的向量嵌入; $\mathbf{E}_o$ 为原始问题的向量嵌入; N 为生成问题的数量,默认为 3。

(3) 上下文精确度

上下文精确度(Context Precision)用于衡量所有与基准事实相关的上下文是否被排列在靠前的位置。理想情况下,所有相关的信息块都应出现在排名的前列。该指标根据问题、基准事实和上下文来计算,其值在 $[0, 1]$, 其中更高的分数表明更高的精确度。

设 T 为前 K 个结果中相关信息块的总数,则上下文精确度得分如公式(3)所示。

$$\text{Context Precision@K} = \frac{\sum_{k=1}^K (\text{Precision@K} \times v_k)}{T} \quad (3)$$

其中, K 表示上下文中信息块的总数; v_k 表示在排名处的相关性指示,其值为 1 或 0,表示该位置的信息块是否相关。此外,通过混淆矩阵,可以将全部预测结果分为 4 类,其中预测为该类别且实际为该类别即为 TP , 预测为该类别但实际非该类别即为 FP , 则 Precision@K 的计算如公式(4)所示。

$$\text{Precision@K} = \frac{TP@K}{TP@K + FP@K} \quad (4)$$

(4) 答案语义相似性

与上述不同的是,答案语义相似性(Answer

Semantic Similarity)是用于评估用户体验的指标,其定义为生成答案与基准事实之间的语义相似性。这一评估是基于基准事实和答案进行的,其值在 $[0, 1]$ 区间。答案语义相似性得分越高,表明生成答案与基准事实之间的一致性越好,如公式(5)所示。

$$\begin{aligned} \text{Answer Semantic Similarity} &= \cos(\mathbf{E}_{g_i}, \mathbf{E}_{gt}) \\ &= \frac{\mathbf{E}_{g_i} \cdot \mathbf{E}_{gt}}{\|\mathbf{E}_{g_i}\| \|\mathbf{E}_{gt}\|} \end{aligned} \quad (5)$$

其中, $\mathbf{E}_{g_i}$ 是生成答案的向量嵌入; $\mathbf{E}_{gt}$ 是基准事实的向量嵌入。

需要注意的是,以上部分指标的计算需要高性能大语言模型(如 GPT-4)的参与,因此数值具有一定的波动性。然而,通过多次评测,能够在一定程度上反映 RAG 应用的真实性能。

4.3 实验结果

(1) 指标评测结果分析

基于前期构建的测评数据集,通过各项指标对 Policy-RAG 框架进行评测。为了更好地进行效果对比,本文分别使用 ChpoGPT 与百度、谷歌所训练的大语言模型,即文心一言与 Gemini 进行对比,将文心一言 ERNIE 4.0 与 Gemini-1.0-pro 的应用程序接口(Application Programming Interface, API)接入 Policy-RAG 框架。

为了更全面地评估 Policy-RAG 框架的性能,本文还设置了基线模型进行对比实验。基线模型不接入政策文档库,这里仅使用 ChatGPT-3.5 模型根据给定的 Prompt 直接生成答案。由于基线模型不涉及检索环节,因此无法计算上下文精确度指标。

经过多轮评测,平均结果如表 4 所示。

表 4 平均指标得分

Table 4 Metric Score

指标类别	Policy-RAG			基线模型
	ERNIE 4.0	Gemini-1.0-pro	ChpoGPT	ChatGPT-3.5
Faithfulness	86.8%	88.4%	89.3%	83.3%
Answer Relevance	79.7%	78.1%	80.2%	67.5%
Context Precision	76.8%	76.4%	76.5%	N/A
Answer Semantic Similarity	52.3%	53.6%	56.4%	23.8%

实验结果表明,Policy-RAG 框架相较于基线模型 ChatGPT-3.5,在政策文本生成方面的性能得到显

著提升。Policy-RAG 框架在结合 ERNIE 4.0、Gemini-1.0-pro 和 ChpoGPT 三个模型后,在事实一

致性指标上分别取得 3.5、5.1 和 6.0 个百分点的提升;在答案相关性指标上实现了 12.2、10.6 和 12.7 个百分点的提升;在答案语义相似性指标上更是获得了 28.5、29.8 和 32.6 个百分点的巨大进步。这表明, Policy-RAG 框架能够有效利用外部政策文档库,为模型提供更精准、更丰富的上下文信息,进而生成更具相关性以及更高专业度的答案。

与此同时,各模型在事实一致性指标上表现较为出色,这主要归因于模型的温度参数设置较低。较低的温度参数限制了输出的多样性和随机性,促使模型更严格地遵循检索到的上下文进行回答,从而保证了答案的稳定性。值得注意的是,经过预训练和微调的 ChpoGPT 模型在事实一致性指标上甚至略优于参数量更大的语言模型,这有力地证明了垂直领域大模型在政策领域的有效性和可行性。

各模型的上下文精确度得分相差不大,这主要是因为该指标主要衡量 RAG 应用的检索效果,即检索到的文本与查询的相关程度。这一点从侧面反映了检索模块本身的性能表现较为稳定。

在答案相关性得分上,ChpoGPT 模型应用性能略优。这可能是 ChpoGPT 模型使用更多与政策领域相关的语料进行预训练,使其在处理政策问答任务时能够更好地理解政策文本的专业术语和表达方式。而将答案相关性与其他指标进行对比,发现普遍低于事实一致性指标但高于上下文精确度指标。这表明模型能够较好地理解问题的语义,并根据检索到的上下文生成相关的答案,而不仅仅是简单地复制粘贴检索结果,但还需要进一步提升答案与问题的相关性。

在答案语义相似性指标上,ChpoGPT 模型取得了最高的得分,其次是 Gemini-1.0-pro 模型,最后是 ERNIE 4.0 模型。这表明 ChpoGPT 模型在生成与基准事实语义相似的答案方面更为精准。同答案相关性一样,模型在预训练阶段所使用的数据来源和预训练方式也会影响其语义理解能力。

同时,可以观察到答案语义相似性得分相对较低,这与政策数据的特点相吻合。因为该指标的计算涉及基准事实(Ground-Truths),而数据中的基准事实主要来自国务院问答平台的问答对,其回答具有较强的主观性。而模型的回答则基于现有数据库

中的政策条文,更加客观和规范。这种主观性和客观性之间的差异导致了语义相似性得分偏低。为了提升该指标,可以考虑从数据层面进行改进,如引入更加客观和多样化的数据源,并对基准事实进行细化和标注。

总体而言, Policy-RAG 框架相较于通用大模型(以 ChatGPT-3.5 为例)性能提升显著,在事实一致性和上下文精确度等指标上表现良好,但在答案语义相似性方面仍有提升空间。这说明模型微调和数据集构建对于检索增强系统的至关重要性。未来可以从数据层面和模型层面进行优化,进一步提升系统在政策问答领域的性能。

(2) 输出结果分析

Policy-RAG 框架可在多种应用场景中为不同用户提供服务,为了更直观地展示 Policy-RAG 的应用,本节展示其与通用大模型(以 ChatGPT-3.5 为例)在政策专业工具、政策咨询两种场景中的部分案例对比。

政策专业工具场景中, Policy-RAG 通过提供高级工具,可简化政府机构的工作,包括提取政策主体、分析政策、寻找同类政策、生成摘要等。提取政策主体与生成摘要的案例对比如表 5 所示。

表 5 展示了 Policy-RAG 和 ChatGPT-3.5 在政策主体提取和摘要生成任务上的输出结果。可以看出, Policy-RAG 框架在准确性、完整性和可理解性方面优于通用大模型 ChatGPT-3.5。在政策主体提取任务中, Policy-RAG 框架能够准确识别所有政策主体及其对应职责,而 ChatGPT-3.5 模型则存在信息遗漏。在摘要生成任务中, Policy-RAG 框架生成的摘要信息更完整,涵盖了政策核心内容,语言表达也更流畅自然。

在政策咨询场景中,智能政策工具可以帮助企业通过及时了解政策动态,评估和降低政策风险,为经营决策提供有力支持;也能够为公众提供迅捷、准确的政策咨询和解答服务,助力他们了解和参与政策讨论和决策。政策咨询问答的案例如表 6 所示。

表 6 展示了 Policy-RAG 和 ChatGPT-3.5 在政策咨询场景下的问答示例。 Policy-RAG 框架能够准确列出政策要求,并提供相关政策文件来源,确保了答案的可靠性。相比之下, ChatGPT-3.5 模型的回答则

表 5 Policy-RAG 输出对比(政策专业工具场景)

Table 5 Policy Domain Output		
输入	ChatGPT-3.5 输出	Policy-RAG 输出
从以下政策原文中提取政策主体,并生成摘要。 政策原文:国务院办公厅关于同意广西壮族自治区县际间海域行政区域界线的通知国办函[2011]124号 广西壮族自治区人民政府,国土资源部、海洋局:国土资源部《关于报请批准广西壮族自治区县际间海域行政区域界线的请示》(国土资发[2011]127号)收悉。 经国务院同意,现通知如下:一、同意广西壮族自治区北海市铁山港区和合浦县间等6条县际间海域行政区域界线。二、广西壮族自治区人民政府要按照《行政区域界线管理条例》和海洋管理法律法规的规定,落实管理责任,依法加强海域行政区域界线管理,健全维护涉界海域社会稳定的协调机制,及时妥善处理涉海界线纠纷,合理开发利用海洋资源,保护和改善海洋生态环境,促进界线附近海域社会稳定和海洋经济可持续发展。三、国家海洋局要加强对广西壮族自治区人民政府海域行政界线管理工作的指导和协调,做好相关督促检查工作。	政策主体: 国务院办公厅、广西壮族自治区人民政府、国土资源部、海洋局、国家海洋局 摘要: 国务院办公厅同意了广西壮族自治区6条县际间海域行政区域界线。广西壮族自治区人民政府需按照相关法律法规,加强海域界线管理,解决涉海纠纷,合理开发利用海洋资源,维护海洋生态环境,促进社会稳定和海洋经济可持续发展。国家海洋局将对广西壮族自治区海域界线管理工作进行指导和协调,并开展督促检查。	主体提取: 国务院办公厅:发布通知,同意广西壮族自治区县际间海域行政区域界线。 广西壮族自治区人民政府:负责落实管理责任,依法加强海域行政区域界线管理。 国土资源部:负责提交界线划定请示。 国家海洋局:负责指导和协调广西壮族自治区海域行政区域界线管理工作,并进行督促。 摘要生成: 国务院同意广西壮族自治区北海市铁山港区和合浦县间等6条县际间海域行政区域界线,并要求广西壮族自治区人民政府按照相关法律法规的规定,落实管理责任,加强海域行政区域界线管理,维护涉界海域社会稳定,保护海洋生态环境,促进海洋经济可持续发展。国家海洋局将指导和协调广西壮族自治区人民政府的海域行政界线管理工作,并进行督促检查。

表 6 Policy-RAG 输出对比(政策咨询场景)

Table 6 Policy Consultation Output		
输入	ChatGPT-3.5 输出	Policy-RAG 输出
药品上市许可持有人如何委托开展不良反应监测工作?	药品上市许可持有人可以委托第三方专业机构或组织,如医疗机构、药品监测机构等,开展不良反应监测工作。通常,药品上市许可持有人会与这些专业机构签订合同,明确监测工作的内容、范围、方法、报告要求等细节,并确保监测工作符合相关法规和标准。这样的委托可以帮助药品上市许可持有人及时了解 and 掌握药品在市场上的使用情况,及时发现和报告不良反应,保障药品的安全性和有效性。	药品上市许可持有人委托开展不良反应监测工作的具体要求如下: 1 持有人应当对委托的不良反应监测工作选择具备相应资质和能力的监测机构进行合作。监测机构应当具备相关专业技术和设备,能够准确、及时地收集、记录和分析药品不良反应信息。 2 持有人应向所在地省级药品监管部门提交委托不良反应监测工作的申请,并提供相关的合作协议、监测机构的资质证明以及监测计划等文件。 3 持有人应与监测机构建立有效的沟通和协作机制,确保监测工作的顺利进行。持有人应向监测机构提供必要的药品信息和不良反应报告,并协助监测机构进行相关调查和分析。 4 监测机构应按照监测计划和相关要求,及时收集、记录和分析药品的不良反应信息,并向持有人提供监测报告和分析结果。 5 持有人应及时向所在地省级药品监管部门报送不良反应监测总结报告,汇总和分析药品的不良反应情况,并根据需要采取相应的风险控制措施。 来源:《国家药监局关于加强药品上市许可持有人委托生产监督管理工作的公告(2023年第132号)》

较为笼统,缺乏具体政策依据。此外,Policy-RAG 框架的答案更加完整,涵盖了政策执行的各个环节,并采用条理清晰的列举方式,将政策要求解释得简洁明了,更易于用户理解和执行。

上述案例分析表明,Policy-RAG 框架能够有效提升政策文本生成的质量,使其在实际应用场景中

表现出更高的准确性、完整性和可理解性,同时效果优于通用大模型,为机构、企业、个人等相关用户提供更高效、便捷的政策信息获取和分析服务。

4.4 实验结果讨论

(1) Policy-RAG 优化大模型输出

实验结果表明,检索增强生成技术通过将检索

技术与大语言模型有机结合,有效缩小了生成模型的搜索空间。这主要得益于两方面:一方面,Policy-RAG框架中的检索模块能够从政策文档知识库中检索与用户查询相关的上下文信息,为模型提供更丰富的背景知识,帮助模型更准确地理解用户意图;另一方面,Policy-RAG框架中采用的向量嵌入模型和语义相似度计算方法能够有效地筛选与用户查询语义相关的政策文本,提高了检索结果的质量。这有效地缓解了大语言模型固有的“幻觉”现象,即大语言模型倾向于生成与真实情况不符的虚假信息。

(2) 高质量数据集影响 Policy-RAG 性能

本文基于构建的政策文本数据集进行实验,该数据集包含人工标注的检索增强微调数据,对大模型的生成结果具有显著影响。在构建数据集时,本文通过人工方法寻找问题所涉及的政策原文,并仅选取与问题高度相关的文本数据。同时,通过二次审核确保数据的准确性和完整性,为模型的训练和评估奠定了可靠的基础。实验结果也表明,数据集的质量对模型性能的影响非常显著。未来可以考虑进一步扩充数据集规模,并探索更加高效的数据标注方法,如利用主动学习、半监督学习等技术,以降低数据标注成本,提高数据质量。

(3) Policy-RAG 框架未来改进方向

目前,Policy-RAG框架急需解决的问题是大语言模型生成结果的随机性。由于大语言模型自身的结构特点,其在不同情况下可能会对相同的输入产生不同的输出结果。这种随机性会影响生成结果的一致性和可靠性,尤其是在对特定问题,如某些政策的具体实施步骤进行重复查询时,可能会导致模型在不同时间生成不同的答案,影响用户体验。此外,政策文本数据规模也将不断扩大,因此,未来需要进一步研究如何提高模型输出的稳定性和可控性,以及如何高效地从海量数据中检索相关信息。

5 结 语

本文将大语言模型与政策信息检索相结合,提出了Policy-RAG框架,探讨大语言模型对于已有检索架构的改进以及现有检索技术与大语言模型结合的具体路径,旨在提升政策文本检索与利用的效率。该框架通过整合检索技术和生成技术,利用大语言

模型强大的语义理解和生成能力,为用户提供更精准、便捷的政策信息获取服务。研究表明,Policy-RAG框架在事实一致性、答案相关性和语义相似性等指标上均优于现有模型,验证了其有效性。

基于垂直领域大模型的检索增强方法仍然存在一些问题,如计算资源消耗大、模型回答输出不稳定、可信度不足等,这将会影响其使用效果与推广。因此,未来的研究需要探索更高效的检索结构,设计更轻量级的Policy-RAG框架,以降低计算资源的消耗,使其更容易部署到移动设备等资源受限的平台;并研究如何提高Policy-RAG框架的透明度和可解释性,使用户更信任模型的输出结果,最终提升检索系统的泛化能力和实用性。

参考文献:

- [1] 胡吉明, 张晓娟, 谭婧. 我国政府信息资源研究的主题结构与演化态势[J]. 信息资源管理学报, 2018, 8(3): 54-63, 36.(Hu Jiming, Zhang Xiaojuan, Tan Jing. Intellectual Structure and Evolution Patterns of Government Information Resource Research in China[J]. Journal of Information Resources Management, 2018, 8(3): 54-63, 36.)
- [2] 胡吉明, 杨云. 基于句法结构的政策文本摘要生成模型研究[J]. 情报理论与实践, 2024, 47(11): 177-185.(Hu Jiming, Yang Yun. Research on Policy Text Summarization Model Integrating Sentence Vector and Dependency Syntax[J]. Information Studies: Theory & Application, 2024, 47(11): 177-185.)
- [3] Otter D W, Medina J R, Kalita J K. A Survey of the Usages of Deep Learning for Natural Language Processing[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(2): 604-624.
- [4] 裴雷, 孙建军, 周兆韬. 政策文本计算: 一种新的政策文本解读方式[J]. 图书与情报, 2016(6): 47-55.(Pei Lei, Sun Jianjun, Zhou Zhaotao. Policy Text Computing: A New Methodology of Policy Interpretation[J]. Library & Information, 2016(6): 47-55.)
- [5] 李江, 刘源浩, 黄萃, 等. 用文献计量研究重塑政策文本数据分析——政策文献计量的起源、迁移与方法创新[J]. 公共管理学报, 2015, 12(2): 138-144, 159.(Li Jiang, Liu Yuanhao, Huang Cui, et al. Remolding the Policy Text Data Through Documents Quantitative Research: The Formation, Transformation and Method Innovation of Policy Documents Quantitative Research [J]. Journal of Public Management, 2015, 12(2): 138-144, 159.)
- [6] 吴建南, 郑烨, 贾金晓. 国家治理体系现代化的网络结构与实践路径——十八届三中全会《决定》的社会网络分析[J]. 上海行政学院学报, 2015, 16(2): 36-47.(Wu Jiannan, Zheng Ye, Jia Jinxiao. The Network Structure and Practice Path of

- Modernization of National Governance System: Social Network Analysis on 'Decision' of the Third Plenary Session of the 18th CPC Central Committee[J]. The Journal of Shanghai Administration Institute, 2015, 16(2): 36-47.)
- [7] 李小宇. 中国互联网内容监管机制研究[D]. 武汉:武汉大学, 2014.(Li Xiaoyu. Study on China's Internet Content Regulation Mechanism [D]. Wuhan: Wuhan University, 2014.)
- [8] 杨慧, 杨建林. 融合 LDA 模型的政策文本量化分析——基于国际气候领域的实证[J]. 现代情报, 2016, 36(5): 71-81.(Yang Hui, Yang Jianlin. Quantitative Analysis of Policy Text Merged with LDA Model—Based on the Field of International Climate as Demonstration[J]. Journal of Modern Information, 2016, 36(5): 71-81.)
- [9] 张祥祥. 面向科技政策的知识增强文本摘要方法的研究与应用[D]. 沈阳:中国科学院沈阳计算技术研究所, 2022.(Zhang Xiangxiang. Research and Application of Knowledge-Enhanced Text Summarization Method for Technology Policy[D]. Shenyang: Shenyang Institute of Computing Technology, Chinese Academy of Sciences, 2022.)
- [10] Cutting D, Pedersen J. Optimization for Dynamic Inverted Index Maintenance[C]//Proceedings of the 13th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. 1989: 405-411.
- [11] Zhang S, Yao L N, Sun A X, et al. Deep Learning Based Recommender System: A Survey and New Perspectives[J]. ACM Computing Surveys, 2020, 52(1): Article No.5
- [12] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond[J]. Foundations and Trends® in Information Retrieval, 2009, 3(4): 333-389.
- [13] Quirk G J, Mueller D. Neural Mechanisms of Extinction Learning and Retrieval[J]. Neuropsychopharmacology, 2008, 33(1): 56-72.
- [14] Nesbit J C, Adesope O O. Learning with Concept and Knowledge Maps: A Meta-Analysis[J]. Review of Educational Research, 2006, 76(3): 413-448.
- [15] devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019: 4171-4186.
- [16] Mitra B, Craswell N. An Introduction to Neural Information Retrieval[J]. Foundations and Trends® in Information Retrieval, 2018, 13(1): 1-126.
- [17] Karpukhin V, Oguz B, Min S, et al. Dense Passage Retrieval for Open-Domain Question Answering[C]// Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing(EMNLP). 2020:6769-6781.
- [18] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Proceedings of the 34th International Conference on Neural Information Processing Systems. 2020: 9459-9474.
- [19] Ai Q Y, Bai T, Cao Z, et al. Information Retrieval Meets Large Language Models: A Strategic Report from Chinese IR Community[J]. AI Open, 2023, 4: 80-90.
- [20] Guo J F, Fan Y X, Pang L, et al. A Deep Look into Neural Ranking Models for Information Retrieval[J]. Information Processing & Management, 2020, 57(6): 102067.
- [21] Zhang Y, Rahman M M, Braylan A, et al. Neural Information Retrieval: A Literature Review[OL]. arXiv Preprint, arXiv: 1611.06792.
- [22] Sathyendra K M, Choudhary S, Nicolich-Henkin L. Extreme Model Compression for On-Device Natural Language Understanding[OL]. arXiv Preprint, arXiv:2012.00124.
- [23] Huang M L, Zhu X Y, Gao J F. Challenges in Building Intelligent Open-Domain Dialog Systems[J]. ACM Transactions on Information Systems, 2020, 38(3): 21.
- [24] Xunzillm4cc/Qwen-7B-Policy[DB/OL]. [2024-06-15]. <https://modelscope.cn/profile/Xunzillm4cc>.

作者贡献声明:

沈思:论文整体设计、规划和文字修改;
冯暑阳:收集论文数据,文献综述与技术路线调研,模型训练和论文撰写;
吴娜:模型调优和论文撰写;
赵志泉:模型参数调优。

利益冲突声明:

所有作者声明不存在利益冲突关系。

支撑数据:

- [1] 冯暑阳. policydata 数据集. <https://huggingface.co/datasets/fsyfb/policydata/tree/main>.
- [2] 赵志泉. 政策文本大语言模型 chatglm3-6b-policy. <https://modelscope.cn/models/Xunzillm4cc/chatglm3-6b-policy>.
- [3] 赵志泉. 政策文本大语言模型 Qwen-7B-Policy. <https://modelscope.cn/models/Xunzillm4cc/Qwen-7B-Policy>.

收稿日期:2024-07-05

收修改稿日期:2024-10-12

Retrieval-Augmented Generation of Policy Texts Based on Large Language Models

Shen Si¹ Feng Shuyang¹ Wu Na² Zhao Zhixiao²

¹(School of Economics & Management, Nanjing University of Science & Technology, Nanjing 210094, China)

²(College of Information Management, Nanjing Agricultural University, Nanjing 210095, China)

Abstract: [Objective] This paper aims to enhance the utilization efficiency of governmental information resources and advance the intelligent transformation of public services by addressing the inherent knowledge limitations of general LLMs when processing policy texts. We investigate the effectiveness of a RAG framework to construct a more precise and reliable intelligent policy Q&A system. [Methods] This paper proposes a retrieval-augmented generation framework based on the Chinese policy large language model ChpoGPT. Specifically, the framework retrieves semantically similar policy documents from a knowledge base based on user queries and combines the retrieved results with ChpoGPT to enhance the model's capabilities for downstream tasks. [Results] Experimental results demonstrate that our framework significantly outperforms existing models on key metrics. The ChpoGPT-based framework achieved a factuality score of nearly 90%. In terms of answer relevance, it scored 80.2%, outperforming the Gemini-1.0-pro model by 2.1%. Furthermore, it attained an answer semantic similarity score of 56.4%, surpassing the ERNIE 4.0 and Gemini-1.0-pro models by 4.1% and 2.8%, respectively. [Limitations] The language model still exhibits some uncontrollable behaviour in its answer output. [Conclusions] The retrieval-augmented generation of policy texts based on LLMs has certain reference value for the intelligent transformation of government services, but it still needs further improvement and optimization.

Keywords: Large Language Model Retrieval-Augmented Generation Natural Language Processing Policy Text

AI虽然不知道自己在做什么,却正在威胁全人类

近日,澳大利亚查尔斯·达尔文大学的一项研究认为,AI已经改变了人类的互动方式,并正在全球范围内威胁着人类的尊严。

研究人员认为,当前对AI的监管未能优先考虑基本的人权和自由,如隐私、反歧视、用户自主权和知识产权,产生这一问题的主要原因是许多算法模型具有不可追溯性。研究人员将这种缺乏透明度的现象称为“黑箱问题”,并指出,由深度学习或机器学习过程做出的决策是人类无法追踪的,这使得用户难以确定AI模型是否以及为何侵犯了他们的权利和尊严,导致用户无法在必要时寻求正义。

这是一个非常严重的问题,如果没有适当的监管,情况只会变得更糟。研究人员认为:“AI在人类理解的任何意义上都不具有智能。AI是工程学的胜利,而非认知行为的胜利。AI根本不知道自己在做什么或为什么这么做,不存在人类所理解的那种思维过程,只有纯粹的模式识别。”

研究人员指出:“在全球范围内,如果我们不将AI的发展锚定在使我们成为人类的核心特质上——我们的选择能力、感受能力、谨慎推理能力、同理心和同情心的能力——我们就有可能创造出贬低人性、将人类扁平化为数据点的系统,而无法改善人类生存状况。”

(编译自:<https://www.sciencedaily.com/releases/2025/09/250907172635.htm>)

(本刊讯)