

开题报告自学讲义

面向复杂金融查询的检索增强问答系统

(由浅入深 · 纯中文 · 工程对齐版)

基于开题报告与仓库 SEAL 结果整理

2026 年 3 月 12 日

使用说明：本讲义对应文件与证据源为 报告/开题报告 _ 石延斌 _U202216405_ 题目 _2026 年 3 月 11 日.pdf、docs/TABLE_MAIN.md、docs/TABLE_NUMERIC.md、docs/MILESTONE_REPORT.md、thesis/figures_seal/ThemeA/figures/*。讲义目标不是“堆概念”，而是帮你从零基础一步步理解：问题为什么难、方法怎么搭、实验说明了什么、目前哪里还没闭环。

目录

1 问题背景	5
1.1 先讲直觉	5
1.2 再讲定义	5
1.3 再讲本报告中的实现与结果	5
1.4 易错点	5
1.5 自测题	6
2 核心概念	6
2.1 先讲直觉	6
2.2 再讲定义	6
2.3 再讲本报告中的实现与结果	6
2.4 易错点	6
2.5 自测题	7
3 RAG 基础	7
3.1 先讲直觉	7
3.2 再讲定义	7
3.3 再讲本报告中的实现与结果	7
3.4 易错点	7
3.5 自测题	8
4 金融查询难点	8
4.1 先讲直觉	8
4.2 再讲定义	8
4.3 再讲本报告中的实现与结果	8
4.4 易错点	8
4.5 自测题	8
5 你的方法四模块	9

目录	3
5.1 先讲直觉	9
5.2 再讲定义	9
5.3 再讲本报告中的实现与结果	11
5.4 易错点	13
5.5 自测题	13
6 实验矩阵解读	13
6.1 先讲直觉	13
6.2 再讲定义	13
6.3 再讲本报告中的实现与结果	13
6.4 易错点	16
6.5 自测题	16
7 关键结论	16
7.1 先讲直觉	16
7.2 再讲定义	16
7.3 再讲本报告中的实现与结果	16
7.4 易错点	17
7.5 自测题	17
8 负结论与局限	17
8.1 先讲直觉	17
8.2 再讲定义	17
8.3 再讲本报告中的实现与结果	18
8.4 易错点	18
8.5 自测题	18
9 复现实操	19
9.1 先讲直觉	19
9.2 再讲定义	19

目录	4
9.3 再讲本报告中的实现与结果	19
9.4 易错点	20
9.5 自测题	20
10 总结与自测	20
10.1 先讲直觉	20
10.2 再讲定义	20
10.3 再讲本报告中的实现与结果	20
10.4 易错点	21
10.5 自测题	21
A 附录：关键指标速查卡	21
B 附录：证据源定位	21
C 附录：最小案例推演	22
D 附录：答辩口径与自查清单	24

1 问题背景

1.1 先讲直觉

你这项研究要解决的是一个很真实的问题：面对很长的金融披露文件（例如年报），人很难在短时间内又快又准地找到证据并回答问题。金融问题常常不是“一个句子对应一个答案”，而是同时要求系统做到三件事：先找到证据，再对齐年份，最后给出可核验的数值或结论。如果只靠大模型直接“生成”，容易出现看起来流畅但无法核对的答案。

1.2 再讲定义

复杂金融查询可以简单理解为：在一个问题里同时有专业术语、时间约束和数值要求。**检索增强问答**可以理解为：先去文档里找证据，再根据证据作答，而不是只凭模型参数记忆回答。

1.3 再讲本报告中的实现与结果

你的开题报告明确把目标聚焦在三个核心能力上：证据定位、年份对齐、数值可靠性。对应仓库工程，当前已经形成可冻结的实验链路（SEAL）：

- matrix_id: 20260228_055920_06d6bb
- 20 个实验 run 全部 status=ok
- 主结果表、数值表、消融表已更新

这说明当前讲义可以建立在**稳定证据**上，而不是停留在“想法阶段”。

1.4 易错点

- 把“问题复杂”理解成“问题很长”。实际上短问题也可能很复杂（例如缩写 + 年份 + 同比）。
- 把“模型会回答”理解成“答案可靠”。金融场景里，可靠性必须可追溯到证据。
- 把“实验跑通”理解成“结论成立”。跑通是必要条件，稳定增益才是结论条件。

1.5 自测题

1. 为什么金融问答必须强调“证据可核验”，而不仅是“语言通顺”？
2. 同一个短问题为什么也可能是复杂查询？
3. 你的项目里“可冻结”具体意味着什么？

2 核心概念

2.1 先讲直觉

先把全局地图建立起来：你做的不是单模型调参，而是一条系统链路。链路中每个模块有输入、有输出、有开关，因此可以做干净的对照实验。

2.2 再讲定义

- 稀疏检索 (BM25)：依赖关键词匹配，擅长精确字符串命中。
- 稠密检索 (Dense)：把查询和文本映射到向量空间，擅长语义匹配。
- 混合检索 (Hybrid)：融合前两者分数，兼顾关键词与语义。
- 查询扩展 (PQE)：在查询中补充关键线索（尤其是年份线索）提高召回。
- 门控计算 (Calculator Gating)：只有条件满足才计算，否则回退。

2.3 再讲本报告中的实现与结果

根据里程碑文档，当前链路可抽象为：查询 → 检索模式选择 → (可选) 扩展/多步检索 → (可选) 数值工具链 → 输出答案。核心认识是：稳定增益主要在检索侧，数值侧目前还在诊断阶段。

2.4 易错点

- 把“模块多”误认为“创新多”。真正重要的是每个模块是否带来可证实增益。
- 把“组合后 coverage 上升”误判为“整体质量提升”。还要看 EM 是否同步改善。

2.5 自测题

1. 稀疏检索和稠密检索各自的优势是什么？
2. 为什么系统要做模块化开关？
3. 如果 coverage 上升但 EM 下降，应该如何解读？

3 RAG 基础

3.1 先讲直觉

RAG 的核心不是“让模型更会说”，而是“让答案有出处”。在金融场景，RAG 的价值非常直接：减少幻觉、增强可追溯、便于人工复核。

3.2 再讲定义

RAG 可分为两层：

1. 检索层：从文档中找到候选证据；
2. 生成/回答层：基于证据输出答案（必要时调用计算工具）。

只要检索层错了，后面再复杂都很难救回来。

3.3 再讲本报告中的实现与结果

你的报告把关注点放在“检索质量如何决定上限”，这与仓库结果一致。例如在主结果表中，m01→m02（Retriever FT）让 full_r10 从 0.3246 提升到 0.3789，full_mrr10 从 0.2030 提升到 0.2554，说明检索底座提升会整体抬升后续能力上限。

3.4 易错点

- 误以为“RAG= 接上向量数据库就完成”。实际上 query 改写、门控、评测口径都影响结果。
- 忽视排序质量。召回高但排序差，会增加后续阅读负担和错误传播。

3.5 自测题

1. 为什么说检索质量决定系统上限？
2. R@10 和 MRR@10 分别反映什么？
3. 检索召回足够高是否就一定能得到高质量最终答案？

4 金融查询难点

4.1 先讲直觉

金融问答比通用问答更难，难在“语义、时间、数值”三重耦合。你不能只回答“是什么”，还要回答“依据在哪”“对应哪一年”“数值是否一致”。

4.2 再讲定义

- 语义难点：缩写、术语密集，表述变体多。
- 时间难点：问题常隐含年份，跨年比较容易错位。
- 数值难点：单位、口径、取值位置、计算类型常常互相缠绕。

4.3 再讲本报告中的实现与结果

仓库中对子集（complex / abbrev / numeric）的拆分，就是为了解耦这三类难点。从结果看，年份感知的扩展策略（PQE 全量版）对 complex 与 abbrev 子集都有稳定小幅提升，而数值工具链仍表现为 coverage 与 EM 的权衡，尚未闭环。

4.4 易错点

- 把“年份”当普通关键词处理。实际需要时间约束一致性，而不只是命中数字。
- 数值任务里忽略单位。单位不一致会让看似正确的计算变成错误答案。

4.5 自测题

1. 为什么“年份对齐”在金融问答中是刚性约束？

2. 哪些情况下数值任务必须回退而不是强算？
3. complex 子集和 numeric 子集分别侧重哪类难点？

5 你的方法四模块

5.1 先讲直觉

你的方法不是一个“大招”，而是四个模块协同：检索评分优化、年份感知扩展、多步检索控制、数值门控计算。这四块分别解决“找得到、找得准、找得稳、算得对”。

5.2 再讲定义

模块 A：检索评分（Dense + BM25 融合）

$$s_{\text{dense}}(q, c) = \langle e_q(q), e_c(c) \rangle \quad (1)$$

公式含义：用向量相似度衡量查询与证据片段的语义相关性。**一句话例子：**问题写的是“运营利润”，证据写的是“经营收益”，也可能被召回。

$$s_{\text{hybrid}}(q, c) = \alpha \cdot \text{Norm}(s_{\text{BM25}}) + (1 - \alpha) \cdot \text{Norm}(s_{\text{dense}}) \quad (2)$$

公式含义：把关键词匹配与语义匹配按权重融合。**一句话例子：**公司缩写靠 BM25，语义近义词靠 dense，两者一起用更稳。

模块 B：年份感知查询扩展（PQE）

$$Q(q) = \{q_0 = q, q_1, \dots, q_m\}, \quad m \leq M \quad (3)$$

公式含义：从原始查询生成有限个受控变体，而不是无限扩写。**一句话例子：**对“比较近两年毛利率”的问题，自动补充候选年份表达。

$$s_{\text{final}}(q, c) = s_{\text{hybrid}}(q, c) + \lambda \sum_j \mathbf{1}[c \in \text{TopM}(q_j)] \cdot s_{\text{hybrid}}(q_j, c) \quad (4)$$

公式含义：仅当证据在扩展查询的高分集合中重复出现，才获得增益。**一句话例子：**同一证据在“2023 年”和“2024 年”变体下都靠前，可信度更高。

模块 C：多步检索与停止门控

多步检索用于在不确定时继续追证，但要设停止条件，避免无效迭代。在你当前结果中，它是合理 **baseline**，但尚未带来净增益。

模块 D：数值工具链与门控回退

$$\hat{y}_i = \begin{cases} \text{Calc}(z_i), & G_i = 1 \\ \text{Base}(z_i), & G_i = 0 \end{cases} \quad (5)$$

公式含义：条件满足才计算，不满足就走保守回退。**一句话例子：**识别出“同比”且年份与单位一致才计算，否则给证据抽取答案。

$$\text{R@k} = \frac{1}{N} \sum_{i=1}^N \frac{|E_i \cap R_i^{(k)}|}{|E_i|} \quad (6)$$

公式含义：前 k 条候选覆盖到多少正确证据。**一句话例子：**前 10 条里至少包含正确段落，后续模块才有机会。

$$\text{MRR@k} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i} \quad (7)$$

公式含义：正确证据排得越靠前，值越大。**一句话例子：**正确证据排第 1 名比排第 8 名更有利于稳定作答。

$$\text{numeric EM} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\text{round}(p_i, t) = \text{round}(g_i, t)] \quad (8)$$

公式含义：数值答案在统一精度下是否严格命中。**一句话例子：**预测 12.35，标准 12.349，在两位小数规则下视为命中。

$$\text{coverage} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[p_i \text{ 可被成功解析}] \quad (9)$$

公式含义：系统有多少比例的问题“敢给出可评估数值答案”。**一句话例子：**coverage 高说明答得多，但不代表答得准。

5.3 再讲本报告中的实现与结果




图 1: 复杂金融查询任务全景图。

这张图回答什么问题：你的系统整体链路如何从查询走到可核验答案？




图 2: 稀疏/稠密/混合检索对比图。

这张图回答什么问题：为什么单一检索范式不够，融合策略有什么现实价值？




图 3: 年份感知查询扩展流程图。

这张图回答什么问题：系统如何在无约束扩写的前提下提高年份对齐能力？




图 4: 多步检索与停止门控流程图。

这张图回答什么问题：为什么多步检索要有“继续/停止”判定，而不是无限迭代？




图 5: 数值工具链门控与回退流程图。

这张图回答什么问题：系统何时该算、何时不该算，如何降低错误计算风险？




图 6: 实验矩阵与结论分层图。

这张图回答什么问题：哪些结果可写主结论，哪些只能写诊断与局限？

5.4 易错点

- 公式写得复杂不等于系统更强，必须看实验是否支持。
- 扩展查询若不受控，容易引入年份噪声，反而伤害精度。
- 门控策略目标不是“多算”，而是“在对的条件下再算”。

5.5 自测题

1. 混合检索公式中的 α 过大或过小会带来什么倾向？
2. 为什么 s_{final} 要对 TopM 命中再加分，而不是全局加分？
3. numeric EM 与 coverage 为什么必须一起看？

6 实验矩阵解读

6.1 先讲直觉

这一节不是“看谁数值最大”，而是学会读对照。对照干净，结论才可信；对照混乱，再高的数字也很难解释。

6.2 再讲定义

当前 SEAL 实验可以按四层理解：

1. 检索底座层（m01–m04）
2. 多步检索层（m05–m10）
3. 数值工具链层（m11–m17）
4. PQE 与交互层（m18–m20）

6.3 再讲本报告中的实现与结果

检索主指标（摘自 docs/TABLE_MAIN.md）

Run	full_r10	full_mrr10	complex_r10	abbrev_r10	解读
m01	0.3246	0.2030	0.3457	0.3174	pre-FT 对照基线
m02	0.3789	0.2554	0.3951	0.3713	post-FT, 稳定抬升
m03	0.2246	0.1266	0.2099	0.2136	BM25 明显落后
m04	0.3491	0.2092	0.3457	0.3373	Hybrid 好于 BM25, 弱于 Dense
m05	0.3789	0.2556	0.3951	0.3713	multistep 与 m02 基本持平
m07	0.3789	0.2556	0.3951	0.3713	gate 放开仍无净增益
m09	0.3789	0.2554	0.3951	0.3713	gate 关闭仍无净增益
m18	0.3842	0.2584	0.4074	0.3752	PQE 全量, 小幅稳定提升
m19	0.3789	0.2556	0.3951	0.3713	仅缩写扩展, 提升消失
m20	0.3842	0.2584	0.4074	0.3752	PQE+calc 的检索侧同 m18

数值主指标（摘自 docs/TABLE_NUMERIC.md）

Run	num_em	num_cov	解读
m11	0.3964	0.6180	计算触发更保守, EM 高但覆盖低
m12	0.3197	0.6695	calculator 主 baseline (允许 yoy/diff)
m13	0.2867	0.6824	关闭 gate 后 coverage 升、EM 降
m15	0.2933	0.6824	扩任务空间后仍未闭环
m20	0.3079	0.6867	与 m12 比较: coverage 升, EM 降

复用现有实验图 1: 消融拆解




图 7: SEAL 消融拆解图（复用仓库现有图）。

这张图回答什么问题：基线、增强模块和组合模块之间的增减关系是什么？

复用现有实验图 2：缩写子集对比




图 8: 缩写子集表现图（复用仓库现有图）。

这张图回答什么问题：面对缩写密集问题，不同策略在召回与排序上谁更稳？

6.4 易错点

- 只看单个 run，不看成组对照，容易误判模块贡献。
- 把 m20 检索侧提升直接当成数值侧闭环，这是跨指标偷换。
- 忽略“主 baseline”定义：里程碑将 m12 视为 calculator 主对照，不是 m11。

6.5 自测题

1. 为什么 m19 能作为“PRF-year 有效性”的反事实对照？
2. m13 相比 m12 告诉我们怎样的门控代价？
3. m20 的结果为什么属于“弱结论”而不是“强结论”？

7 关键结论

7.1 先讲直觉

关键结论要满足两个条件：指标改善稳定 + 模块归因清楚。只满足其一，都不应该写成主结论。

7.2 再讲定义

本讲义采用三层结论框架：

1. 强结论：可进摘要与主结论；
2. 弱结论：有信号但未闭环；
3. 负结论：在当前口径下未见净增益。

7.3 再讲本报告中的实现与结果

强结论 1：Retriever FT 是当前最稳增益来源。

- m01→m02：full_r10 +0.0543；full_mrr10 +0.0524。
- complex_r10 +0.0494；abbrev_r10 +0.0539。

- 说明不是局部偶然提升，而是检索底座整体上移。

强结论 2: Dense 是当前主模式。

- m02 对 m03 (BM25) 有显著优势；
- m04 (Hybrid) 虽优于 BM25，但仍弱于 m02。

中等结论: PQE (含年份扩展) 可替代 multistep 作为主增益路径。

- m18 比 m02 有一致小幅提升；
- m19 (abbrev-only) 回落到 m02 水平，支持“主增益来自年份相关扩展”。

7.4 易错点

- 把“提升幅度不大”误判为“没有价值”。稳定小幅提升在工程系统中同样重要。
- 把“单次高点”当稳定结论。这里强调的是多指标一致、对照清晰。

7.5 自测题

1. 为什么 m01→m02 可以独立成立为主结论？
2. PQE 的证据链为什么需要 m19 这种反事实 run？
3. 强结论与弱结论在证据要求上有什么区别？

8 负结论与局限

8.1 先讲直觉

负结论不是失败，而是把“看起来合理但当前无效”的路径排除掉。这会让后续研究更聚焦、更省时间。

8.2 再讲定义

负结论: 在既定数据与口径下，模块没有产生可观测净增益。**未闭环:** 某些指标改善，但未转化为最终质量同步提升。

8.3 再讲本报告中的实现与结果

负结论 1: multistep 当前未见净增益。

- m05、m07、m09 与 m02 几乎持平。
- 结论是“当前实现和口径下无增益”，不是“多步检索理论无效”。

负结论 2: calculator 出现 coverage-EM 背离。

- m12→m13: coverage 从 0.6695 到 0.6824，但 EM 从 0.3197 到 0.2867。
- m12→m15: coverage 同样上升，但 EM 仍下降。

弱结论: 组合模块 C (m20) 有交互，无闭环。

- 与 m12 比: coverage +0.0172, EM -0.0118。
- 说明 retrieval 侧提升确实把更多样本送入 numeric 路由，但尚未转化为更高质量数值答案。

局限披露: 子集路径仍需完全对齐。里程碑中已提示 subsets_v2 概念修正存在，但部分 resolved config 仍指向旧路径，论文写作应明确披露这一点，避免口径误解。

8.4 易错点

- 把“有交互信号”直接写成“方法有效”。
- 把“局限披露”理解为减分。事实上完整披露会提升研究可信度。

8.5 自测题

1. multistep 当前结果应该如何在论文中表述才严谨？
2. 为什么 m20 不能写成“正向主结论”？
3. coverage 与 EM 的权衡在系统设计上意味着什么？

9 复现实操

9.1 先讲直觉

复现不是“把命令跑一遍”，而是确保别人用同一口径能得到同一结论。因此必须固定事实源、命令顺序和产物边界。

9.2 再讲定义

根据仓库封条规则,当前采用 commit-safe 证据面:docs/TABLE_*.md、docs/SEAL_*.md、thesis/figures_seal/**。outputs/** 可用于本地审计,但不作为远端提交边界。

9.3 再讲本报告中的实现与结果

规范复现顺序（四步）:

1. 先烟雾测试（必须先跑）:

```
python scripts/smoke.py --config configs/smoke.yaml --run-id seal_final_smoke
```

2. 再跑 seal 矩阵:

```
python scripts/run_matrix_step6.py --base-config configs/step6_base.yaml \
  --matrix configs/step6_matrix_seal.yaml
```

3. 生成主表:

```
python scripts/make_tables.py --experiments configs/step6_experiments_seal.yaml
```

4. 生成图表:

```
python scripts/plot_all.py --config scripts/plot_config.yaml
```

本讲义自身编译方式（本目录）:

```
powershell -ExecutionPolicy Bypass -File .\build_report_lecture.ps1
```

9.4 易错点

- 直接使用旧 matrix 配置，导致表与图和正文口径不一致。
- 跳过 smoke，违反工程策略，也增加后续排错成本。
- 只留 outputs，不更新 docs/TABLE_*.md。

9.5 自测题

1. 为什么 smoke 必须在实验前执行？
2. 为什么论文正文应优先引用 docs/TABLE_*.md？
3. “可复现”和“可审计”的区别是什么？

10 总结与自测

10.1 先讲直觉

这份讲义真正想帮你建立的是一个判断框架：面对一个模块，不问“新不新”，先问“有没有干净证据证明它有效”。

10.2 再讲定义

你当前项目的最稳主线可以压缩为三句话：

1. 先把检索底座做好（Retriever FT + Dense 主模式）；
2. 再做受控扩展（PQE 尤其是年份扩展）；
3. 数值侧继续聚焦路由质量与闭环，不急于扩大任务空间。

10.3 再讲本报告中的实现与结果

一句话总评：当前证据清楚支持“检索侧已形成稳定主增益”，而“数值侧与组合模块 C 仍处于诊断和闭环前阶段”。

你下一步最值得投入的方向：

- 对齐并冻结子集路径口径；
- 强化 numeric 路由诊断（task dispatch / fact filtering / fallback 质量）；
- 在闭环证据出现前，谨慎对外宣称组合模块贡献。

10.4 易错点

- 把“做了很多模块”当“论文贡献完整”。
- 为了叙事完整而弱化负结论，反而会损害可信度。

10.5 自测题

1. 如果答辩老师问“你的核心贡献是什么”，你怎么用 30 秒回答？
2. 如果被追问“为什么多步检索没效果”，你怎么严谨表述？
3. 如果被追问“m20 是不是成功了”，你怎么解释“有交互但未闭环”？

A 附录：关键指标速查卡

指标/概念	快速解释
R@10	前 10 条候选里覆盖正确证据的能力，解决“找没找回来”。
MRR@10	正确证据在候选中的前置程度，解决“排得靠不靠前”。
numeric EM	数值答案在统一精度下是否命中，解决“算得准不准”。
coverage	是否给出可解析数值答案，解决“答得出来多少”。
强结论	多指标一致改善，且可清楚归因到具体模块开关。
弱结论	出现局部正信号，但未形成全链路质量闭环。
负结论	在当前设置下无净增益，帮助排除无效路径。

B 附录：证据源定位

- 开题报告:报告/开题报告 _ 石延斌 _U202216405_ 题目 _2026 年 3 月 11 日.pdf
- 主结果: docs/TABLE_MAIN.md

- 数值结果: docs/TABLE_NUMERIC.md
- 里程碑解释: docs/MILESTONE_REPORT.md
- SEAL 状态: docs/SEAL_FINAL_CHECK.md
- 现有实验图: thesis/figures_seal/ThemeA/figures/ablation_breakdown.png、thesis/figures_seal/ThemeA/figures/abbrev_breakdown.png

C 附录：最小案例推演

案例 1：缩写密集查询

题型示例：“比较某公司近两年 EPS 与 EBITDA 的变化。”推演步骤：

1. 先识别缩写词（EPS、EBITDA）并建立术语映射；
2. 检索层优先采用 Dense 主模式，再用关键词兜底；
3. 若原始查询年份信息不足，触发年份感知扩展；
4. 返回证据时保留来源段落与年份标签，便于核查。

你应关注的诊断点：

- 缩写映射是否把术语解释错位；
- 检索命中是否落在正确年份段落；
- top-k 中正确证据位置是否足够靠前。

案例 2：跨年份比较查询

题型示例：“公司风险因素在 2023 与 2024 年变化最大的条目是什么？”推演步骤：

1. 原始查询先做种子检索，抽取候选年份线索；
2. 对年份变体做受控扩展，避免无约束改写；
3. 用融合分数重排，优先保留双年份都命中的证据；
4. 输出答案时附上两年对应证据段，避免主观总结。

你应关注的诊断点：

- 年份实体是否被错误扩展到不相关年份；
- 两个年份证据是否来自同一语义口径；
- 系统是否只给结论不提供可核验证据。

案例 3：数值计算查询

题型示例：“请给出某指标同比增速并说明计算依据。”推演步骤：

1. 先识别任务类型（同比 / 差值 / 比例）；
2. 抽取操作数、单位、年份并做一致性校验；
3. 仅在门控通过时调用计算器；
4. 若门控失败，回退到证据抽取答案并显式说明原因。

你应关注的诊断点：

- coverage 上升是否伴随 EM 下降；
- 回退路径的答案是否可读且可核对；
- 计算触发比例是否过高导致误算扩散。

案例 4：组合模块 C 诊断

题型示例：“在启用 PQE+calculator 后，系统是否整体更好？”推演步骤：

1. 先看检索侧指标是否提升（m20 相比 m12）；
2. 再看数值侧是否同步提升（EM 与 coverage）；
3. 若仅 coverage 提升，判定为有交互但未闭环；
4. 将结果归入弱结论，不上升为主贡献。

你应关注的诊断点：

- 是否发生跨指标偷换（检索增益替代数值闭环）；
- 是否存在只强调可回答率、不强调准确率的偏差；
- 结论是否与里程碑分层口径一致。

D 附录：答辩口径与自查清单

高频追问的标准回答框架

可能问题	建议回答框架
你的核心贡献是什么？	先给一句话主结论：检索侧形成稳定增益；再给两组证据：m01→m02、m02→m18；最后明确边界：数值侧未闭环。
为什么多步检索没有提升？	强调“当前实现和口径下无净增益”，并给 m05/m07/m09 与 m02 基本持平的证据；不把它扩大为理论无效。
为什么不直接强调组合模块 C？	给出 m20 与 m12 的 numeric 对比：coverage 上升但 EM 下降；说明其定位是弱结论与后续工作入口。
你的工作可复现吗？	说明 canonical 四步命令、SEAL matrix 全部 ok、主表与图均可重建；并区分 commit-safe 证据面与本地审计产物。
你和已有 RAG 工作的区别？	不是只做通用 RAG，而是围绕金融场景的年份对齐与数值可靠性，做模块化协同与可归因消融。

提交前 15 条自查清单

1. 所有关键数字与 TABLE_MAIN/TABLE_NUMERIC 完全一致。
2. 强/弱/负结论分层与 MILESTONE_REPORT.md 一致。
3. 没有把 coverage 提升写成闭环成功。
4. 没有把局部信号写成全局主结论。
5. 所有图都写清楚“这张图回答什么问题”。
6. 公式后面都有“公式含义 + 一句话例子”。
7. 每章都有易错点与自测题。
8. 复现部分明确 smoke 在先。
9. 复现部分区分 commit-safe 与 outputs 审计层。
10. 对 multistep 的表述是“当前无净增益”，不是“理论无效”。

11. 对组合模块 C 的表述是“有交互、未闭环”。
12. 子集口径风险被明确披露，不回避。
13. 所有路径名、run 名字可在仓库中对应到实际文件。
14. 讲义语言以中文为主，英文缩写都给了中文语境解释。
15. 最终 PDF 编译通过且无缺图。